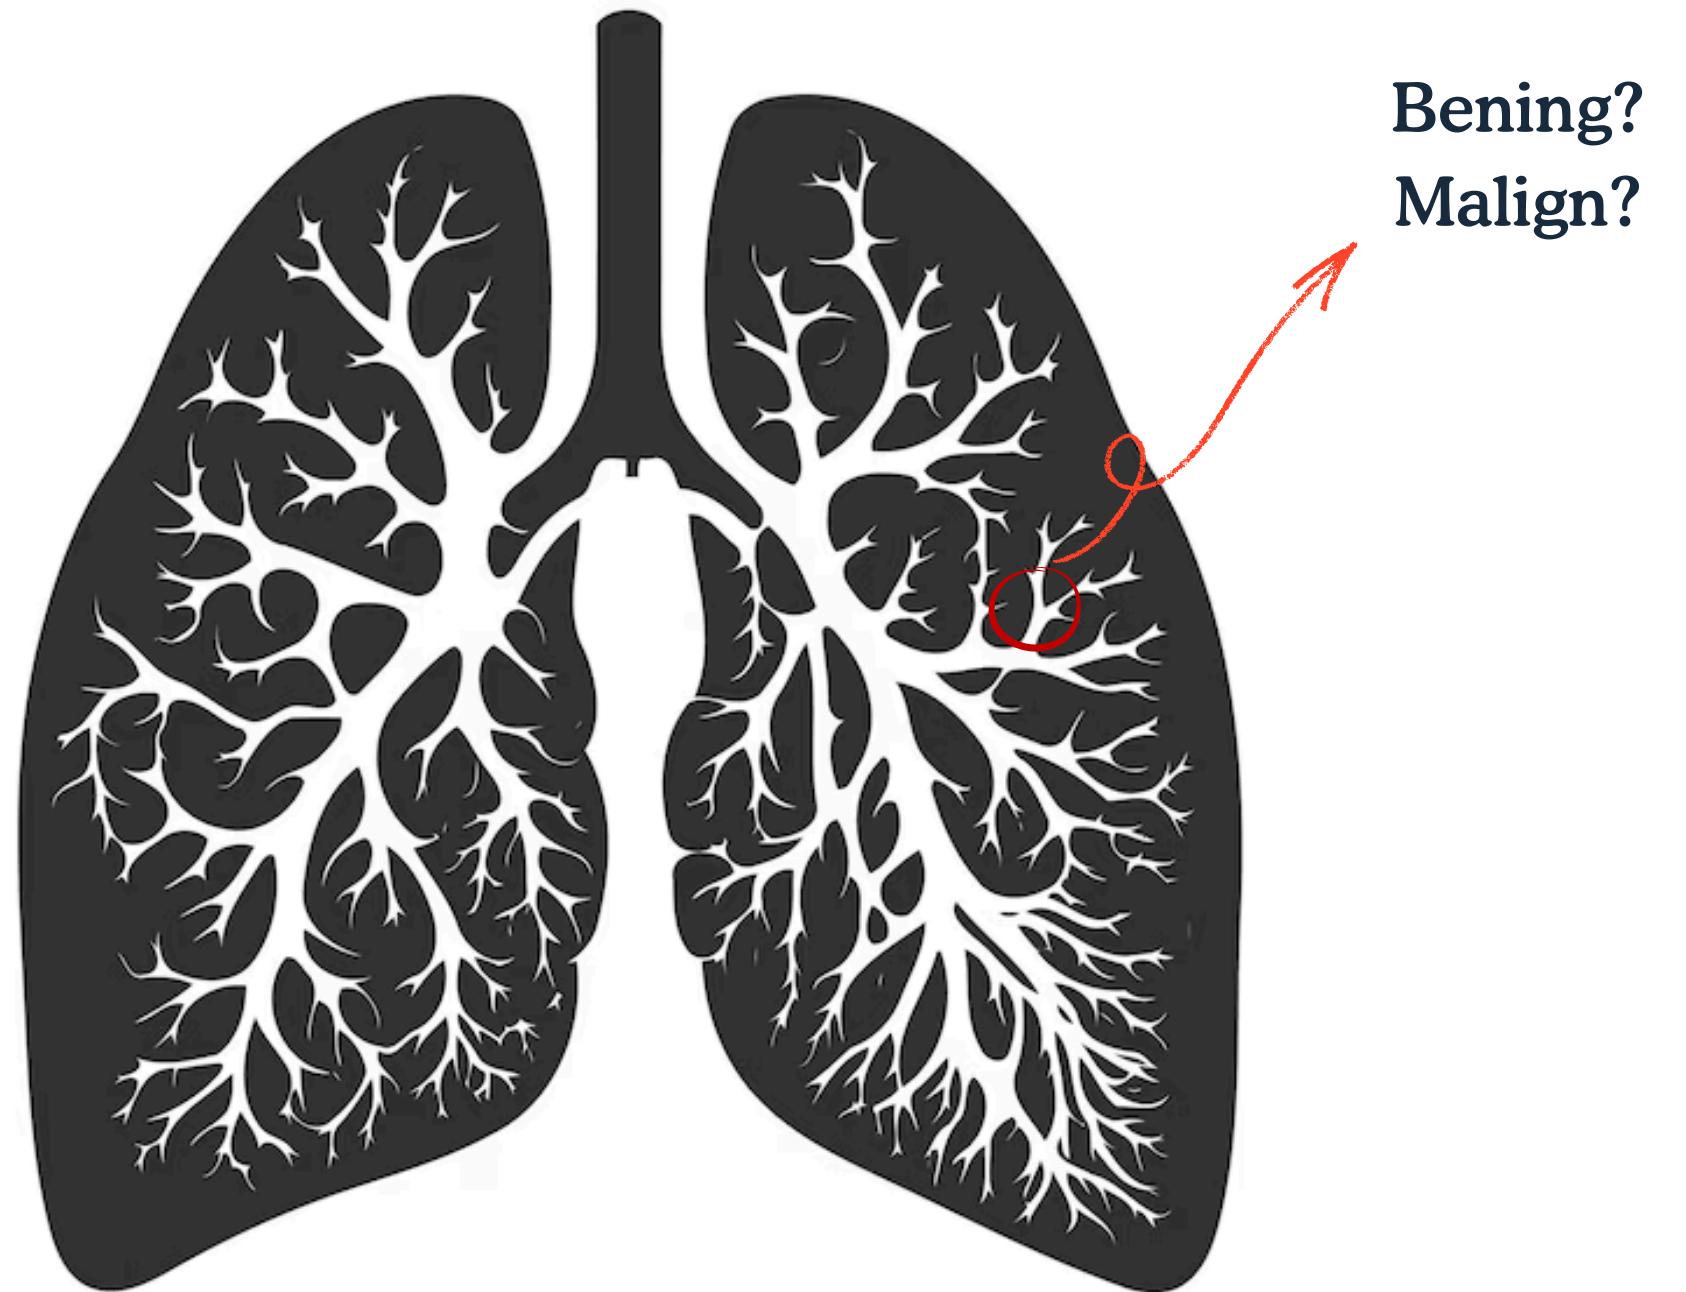


# Clasificación de Nódulos Pulmonares

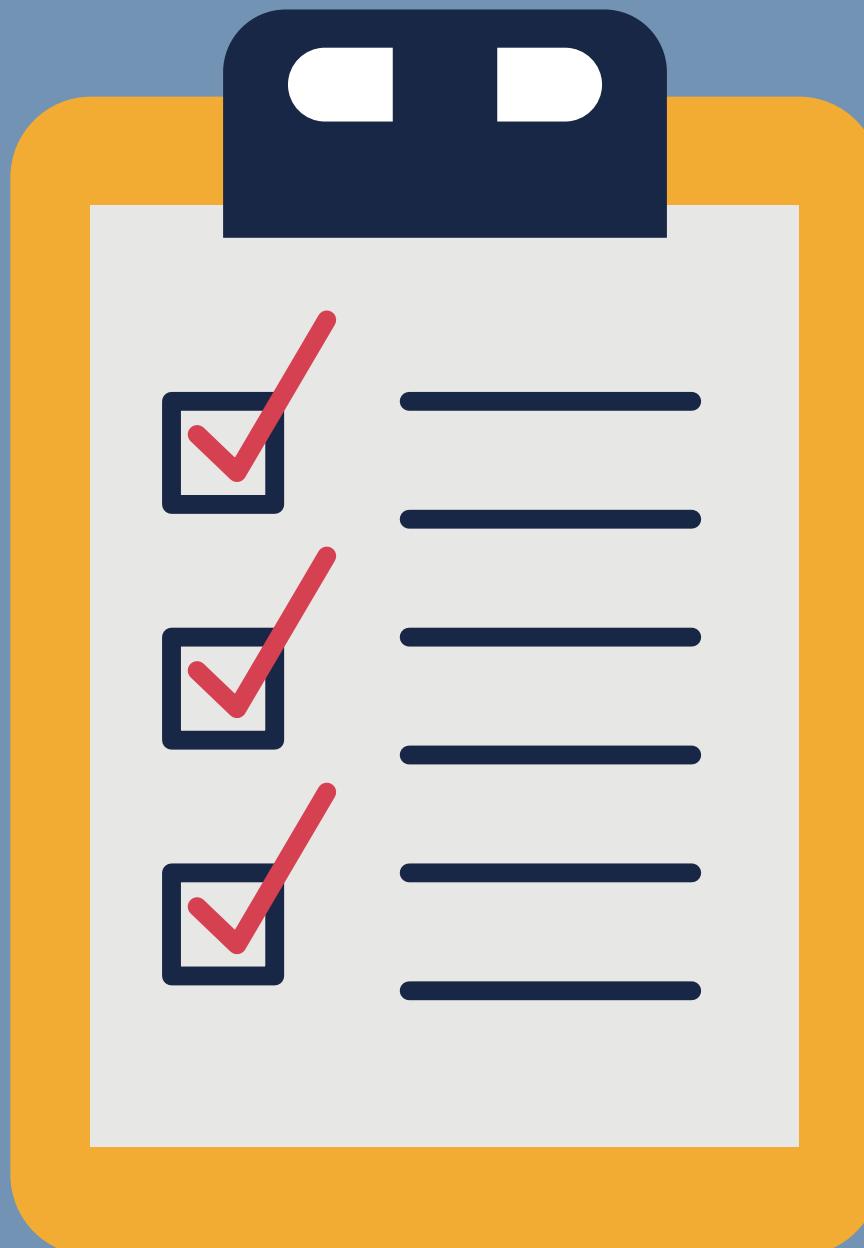
Jhon Anderson Vargas Gómez - 2220086  
Juan David Pallares Pallares - 2220079

Inteligencia Artificial II



# Contenido

1. Motivación
2. Alcance
3. Datos
4. Estado Del Arte
5. Implementación
6. Reporte de Métricas
7. Conclusiones Finales





# Motivación

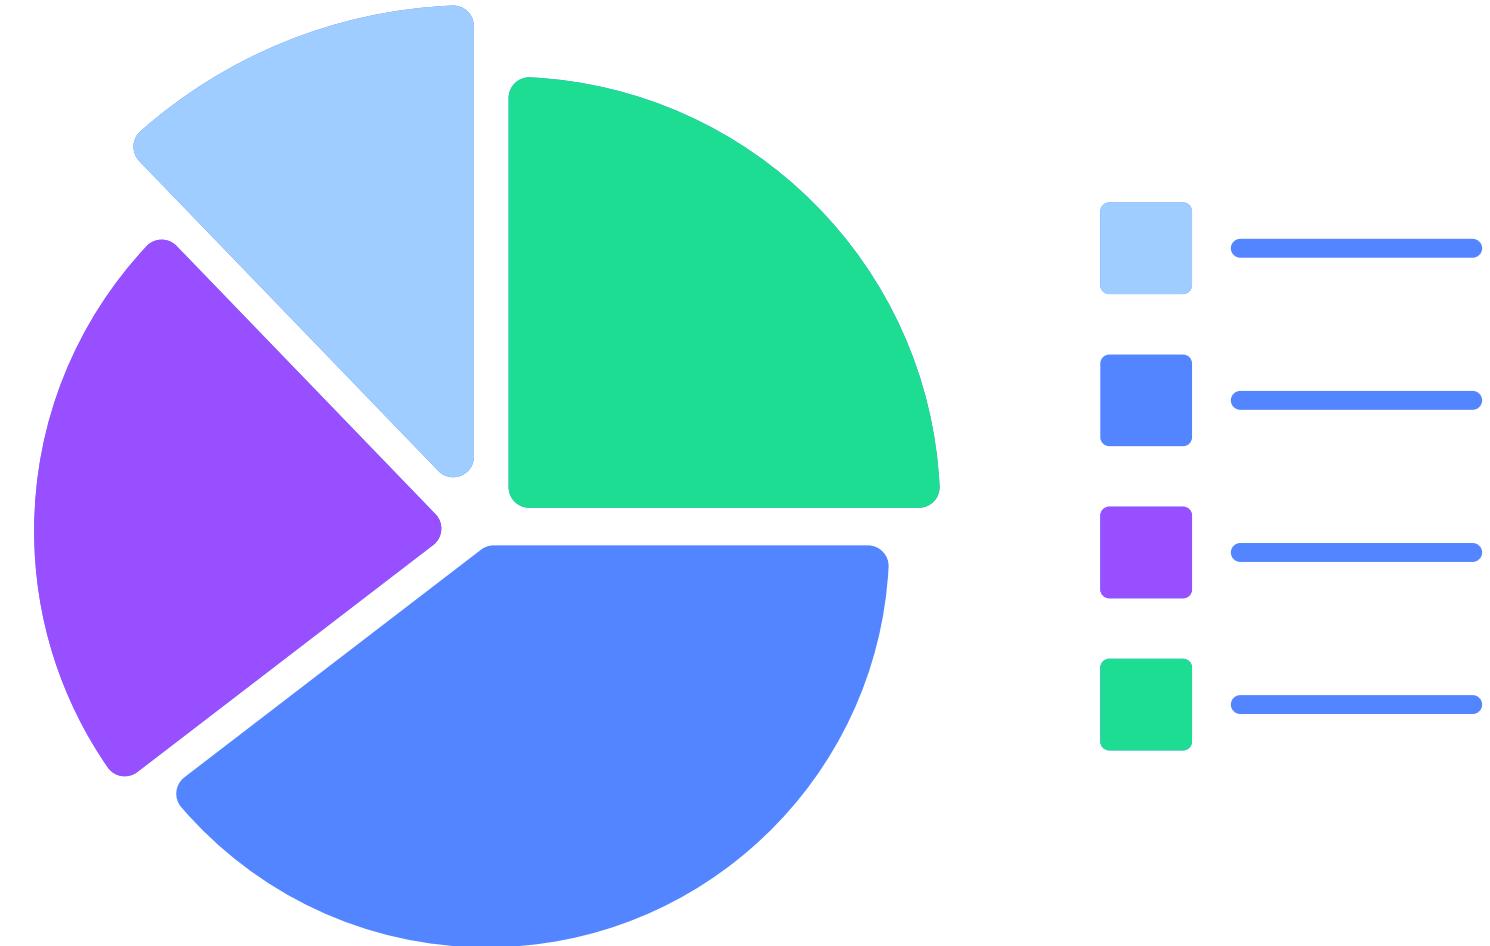
# Motivación



A nivel mundial es el cáncer más común con una incidencia de 23.6 cada 100.000 (ASR), 2.4 millones de casos reportados y 1.8 millones de muertes en 2022, siendo la principal causal de muertes por cáncer.<sup>1</sup>

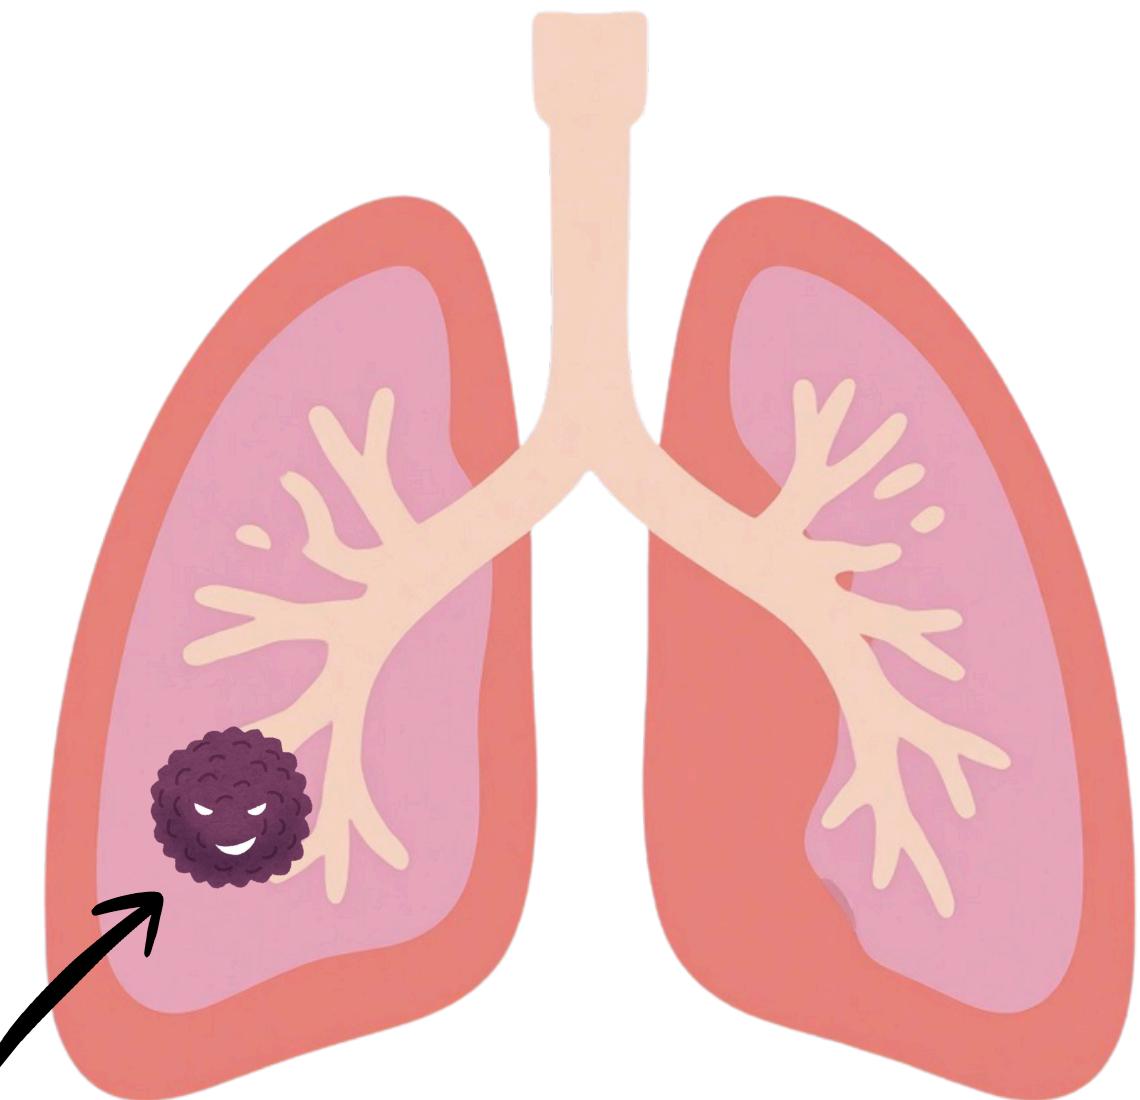


5.<sup>o</sup> cáncer más común con 7.192 casos reportados en 2022, un ASR de 10.1 y 2.<sup>o</sup> causa de muerte por cáncer (6.124 muertes en 2022).<sup>1</sup>



El cáncer de pulmón es un tipo de cáncer que se origina en los pulmones, donde **células anormales crecen descontroladamente** y forman tumores que pueden ser malignos o benignos.

Identificarlo en etapas tempranas es un paso crucial para apoyar el diagnóstico médico. Por eso, se busca desarrollar un modelo de IA que permita la clasificación de nódulos pulmonares.

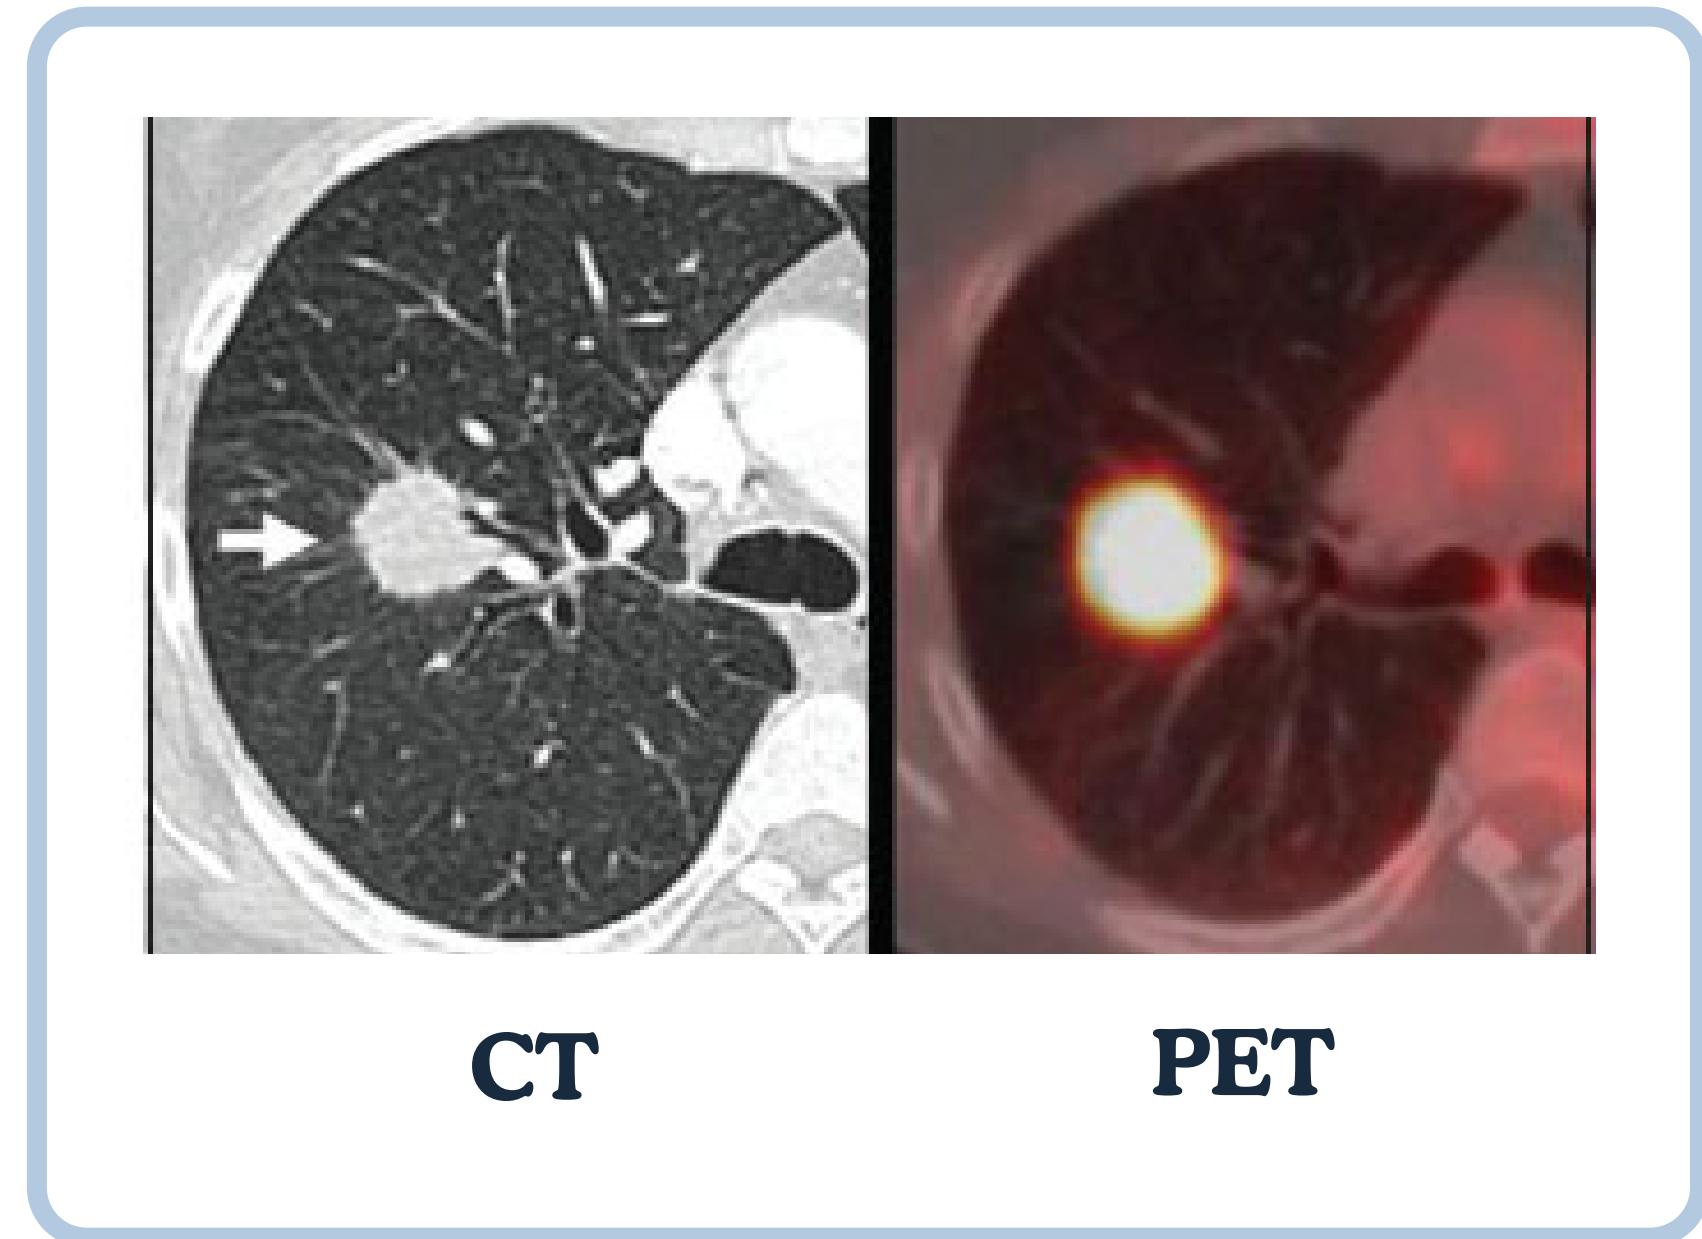


# Diagnóstico

Los tumores formados se denominan **nódulos pulmonares** y son pequeños crecimientos o masas anormales en los pulmones, generalmente de menos de 3 cm de diámetro.

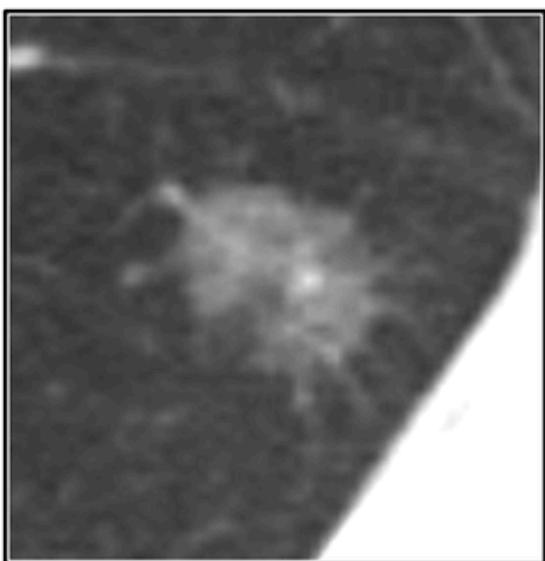
Son comunes y se detectan a menudo mediante **tomografías computarizadas (CT)** de tórax o **resonancias magnéticas (PET)**.

Algunos de estos nódulos pueden ser malignos, lo que representa el **cáncer de pulmón** en sus primeras etapas.

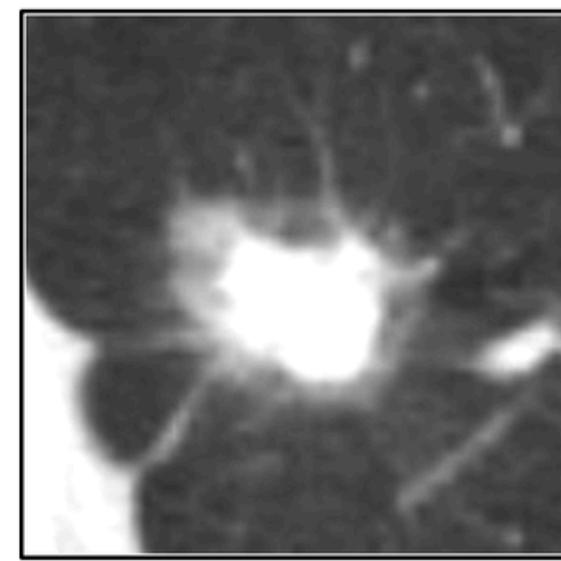


# Clasificación según la apariencia en la CT

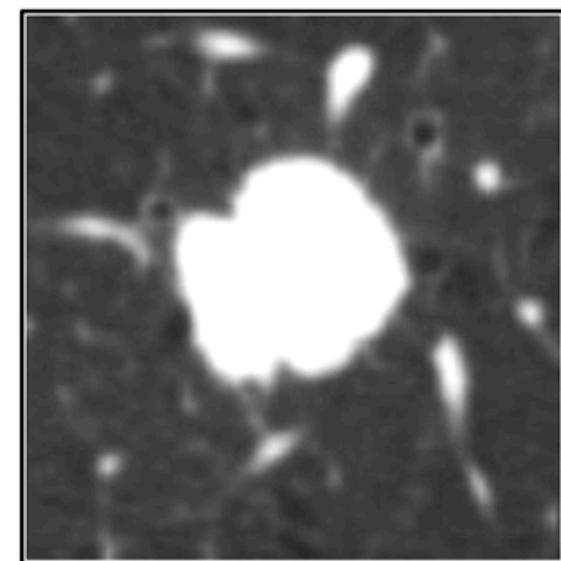
Según la morfología del nódulo se puede clasificar en sólido, parcialmente sólido o de vidrio esmerilado puro.



Ground-Glass Opacity



Part-solid nodule



Solid nodule

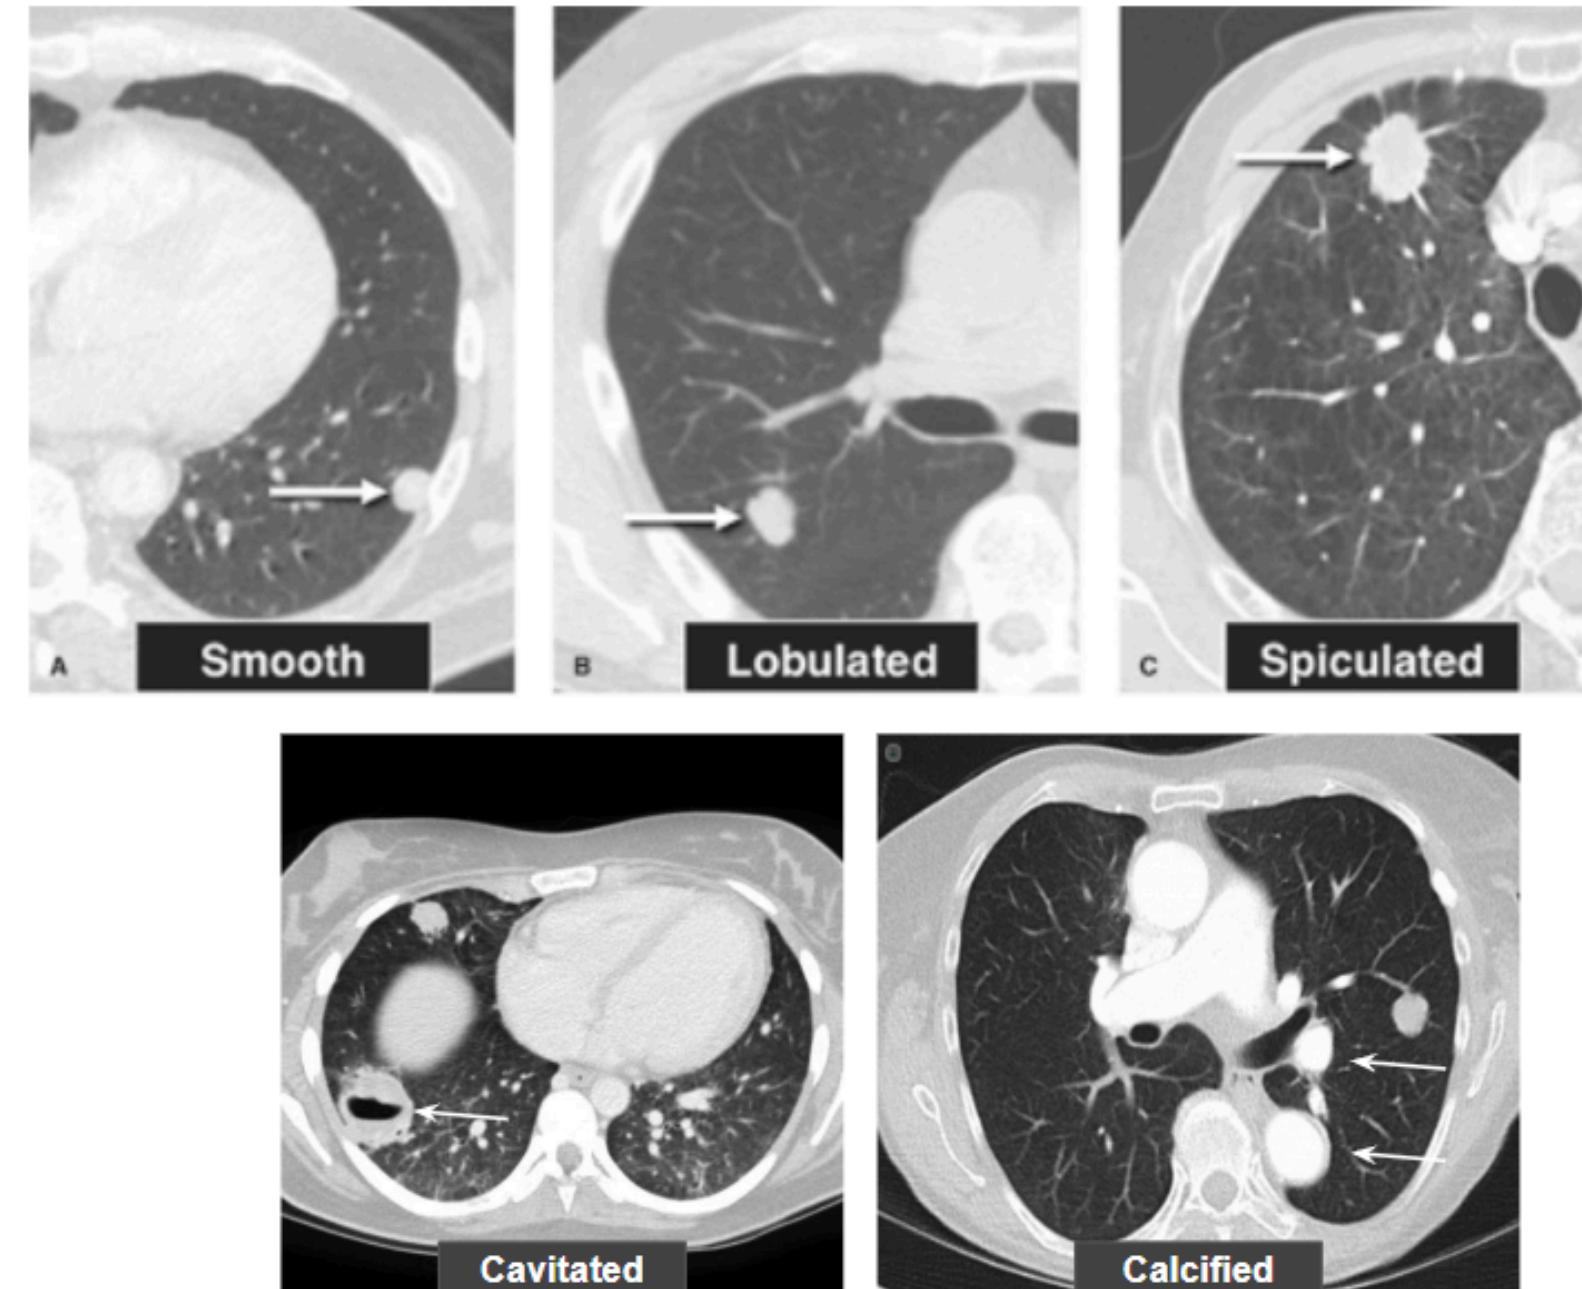
Subsolid nodule

**Vidrio esmerilado puro:** Opacidad difusa, que permite ver los vasos sanguíneos.

**Parcialmente sólido:** Combina áreas sólidas y núcleos en vidrio esmerilado.

**Sólido:** Nódulo denso y opaco.

# Características de los nódulos pulmonares



**Lisos:** Bordes uniformes, más comunes en nódulos benignos pero no descartan la malignidad.

**Lobulados:** Bordes ondulados, similares a moras.  
Alta probabilidad de cáncer

**Espiculados:** Bordes con proyecciones puntiagudas.  
Un fuerte indicador de malignidad

**Cavitados:** Cavidad interna con aire. Puede ser benigno o maligno.

**Calcificado:** Depósitos de calcio. Normalmente benigno pero las calcificaciones excéntricas son preocupantes.

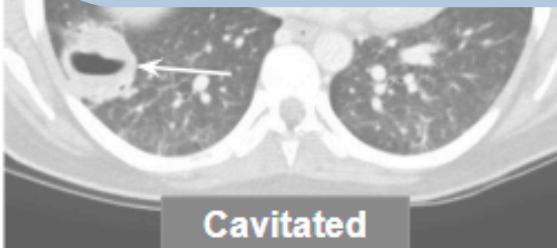
# Características de los nódulos pulmonares



## Problemas en clasificación de nodulos

Subjetividad Radiológica - Variabilidad  
Interobservador - Variabilidad Intraobservador.

Diagnósticos erróneos, tratamientos excesivos (biopsias innecesarias) o diagnósticos insuficientes (cáncer no detectado).

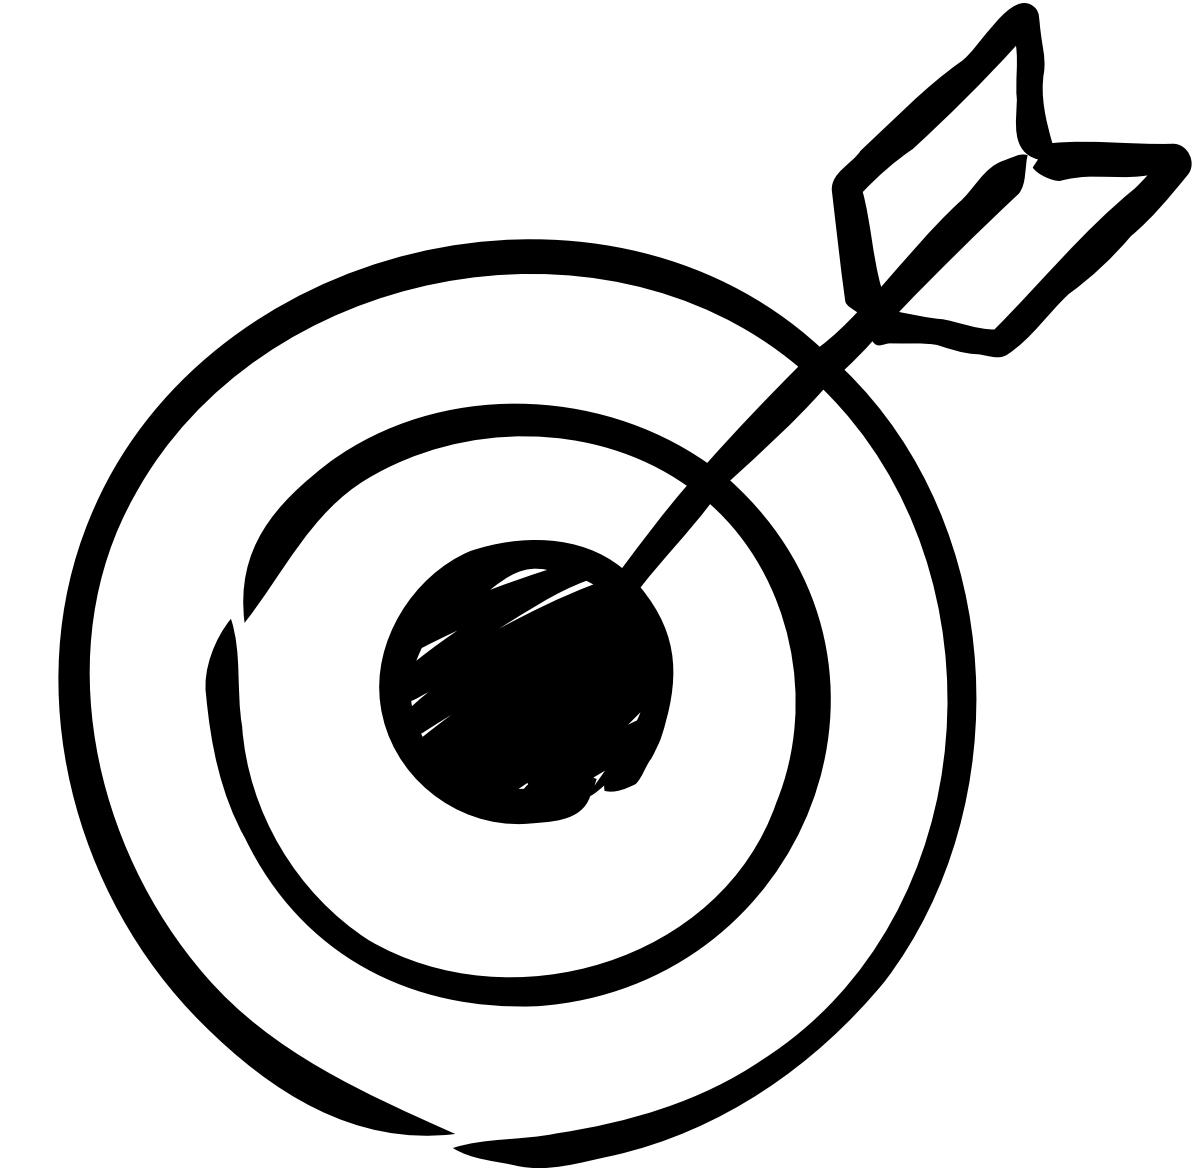
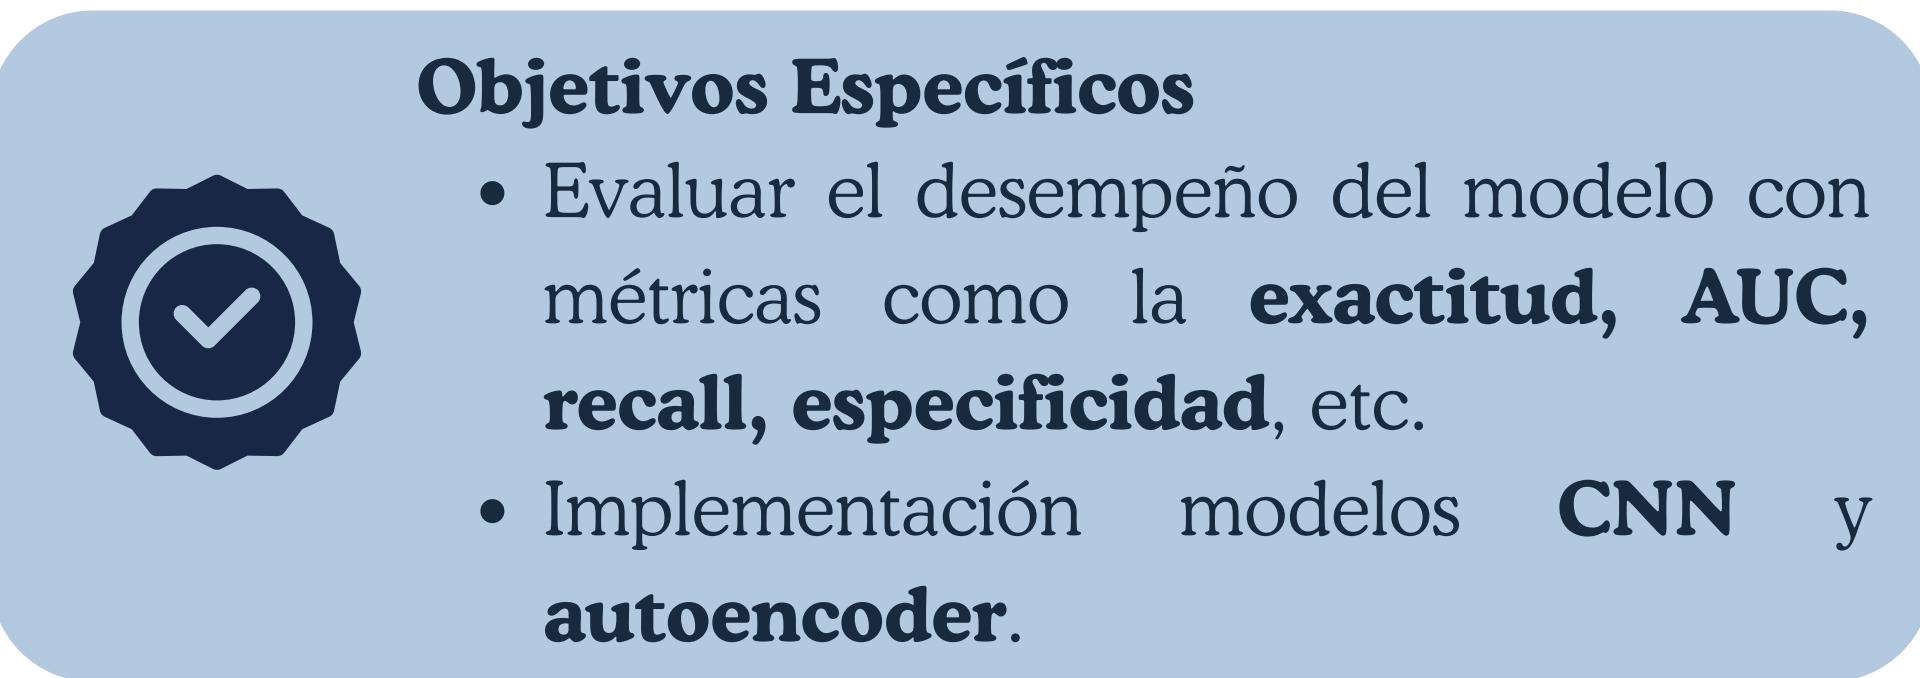
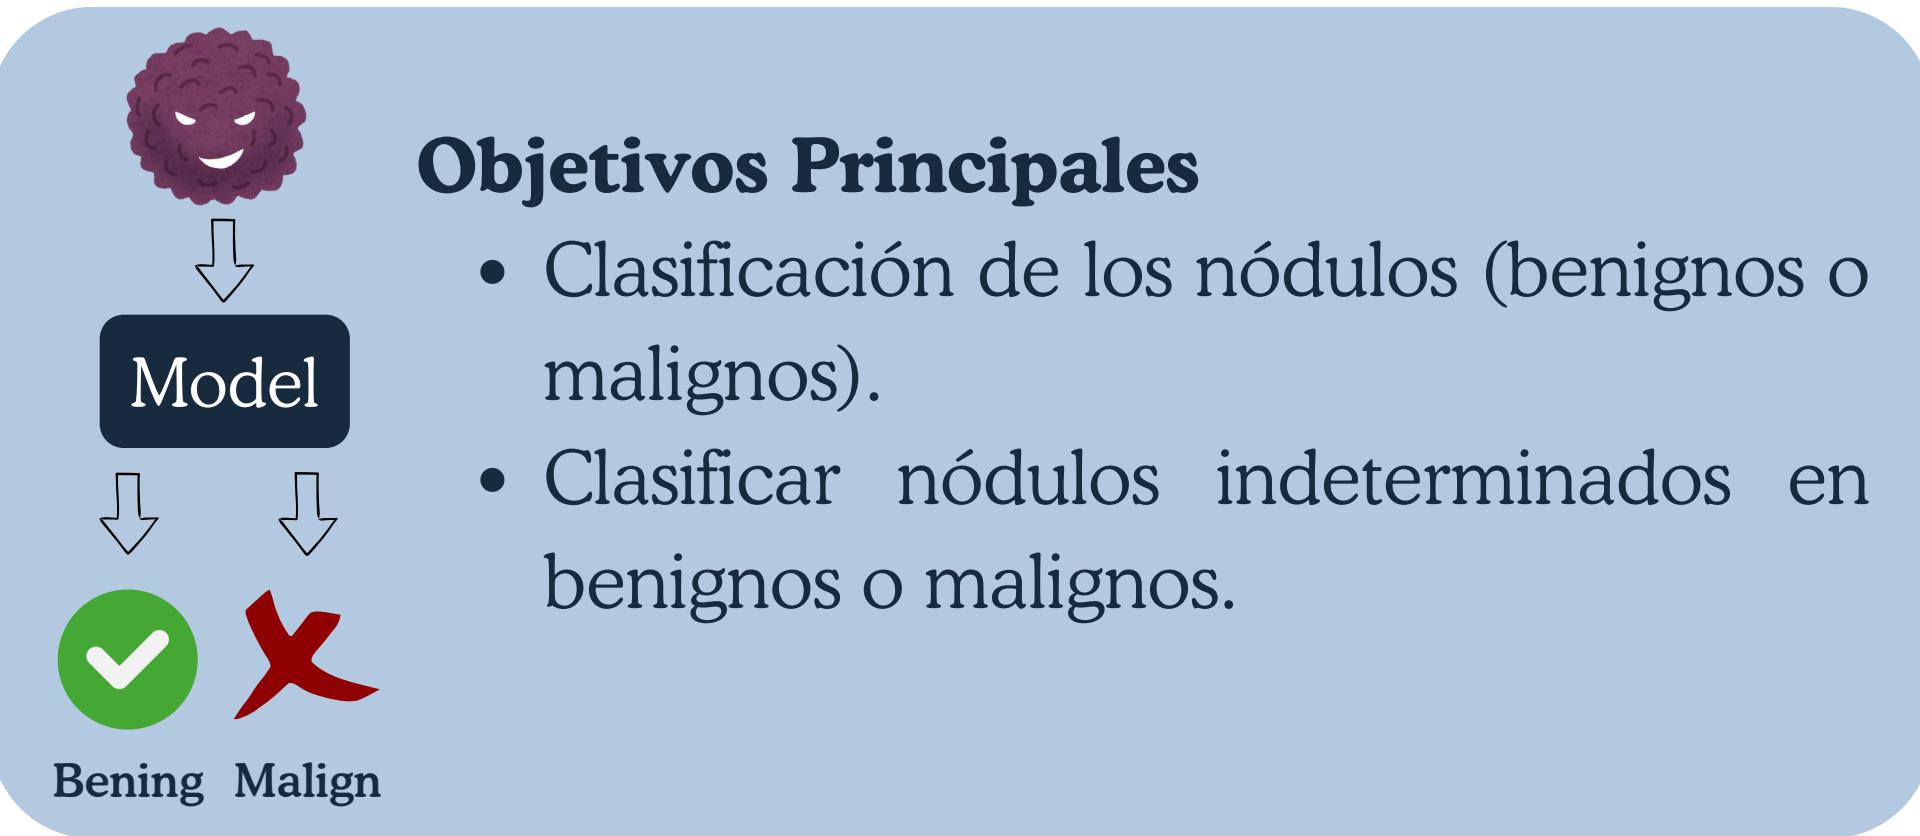


**Calcificado:** Depósitos de calcio. Normalmente benigno pero las calcificaciones excéntricas son preocupantes.



# Alcance

# Alcance del proyecto





# Conjunto de datos

# Conjunto de Datos



Para entrenar y evaluar el modelo se trabajará con el dataset **LIDC-IDRI (Lung Image Dataset Consortium and Image Database Resource Initiative)**

**LIDC-IDRI - The Cancer Imaging Archive (TCIA)**



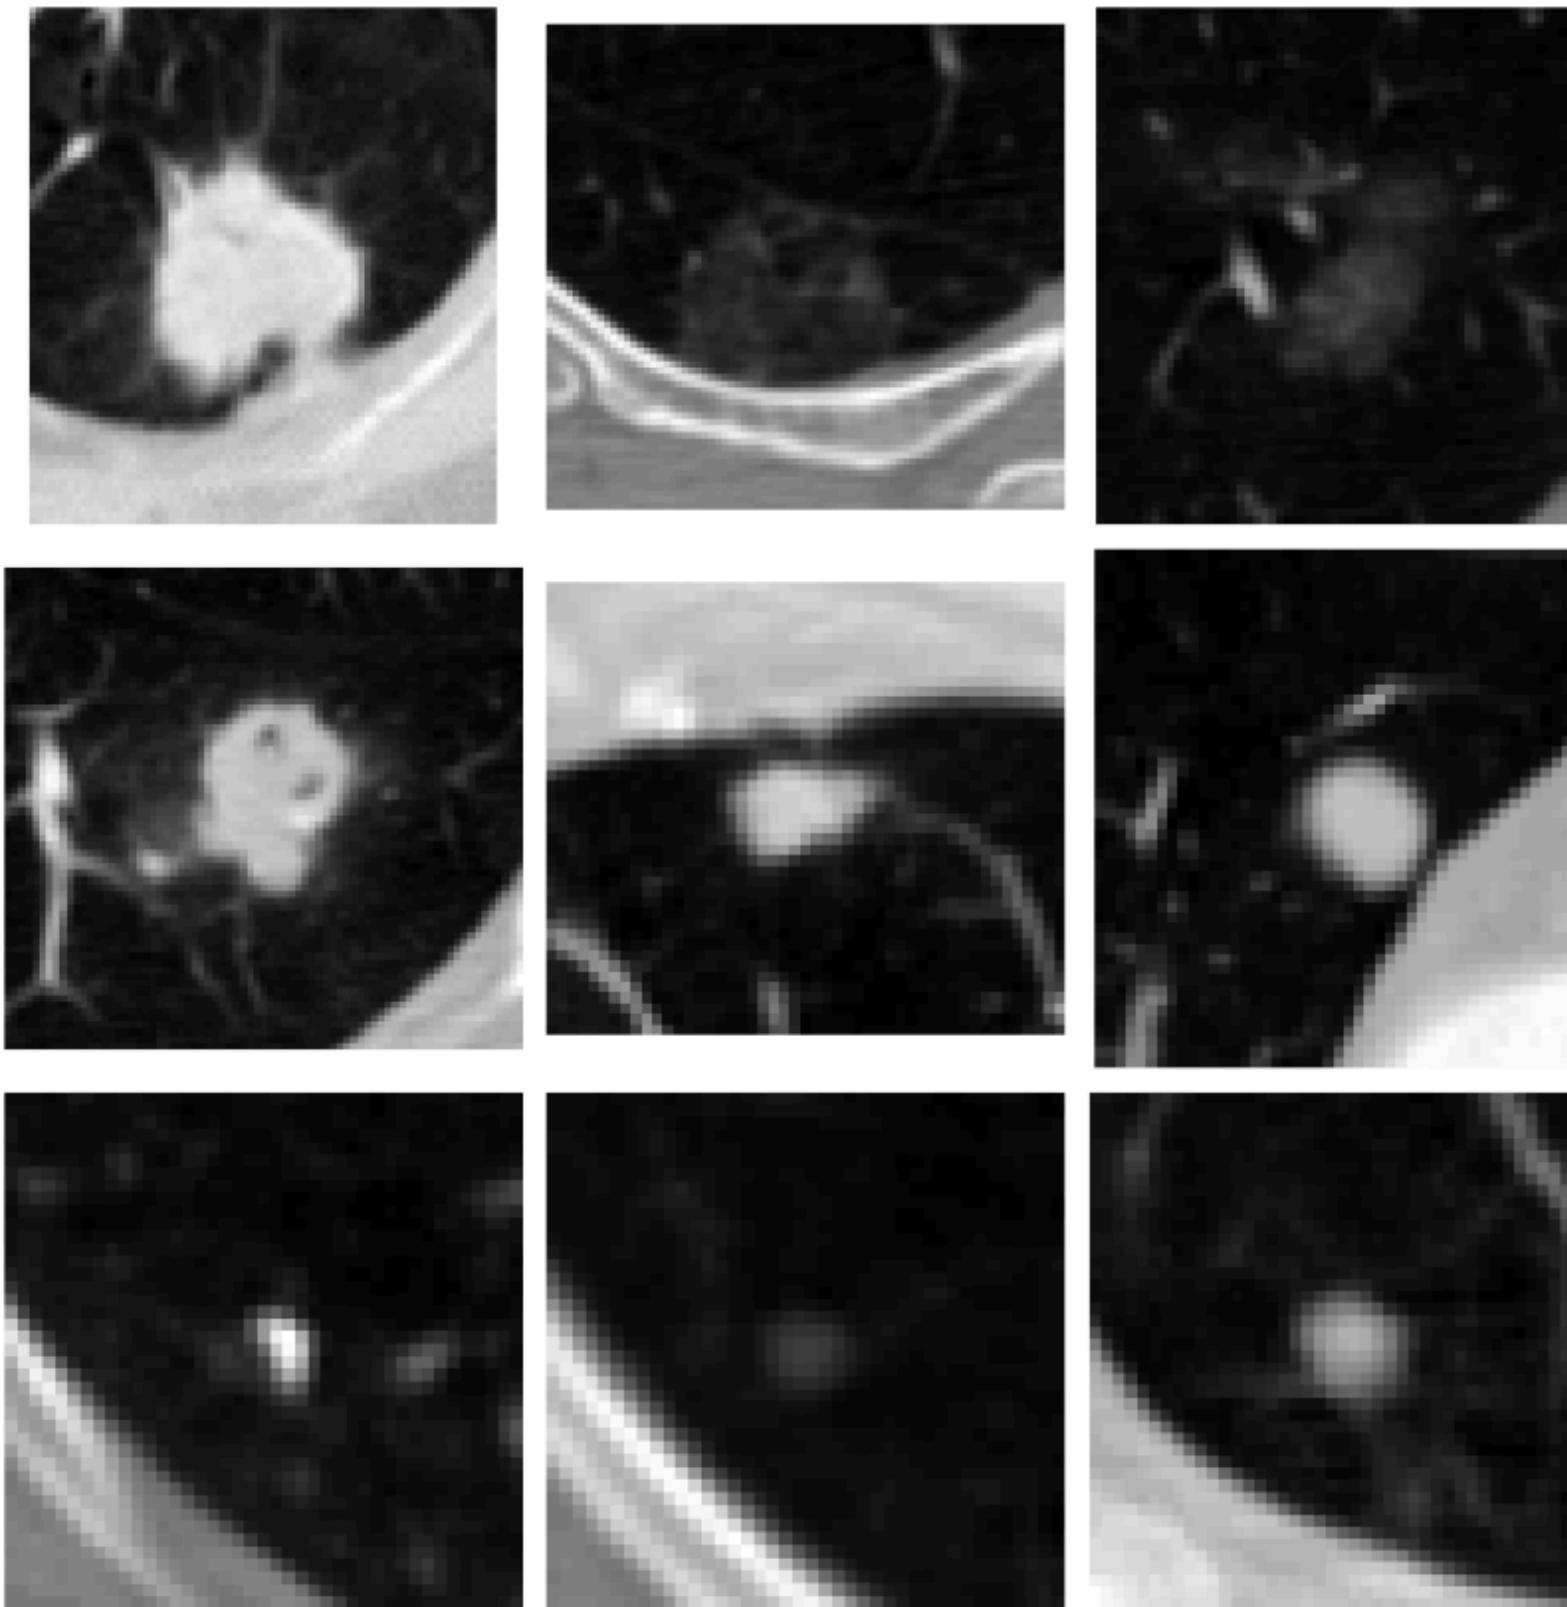
## Contenido

- Pacientes y Escaneos: 1010 pacientes, 1018 casos (8 con 2 escaneos), 1308 estudios, 244,527 imágenes.
- Formato: Imágenes DICOM (TC torácicas helicoidales).
- Tipos de Datos: Imágenes CT, DX, CR, características radiómicas, mediciones y diagnósticos.

## Datos usados

Del dataset, se extrajeron 2513 parches CT de diferentes dimensiones que contienen el nódulo pulmonar con un grado de **malignidad** establecido de **1-5**

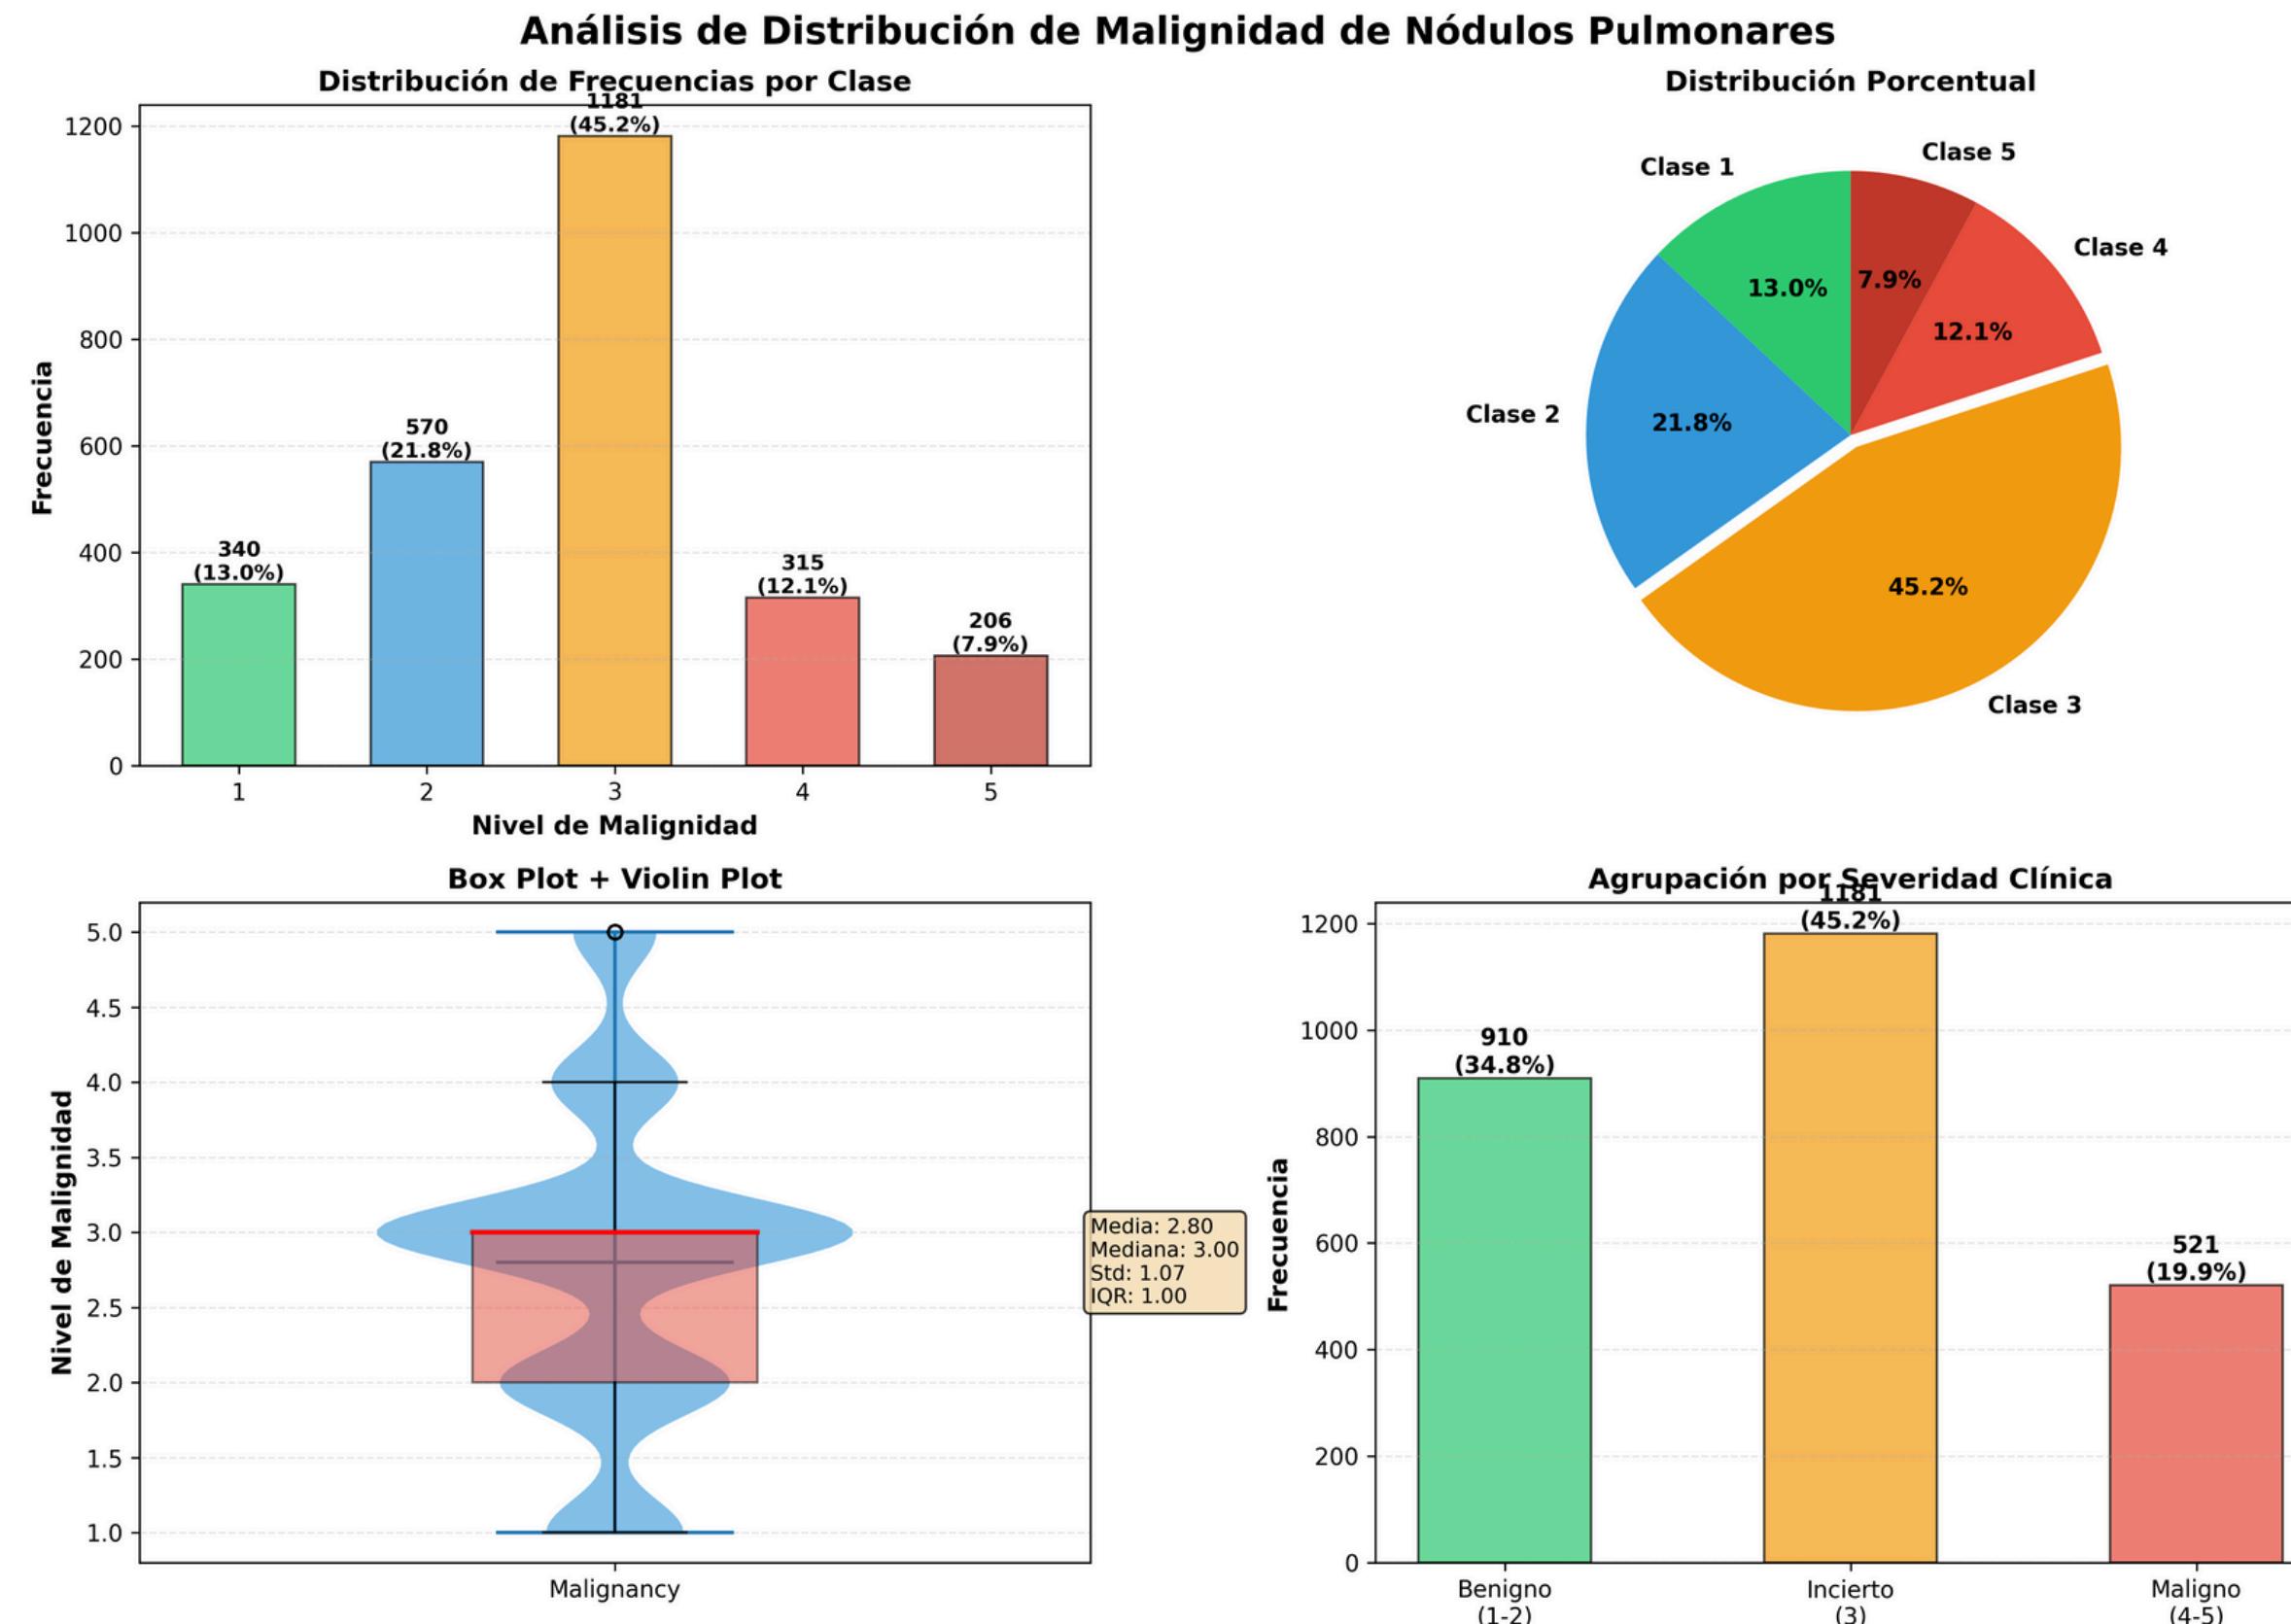
# Exploracion del conjunto de datos



## Grado de malignidad (1 - 5)

1. Muy Improbable
2. Moderadamente Improbable
3. Indeterminado
4. Moderadamente sospechoso
5. Muy sospechoso

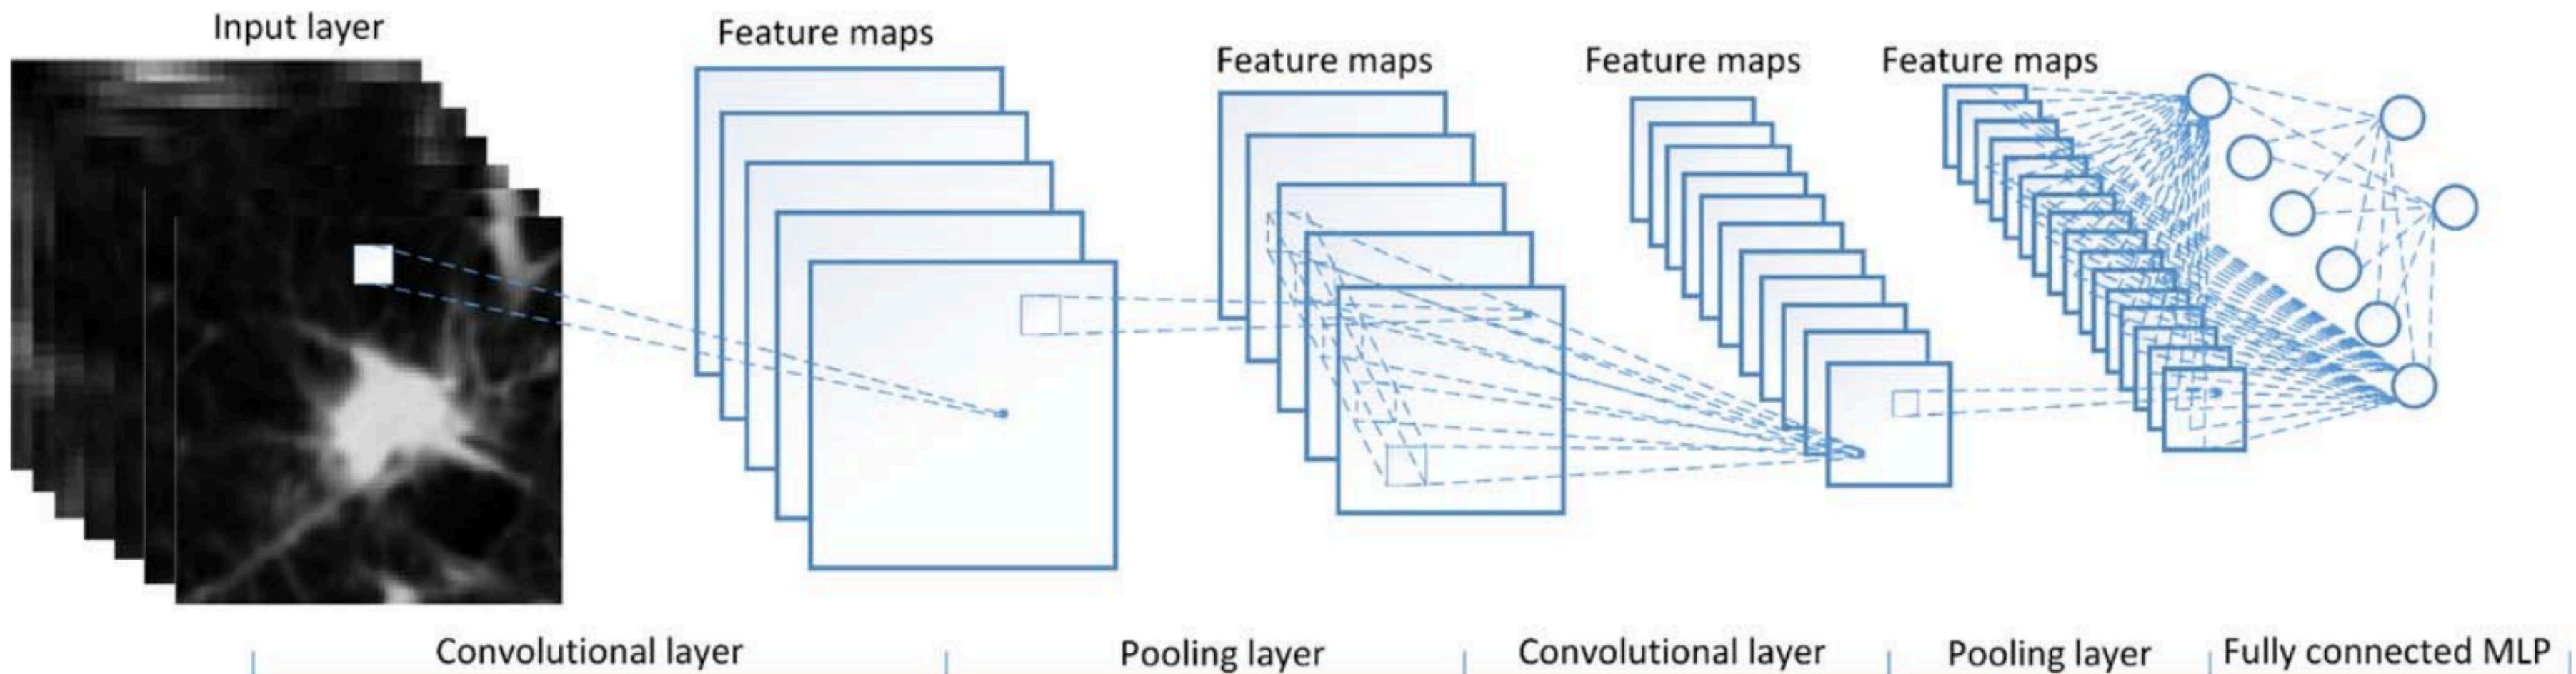
# Exploración del conjunto de datos





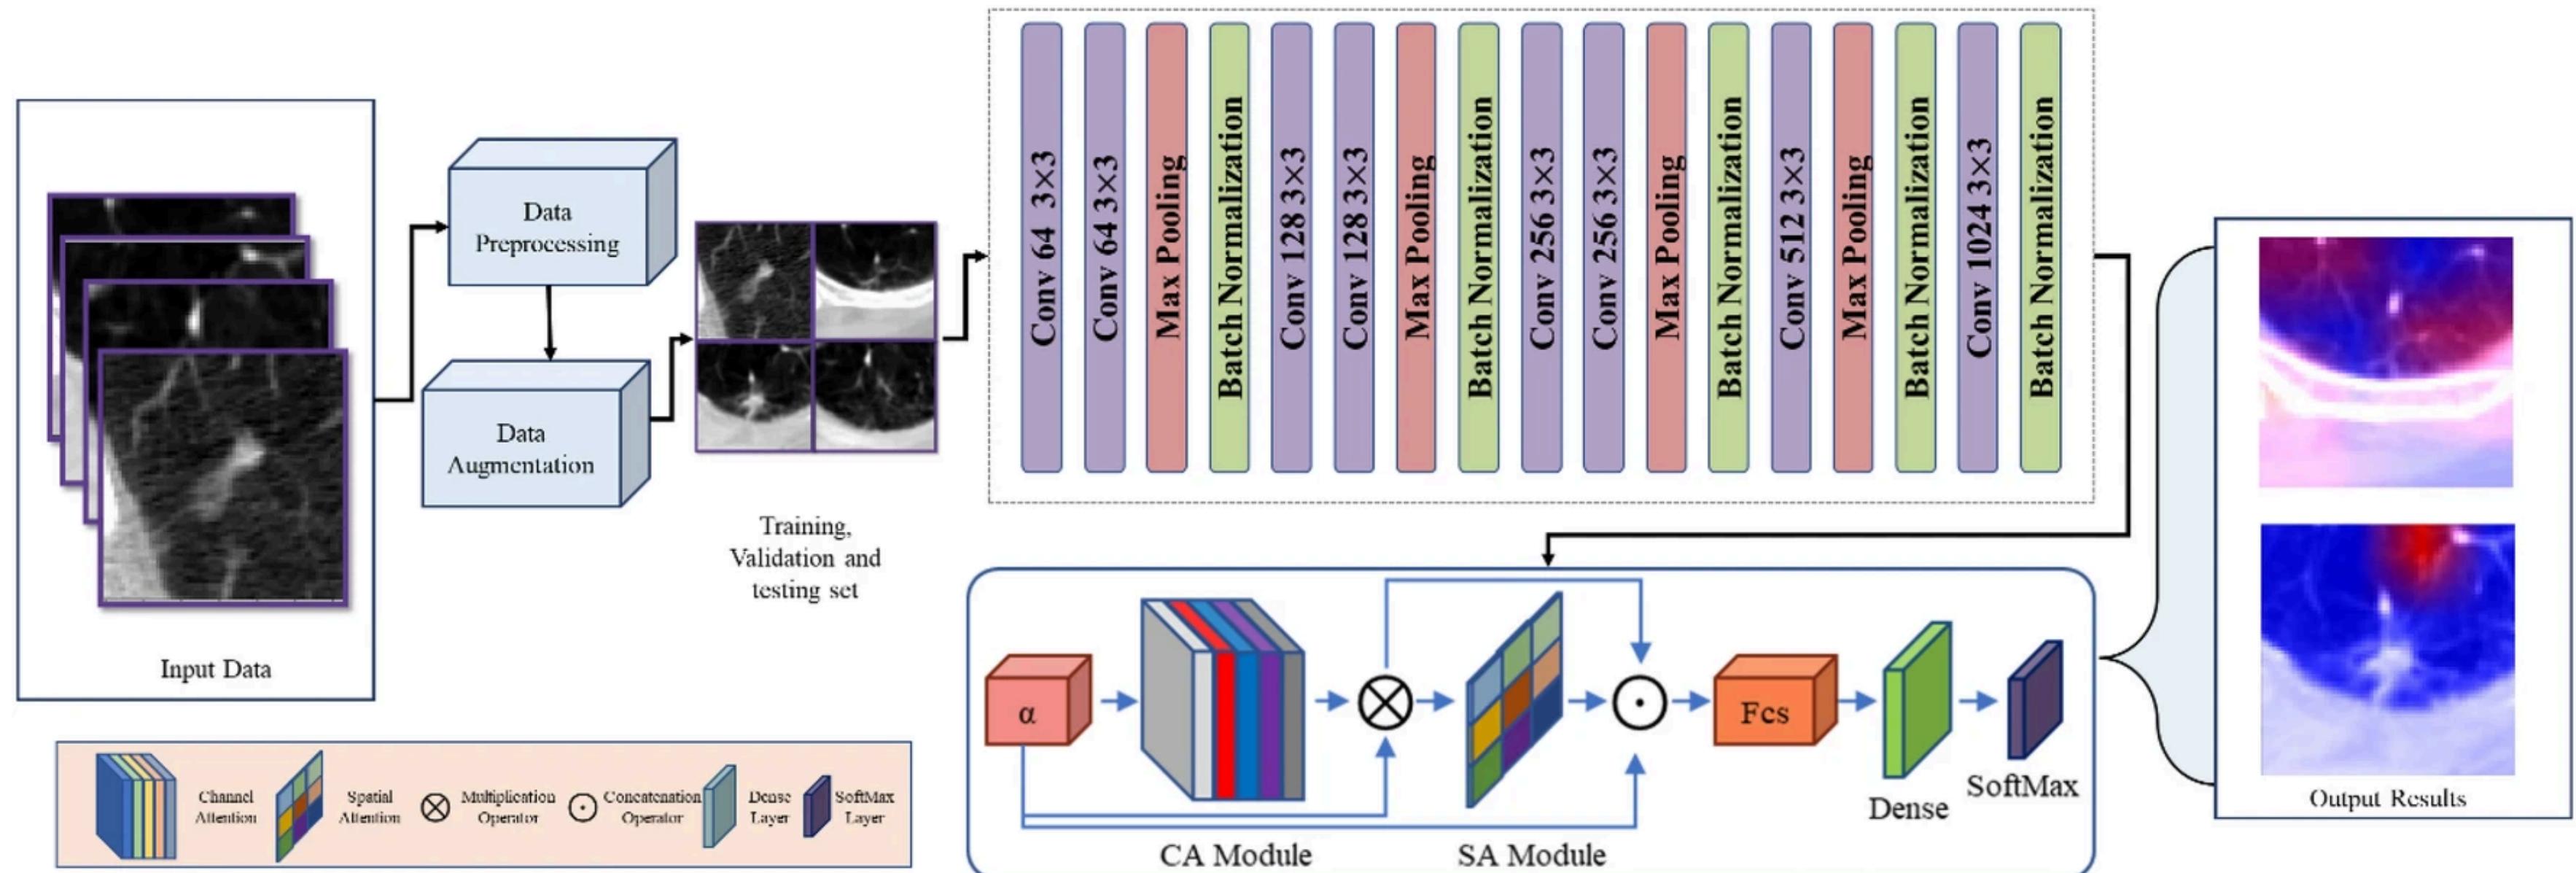
# Estado del arte

# Multiview Convolutional Neural Networks for Lung Nodule Classification.



**Figure 2.** The architecture of a multiview CNN. [Color figure can be viewed at [wileyonlinelibrary.com](http://wileyonlinelibrary.com)]

# Effective lung nodule detection using deep CNN with dual attention mechanisms

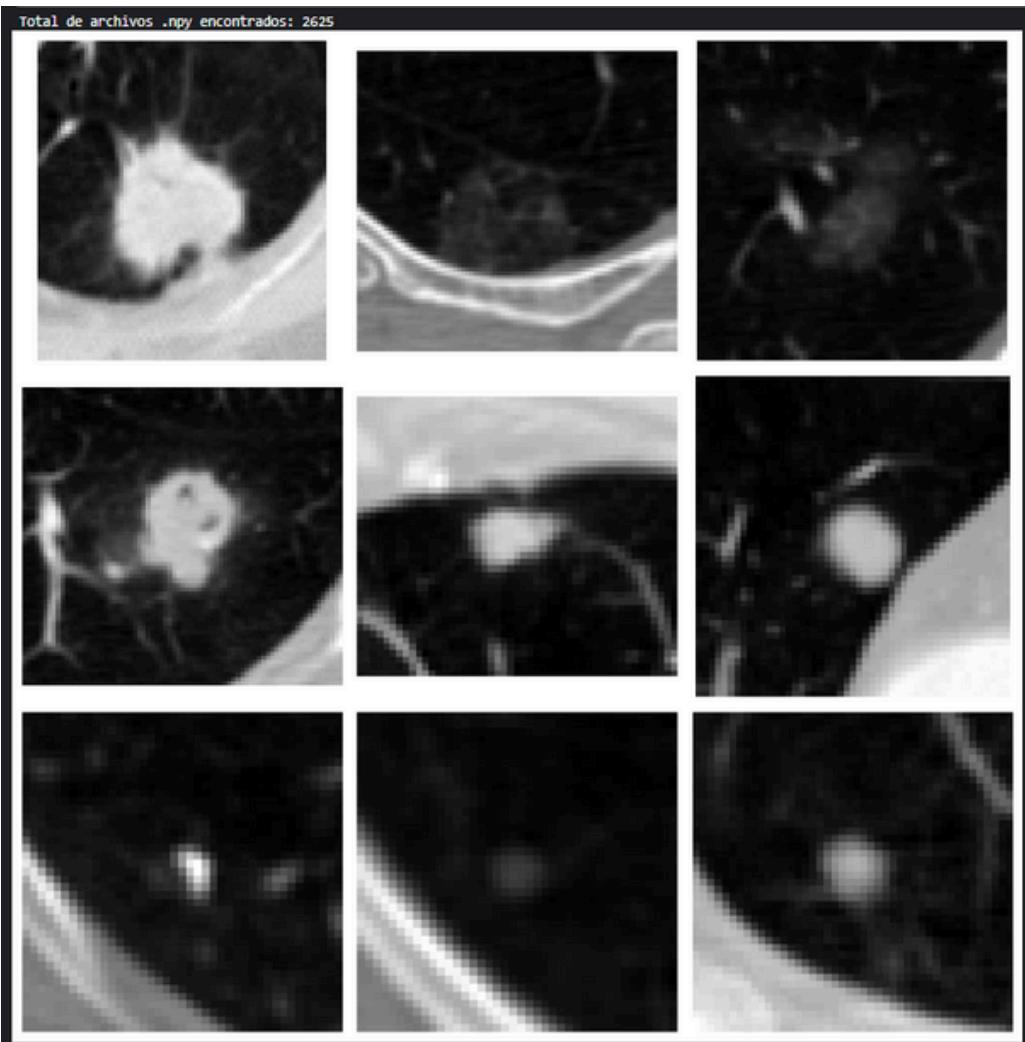




# Implementación

# Preprocesamiento de los datos

## Extracción de los parches



## Normalización (Min Max)

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

## Resize

Conjunto 1 → 32x32

Conjunto 2 → 224x224 (3 canales)

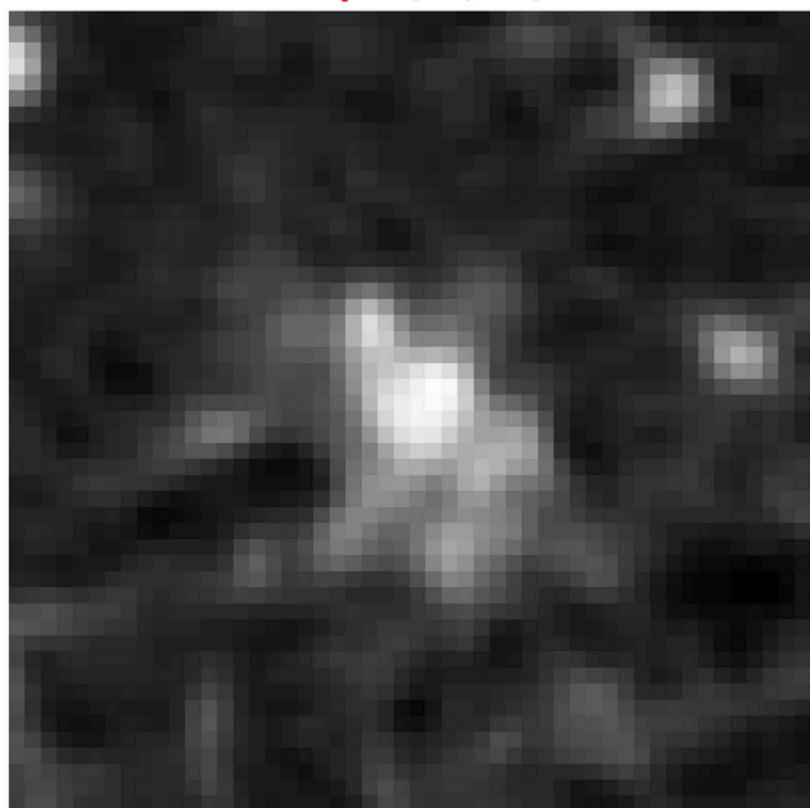
# Preprocesamiento de los datos

Universidad  
Industrial de  
Santander



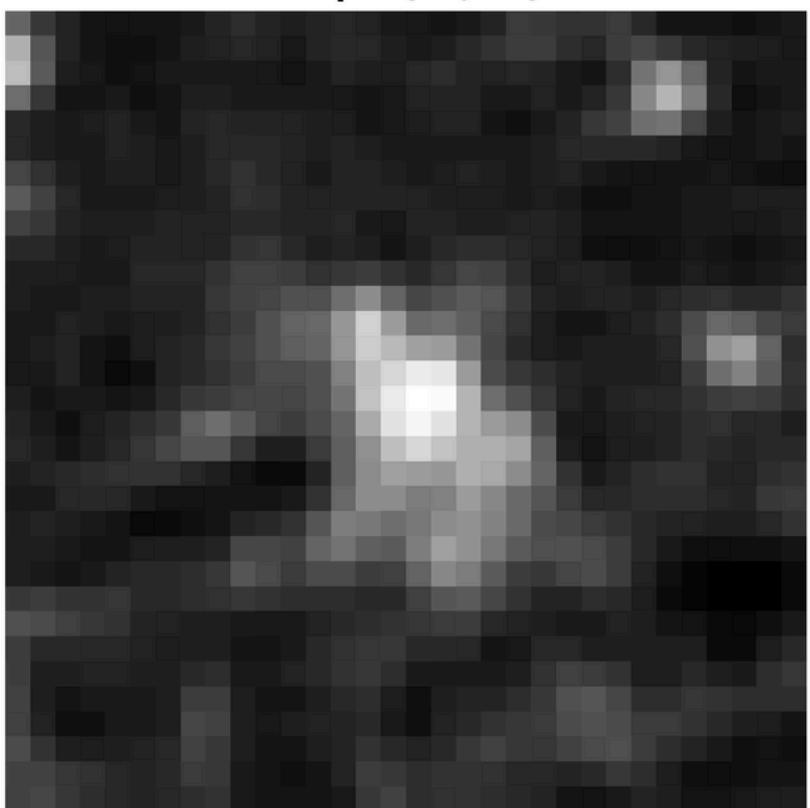
Comparación: Original vs Redimensionamientos - Muestra #0

Original (HU)  
Malignancy: 1  
Shape: (50, 50)



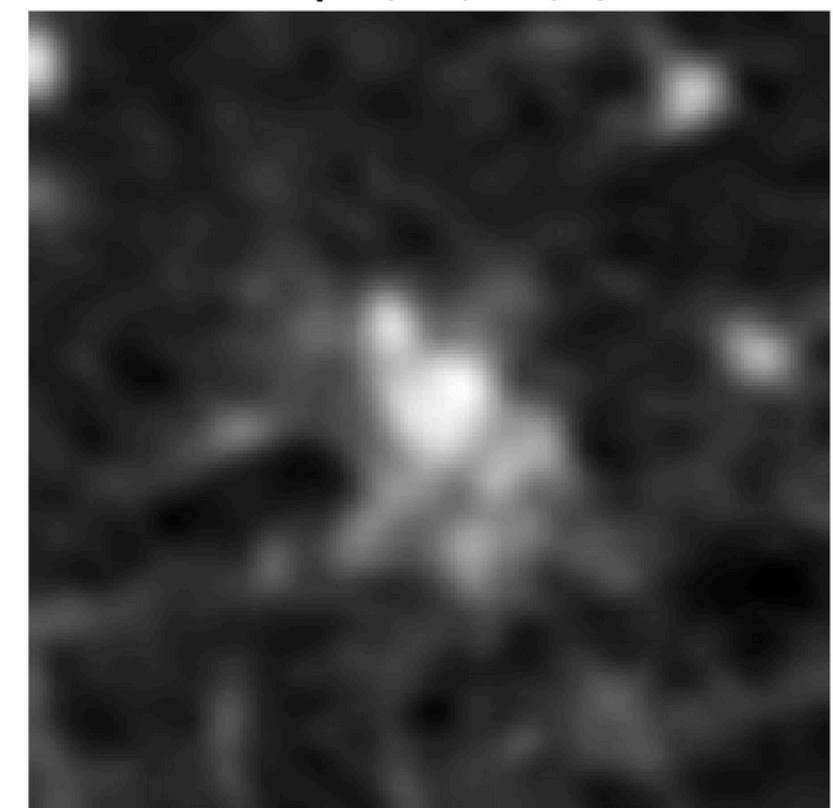
Rango: [-1018.0, 6.0] HU

32x32 (normalizada)  
Malignancy: 1  
Shape: (32, 32)



Rango: [0.234, 0.881]

224x224 (3 canales)  
Malignancy: 1  
Shape: (224, 224, 3)



Rango: [0.219, 0.915]

Parches Originales

Parches 32x32

Parches 224x224

# Preprocesamiento de los datos



## Data Augmentation

Como no tenemos una gran cantidad de imágenes queremos ampliarlas, esto lo podemos realizar aplicando data augmentation al conjunto de datos de entrenamiento. Planteamos usar **weak augmentations** para no ser demasiado estrictos con el modelo

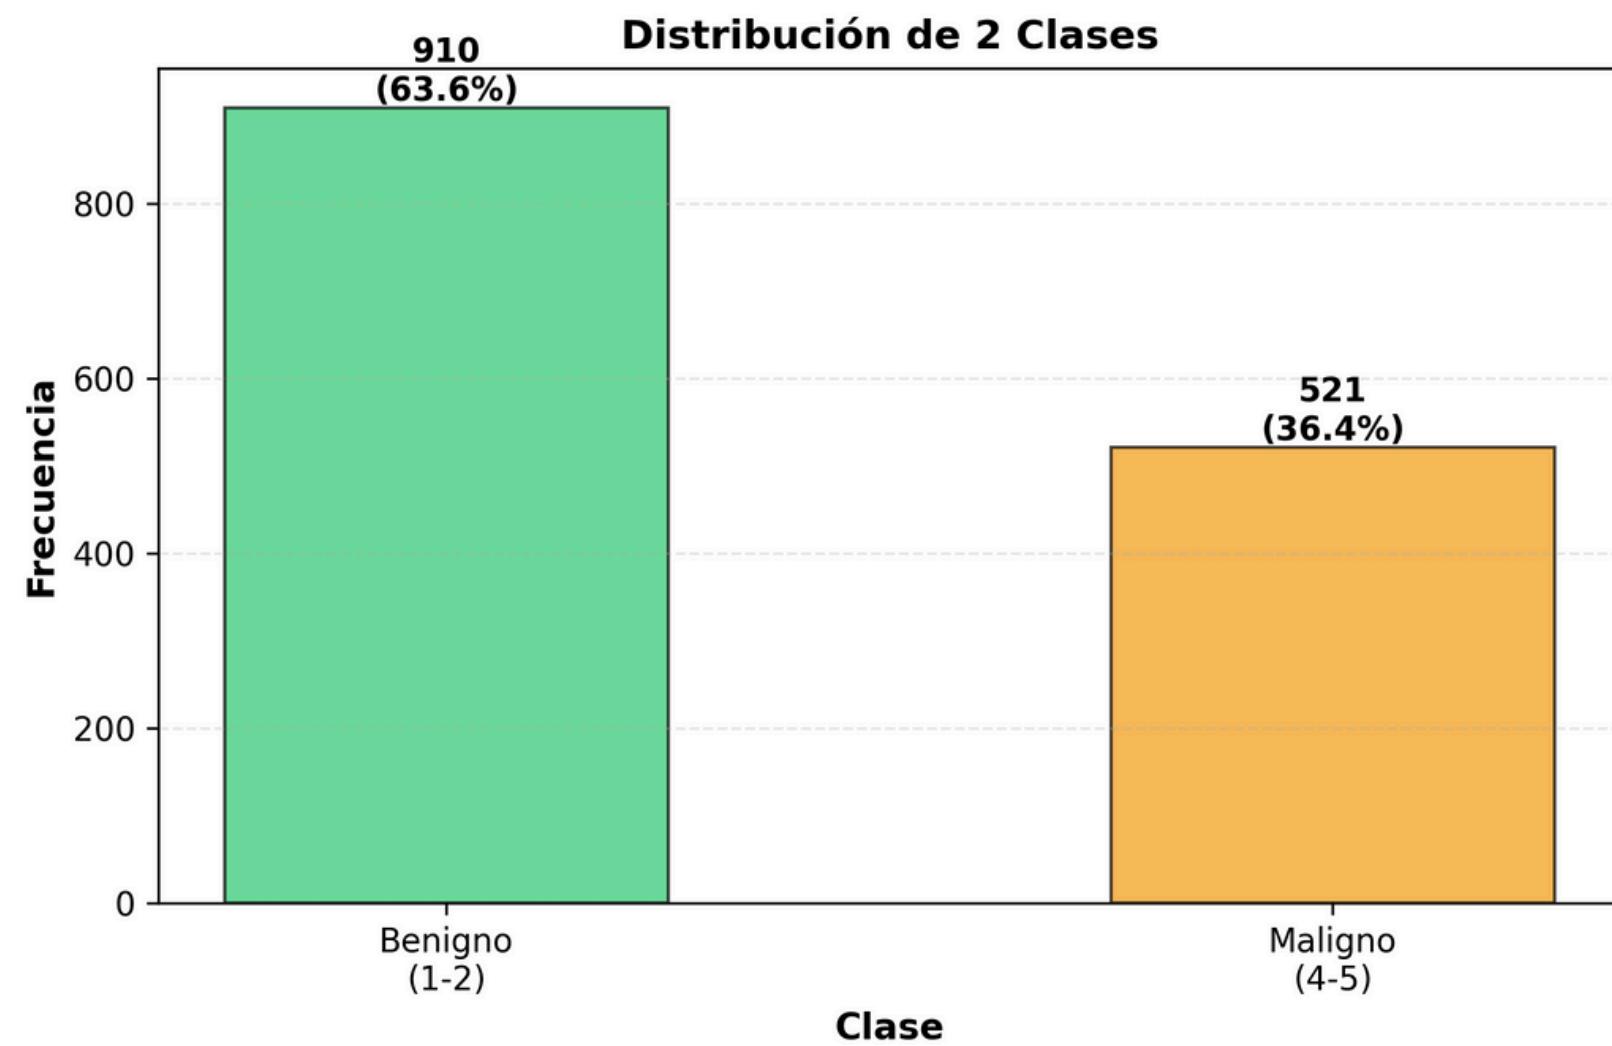
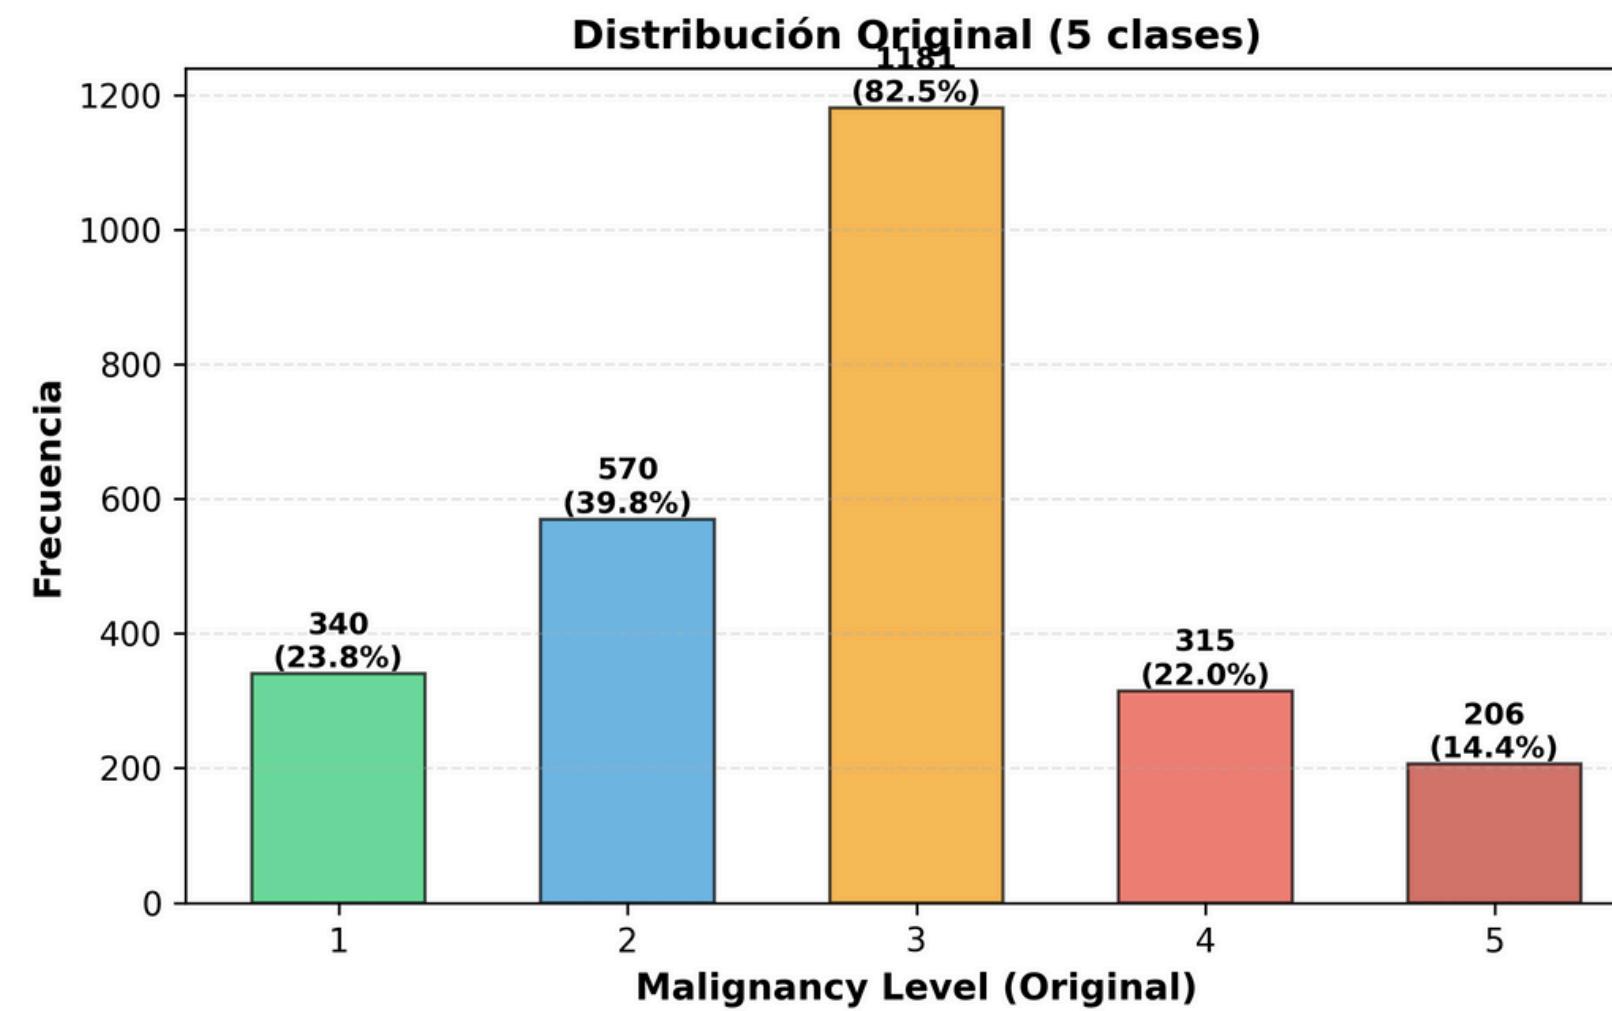
```
from tensorflow.keras.preprocessing.image import ImageDataGenerator
train_datagen = ImageDataGenerator(
    # Rotar
    rotation_range=20, # ±20 grados (nódulos no tienen orientación fija)
    # Traslación
    width_shift_range=0.15, # 15% horizontal
    height_shift_range=0.15, # 15% vertical
    # Zoom
    zoom_range=0.15, # ±15%
    # Flips Horizontales
    horizontal_flip=True,
    # Rellenado de bordes
    fill_mode='constant', # Usar 0 (negro) para CT
    cval=0.0
)
val_test_datagen = ImageDataGenerator()
```

- Rotación de imágenes (20 grados)
- Zoom (15%)
- Desplazamientos horizontales y verticales (15%)
- Flips horizontales

# Preprocesamiento de los datos

## División de Clases (Benigno y Maligno)

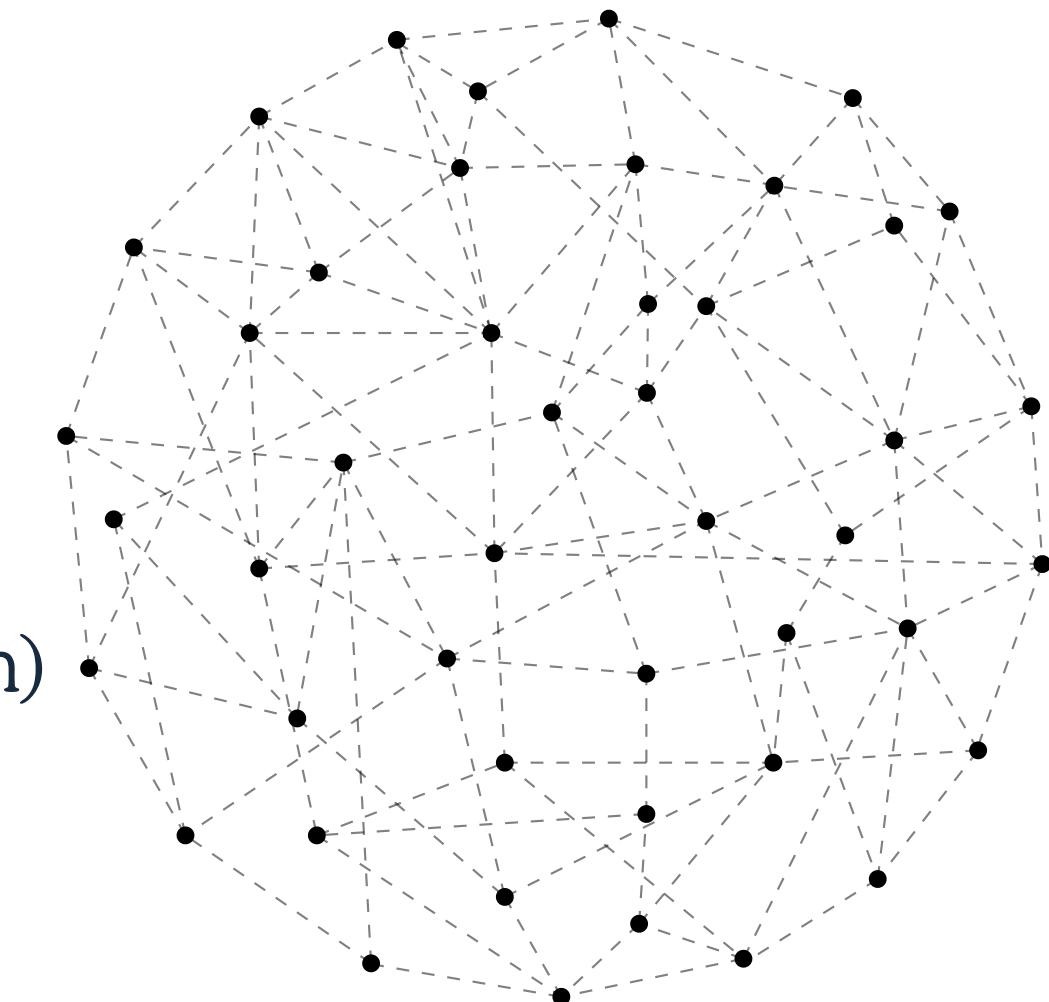
Comparación: Original vs 2 Clases



# Modelos Desarrollados

Para el desarrollo del proyecto se implementaron 4 modelos distintos para probar diferentes tipos de arquitecturas para el procesamiento de las imágenes:

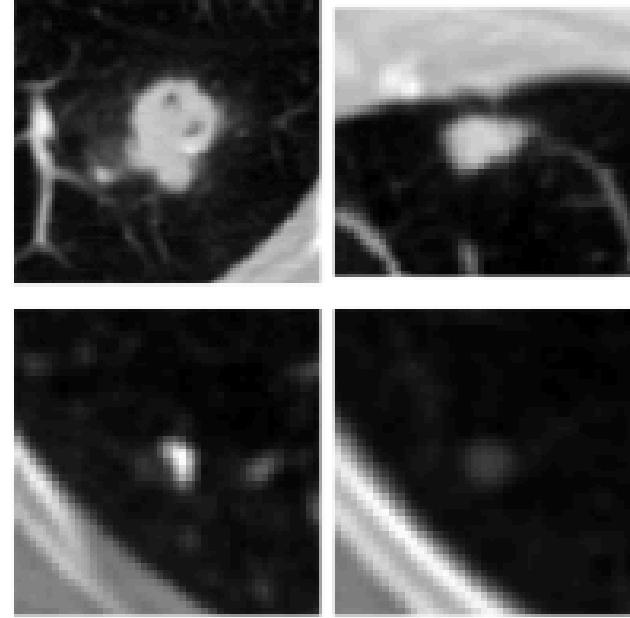
- Modelo DNN
- Modelo CNN (Modelo propio + Data Augmentation)
- Modelo CNN (Transfer Learning + FineTunning + DataAugmentation)
- Autoencoder Anómalo.



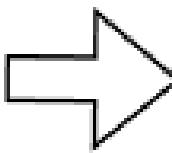
La clasificación se realizará entre benigno y maligno. Luego hablaremos de que se realizó con los nódulos **indeterminados...**

# Modelo DNN

# Pipeline



Input  
(32, 32)



2048 Neuronas  
BatchNormalization  
Activation PReLU  
DropOut(0.3)

1024 Neuronas  
BatchNormalization  
Activation PReLU  
DropOut(0.35)

512 Neuronas  
BatchNormalization  
Activation PReLU  
DropOut(0.4)

256 Neuronas  
BatchNormalization  
Activation PReLU  
DropOut(0.45)

128 Neuronas  
BatchNormalization  
Activation PReLU  
DropOut(0.5)

64 Neuronas  
BatchNormalization  
Activation PReLU  
DropOut(0.5)



Universidad  
Industrial de  
Santander

OUTPUT  
SoftMax

Benigno  
o  
Maligno

## Métricas Validación:

Accuracy: 0.81

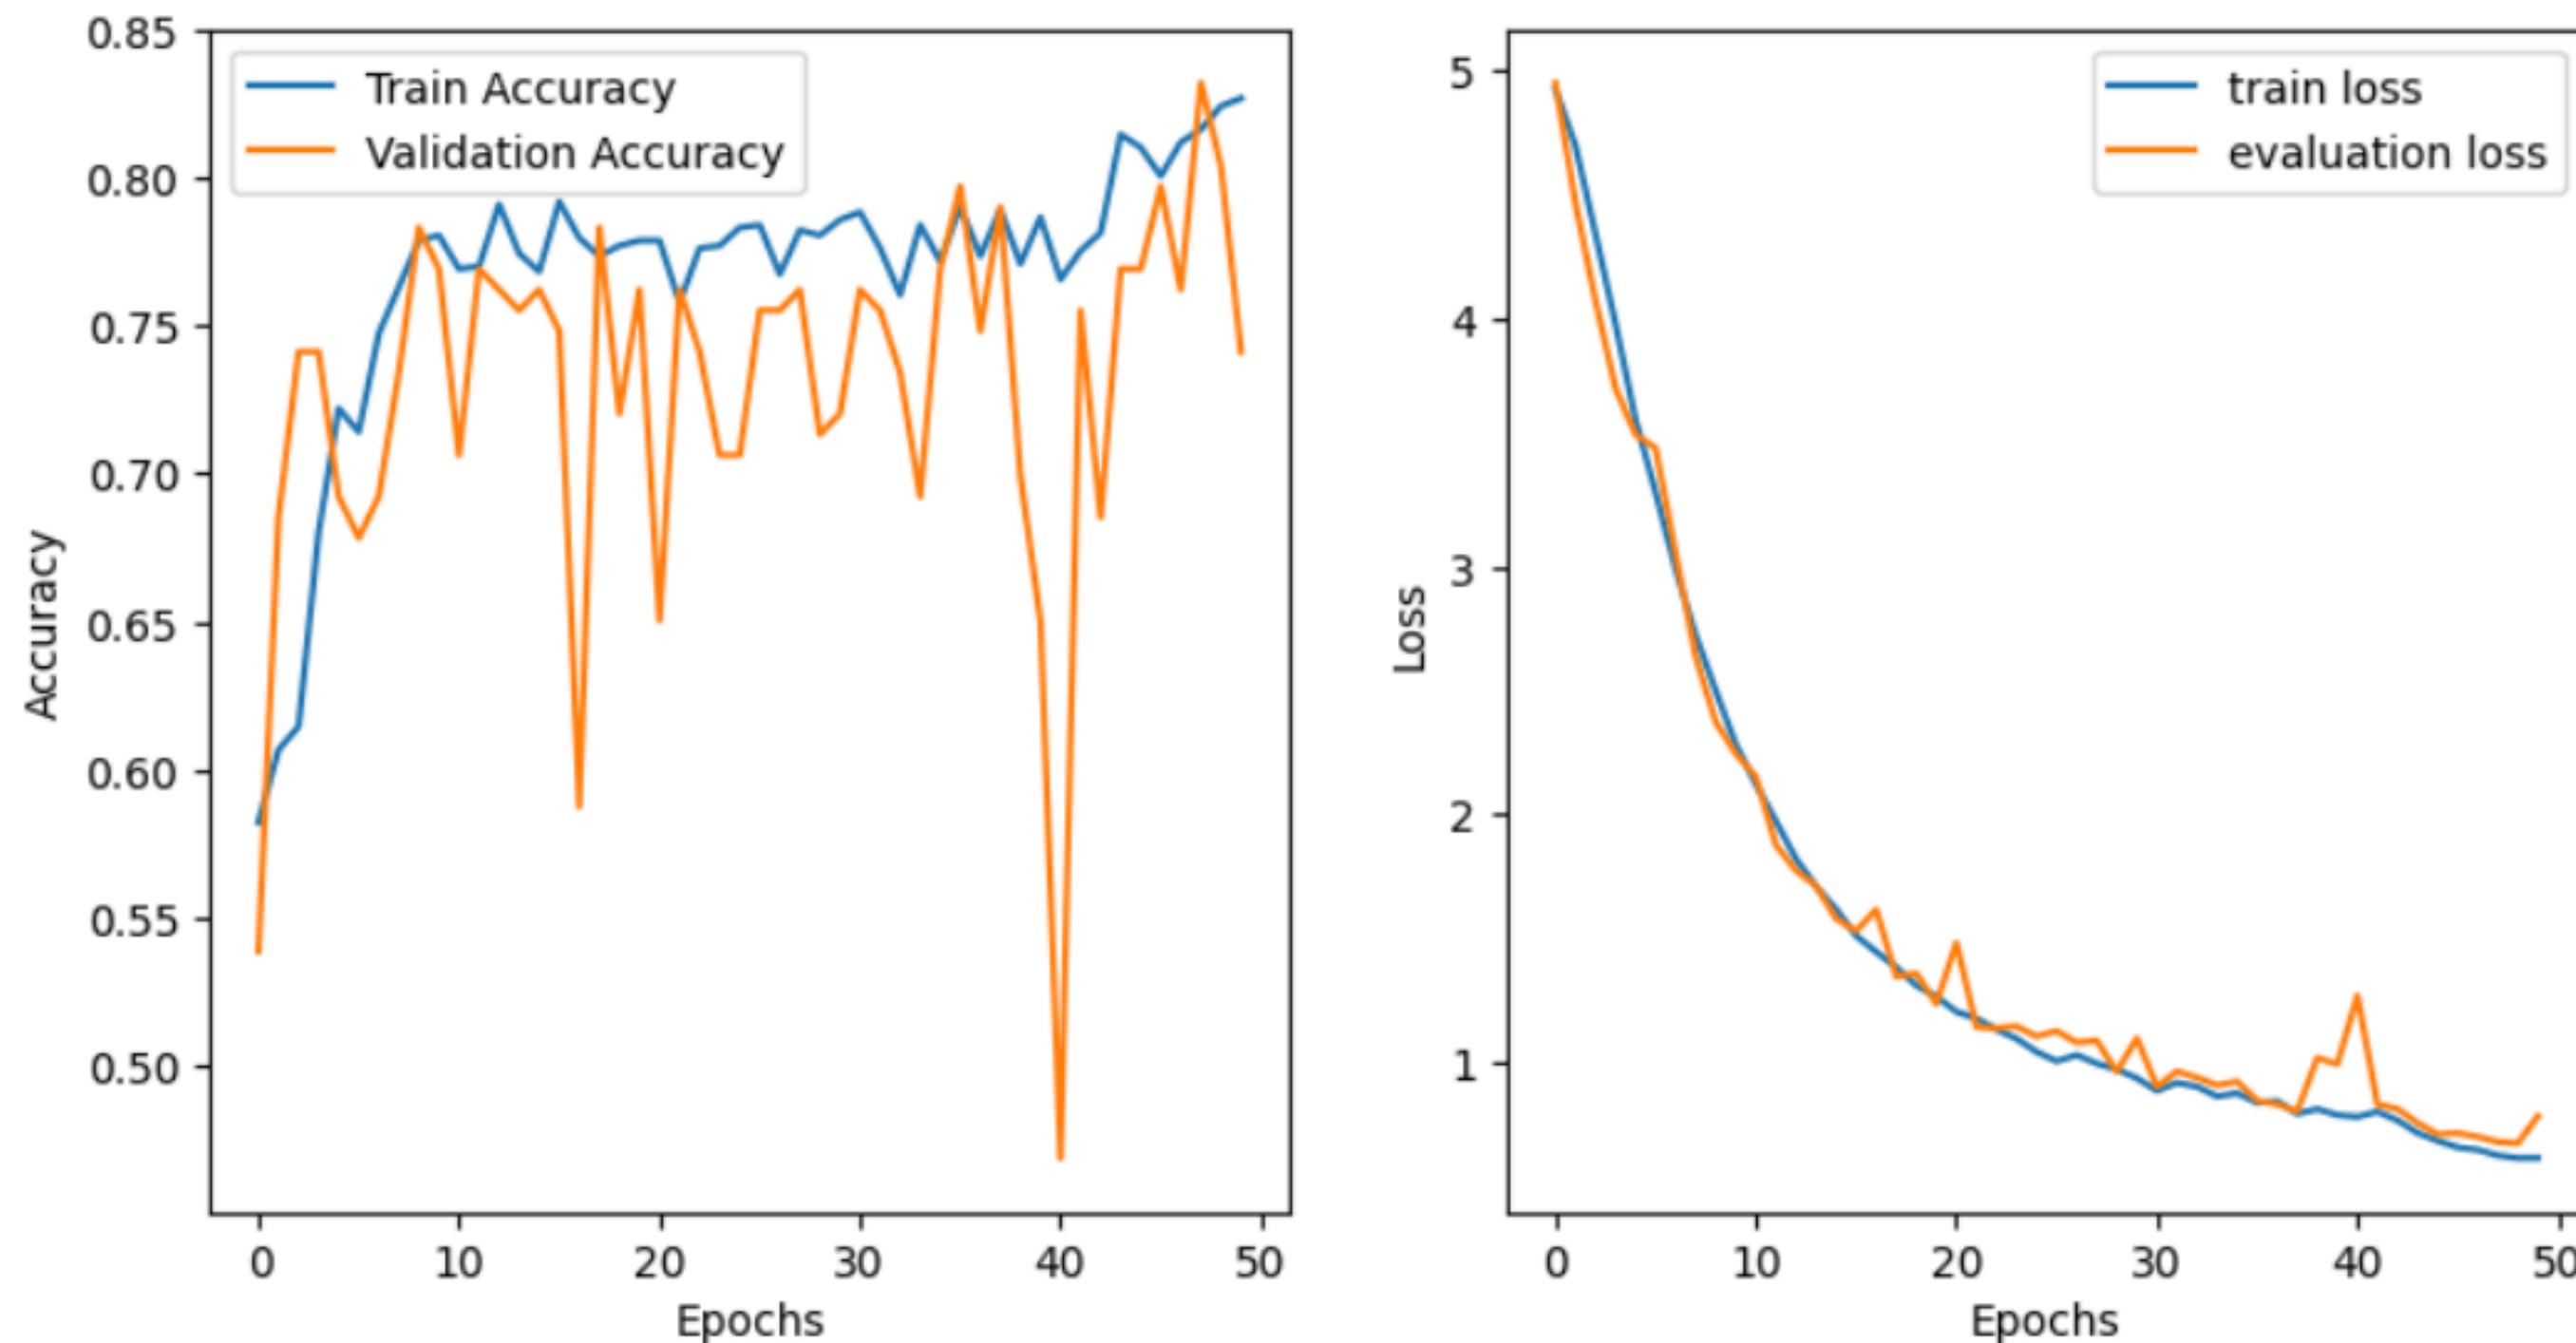
Precision: 0.81

AUC: 0.84

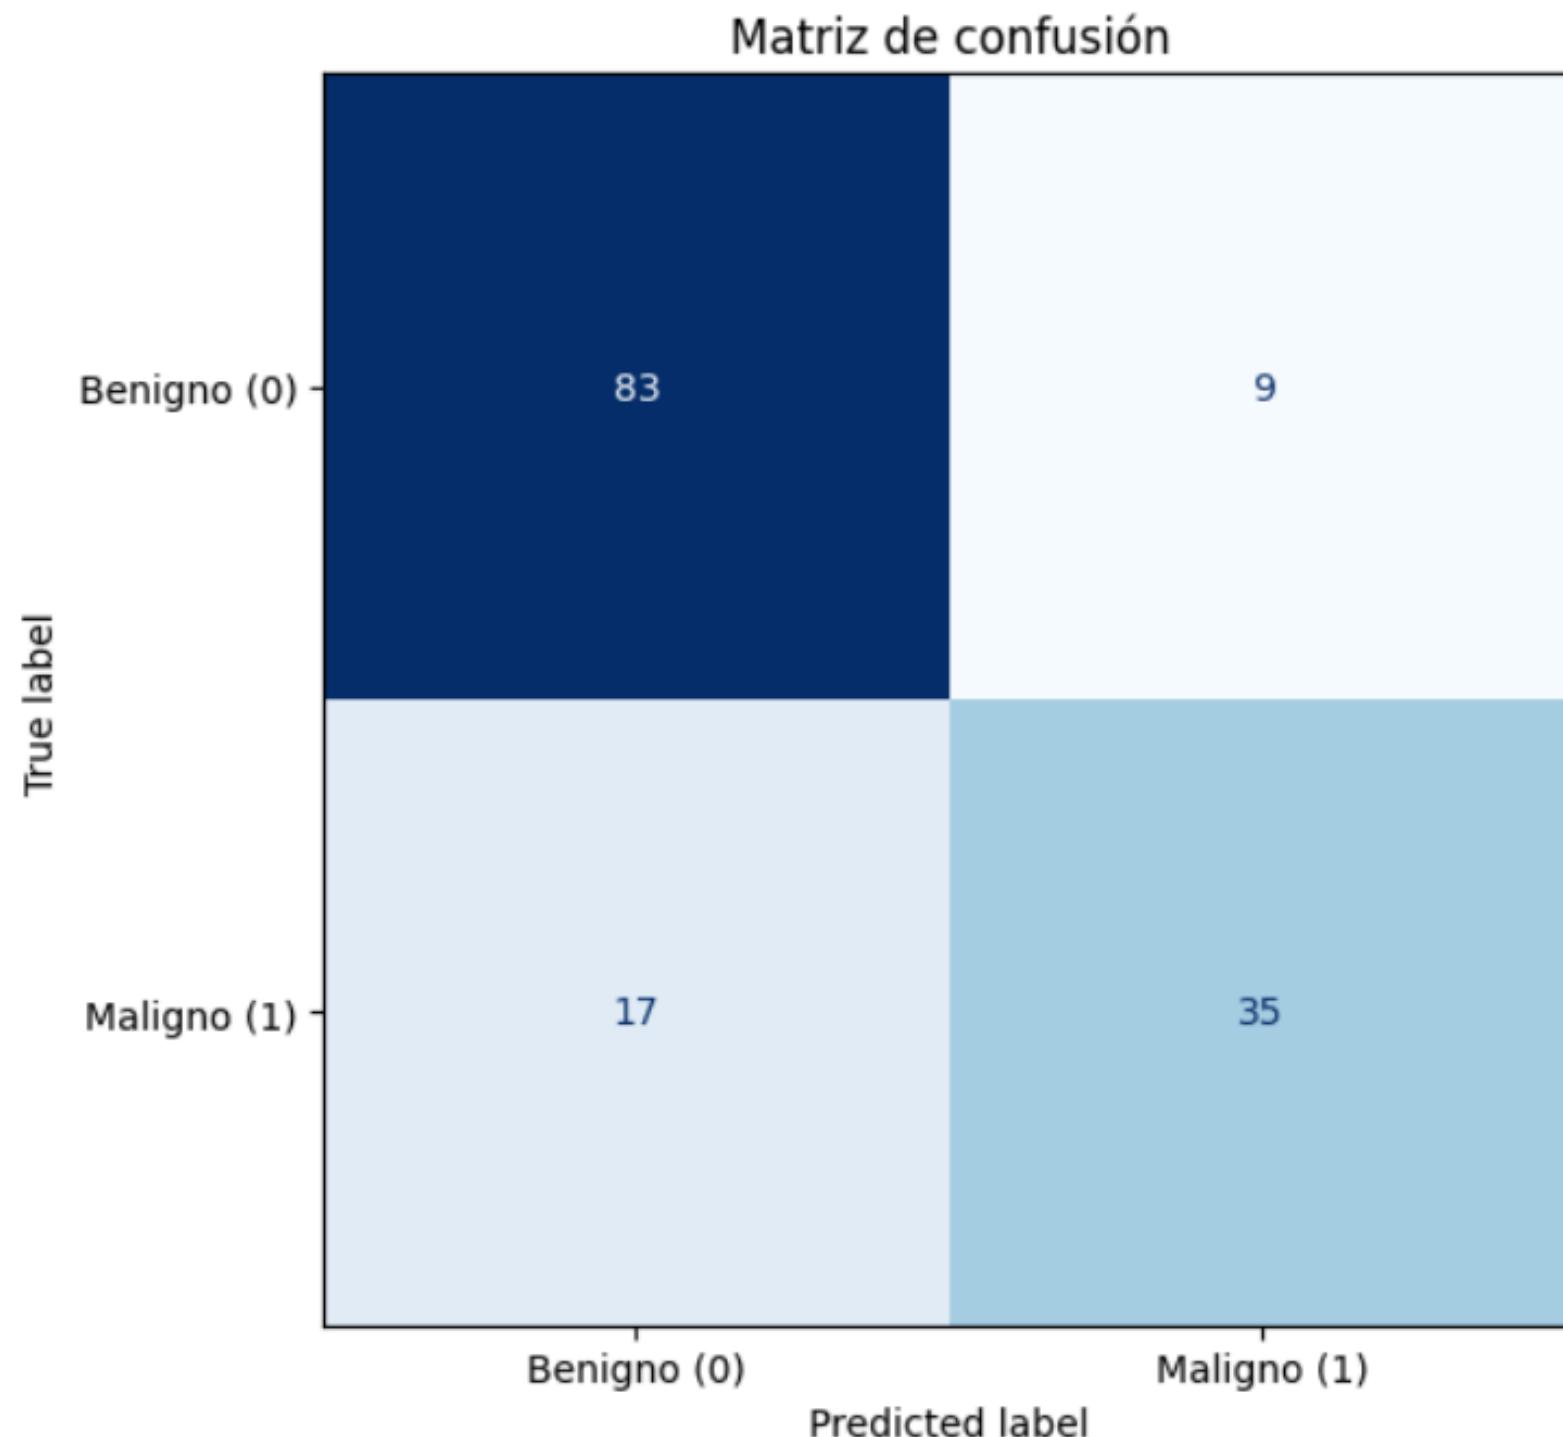
Recall: 0.81

Loss: 0.69

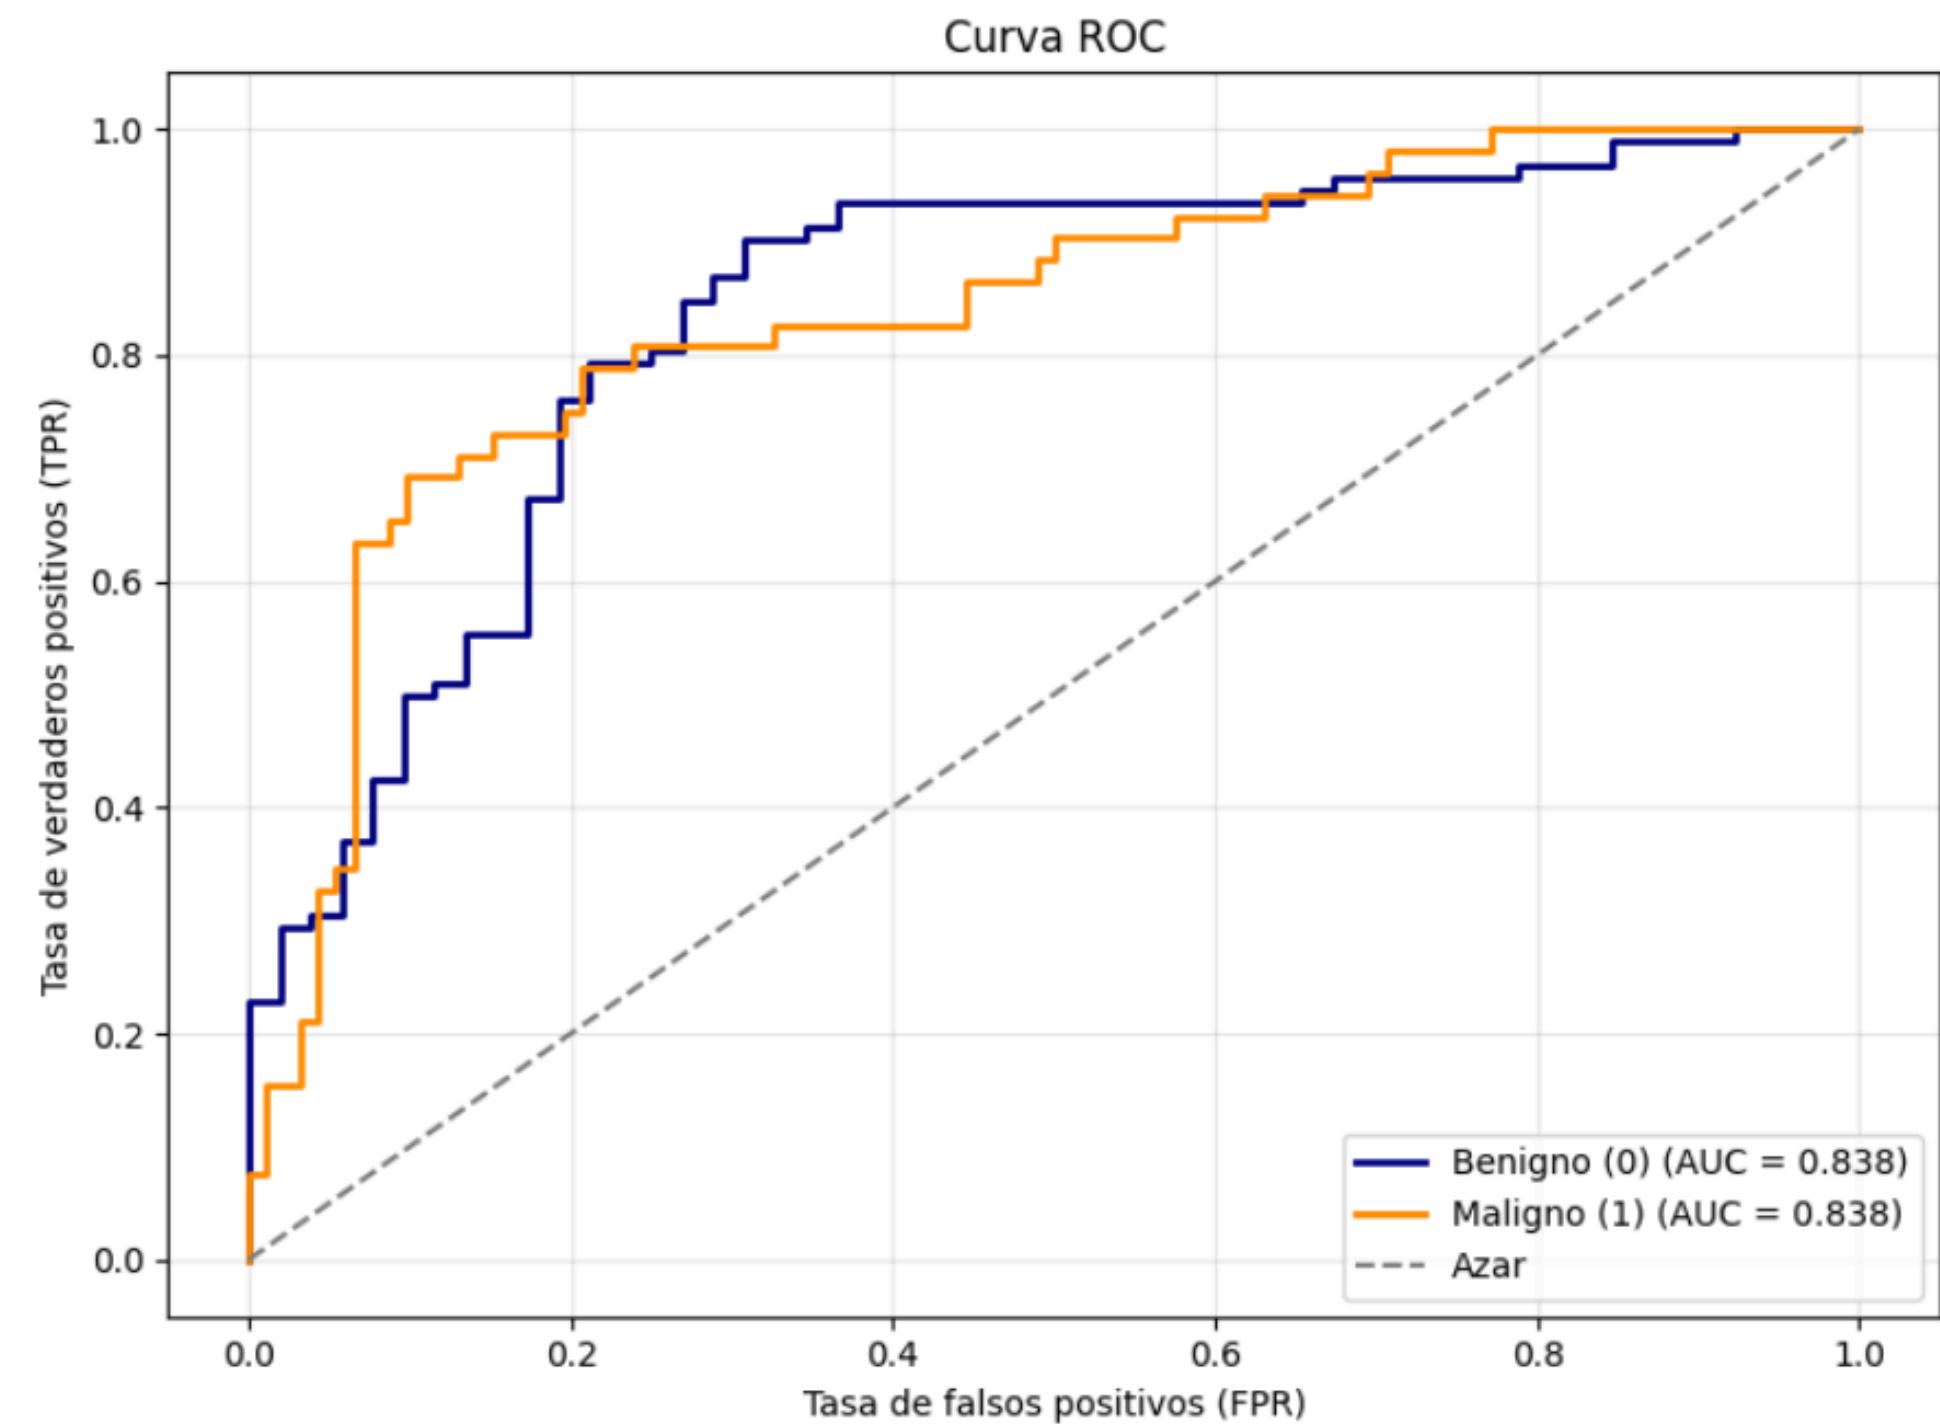
# Accuracy y Loss VS Epochs



# Matriz de Confusión

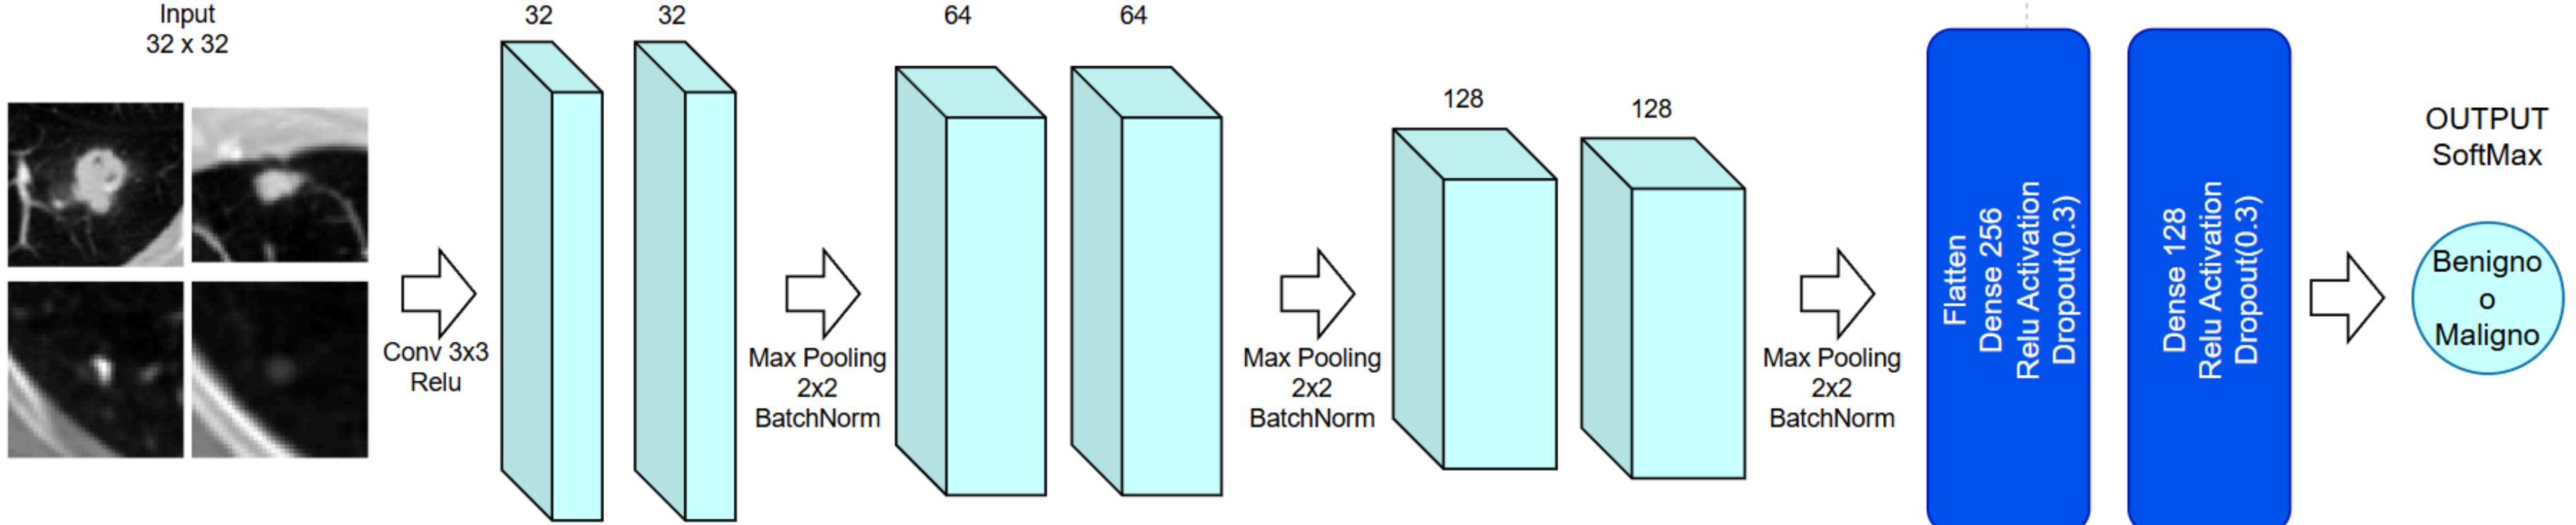


# Curva ROC



# Modelo CNN

# Pipeline



## Métricas Validación:

Accuracy: 0.81

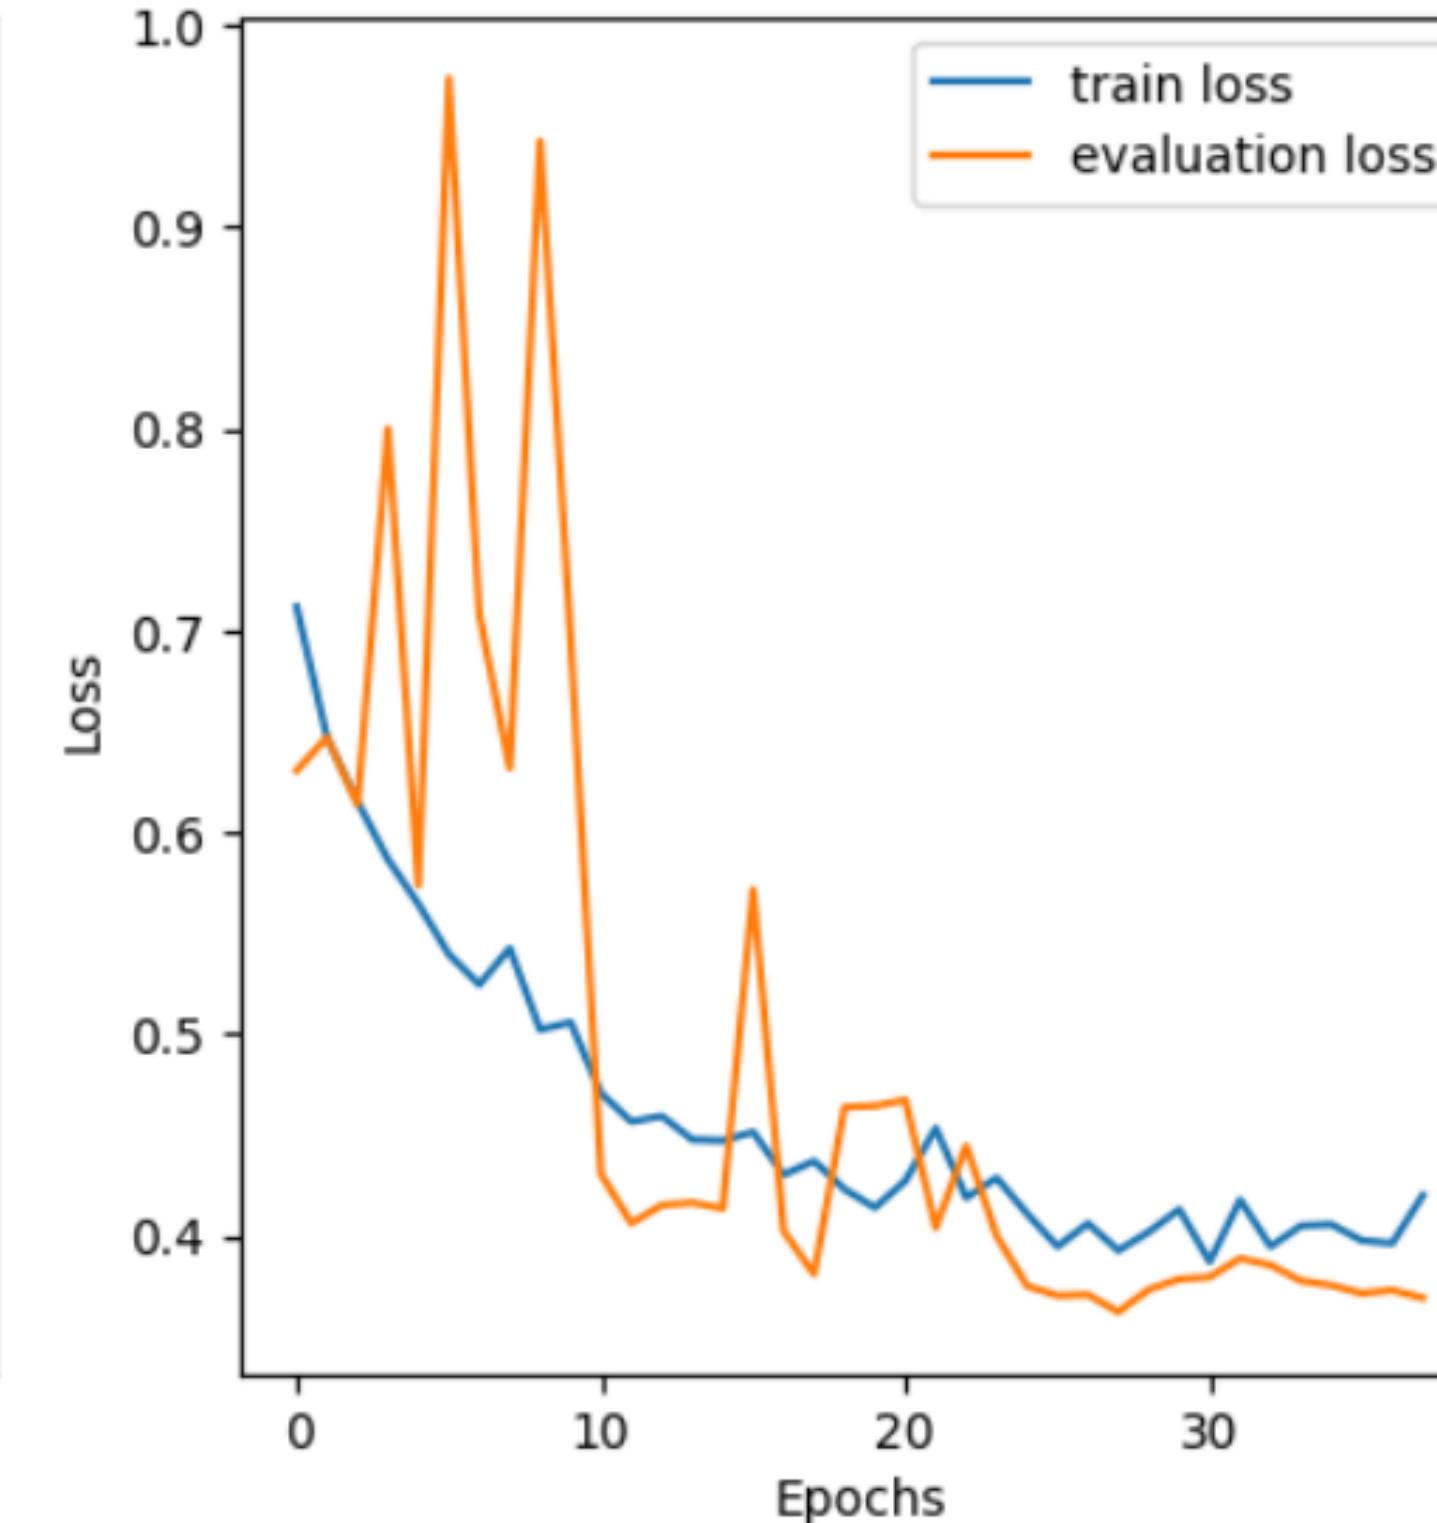
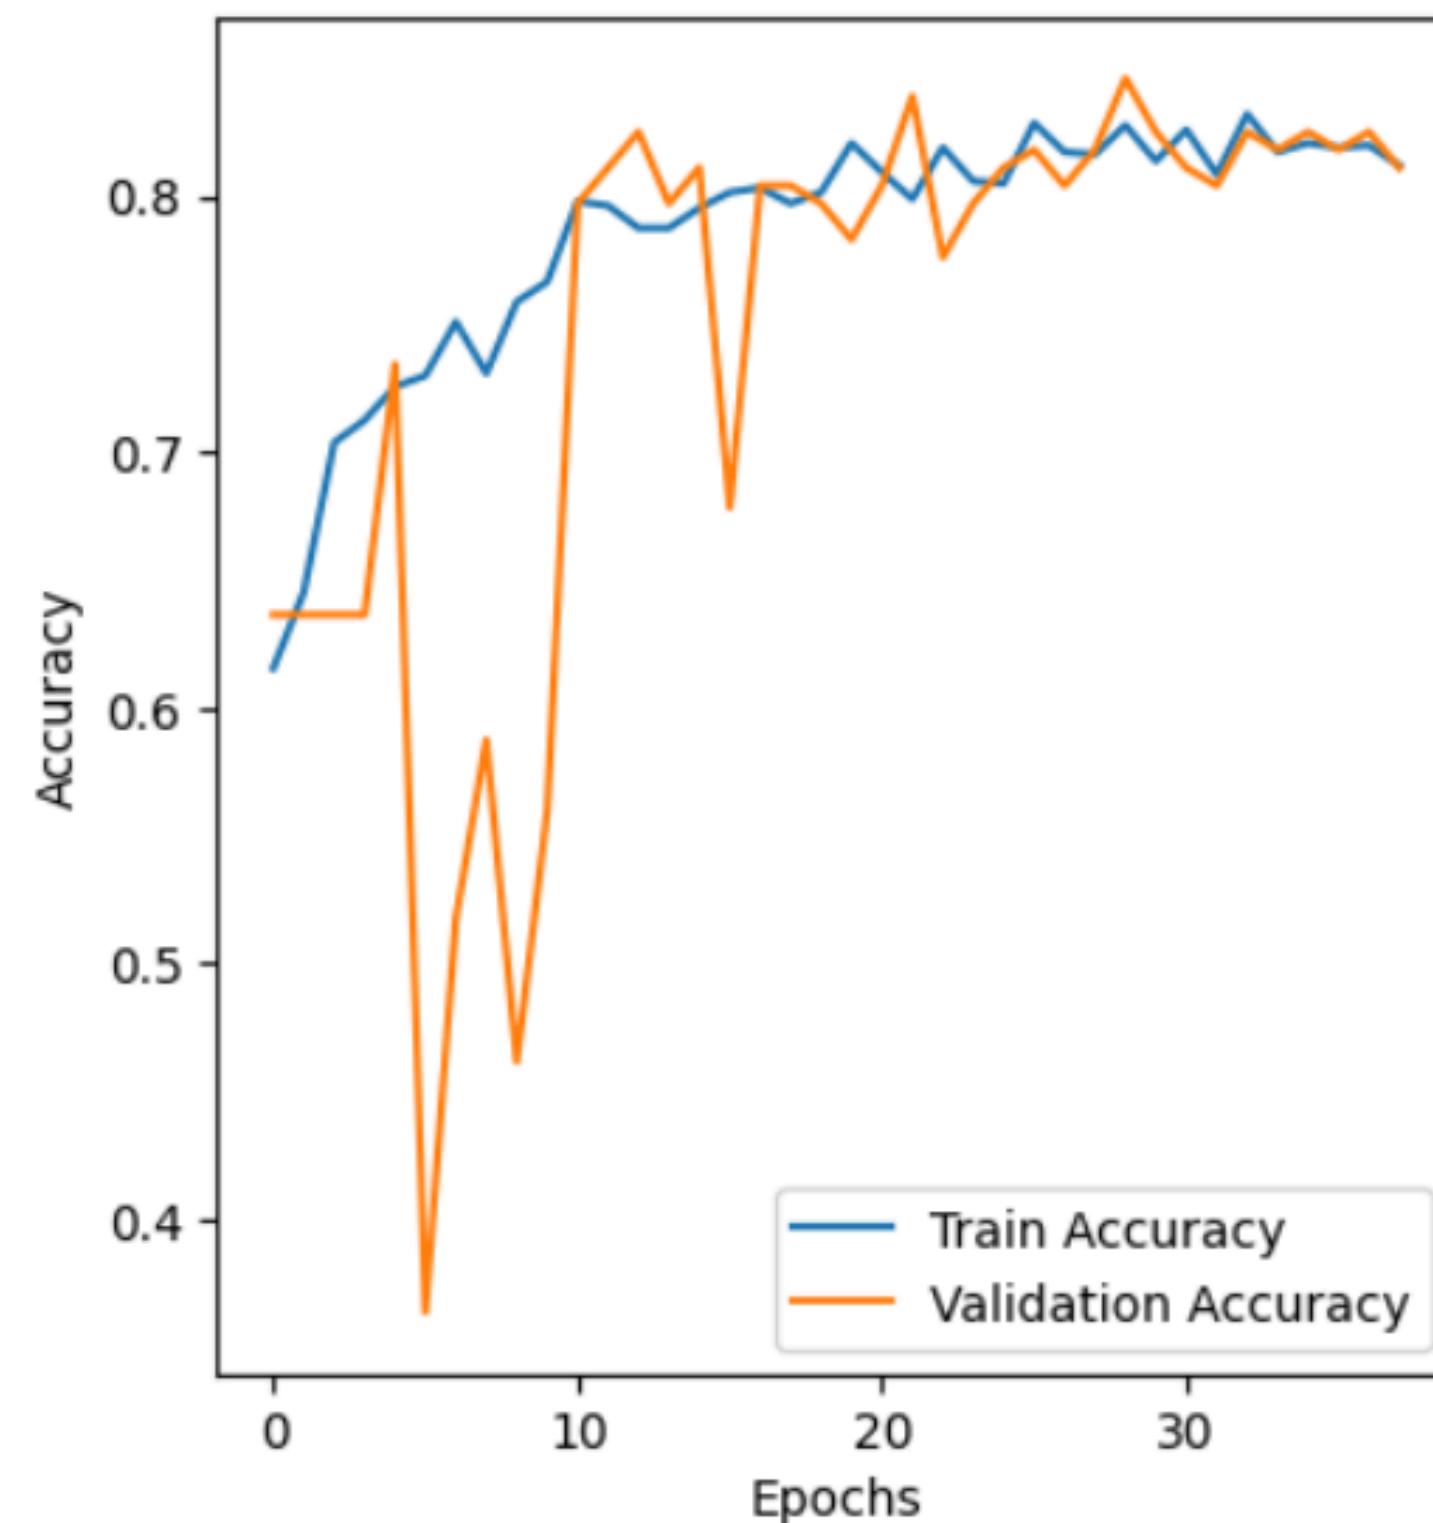
AUC: 0.88

LOSS: 0.42

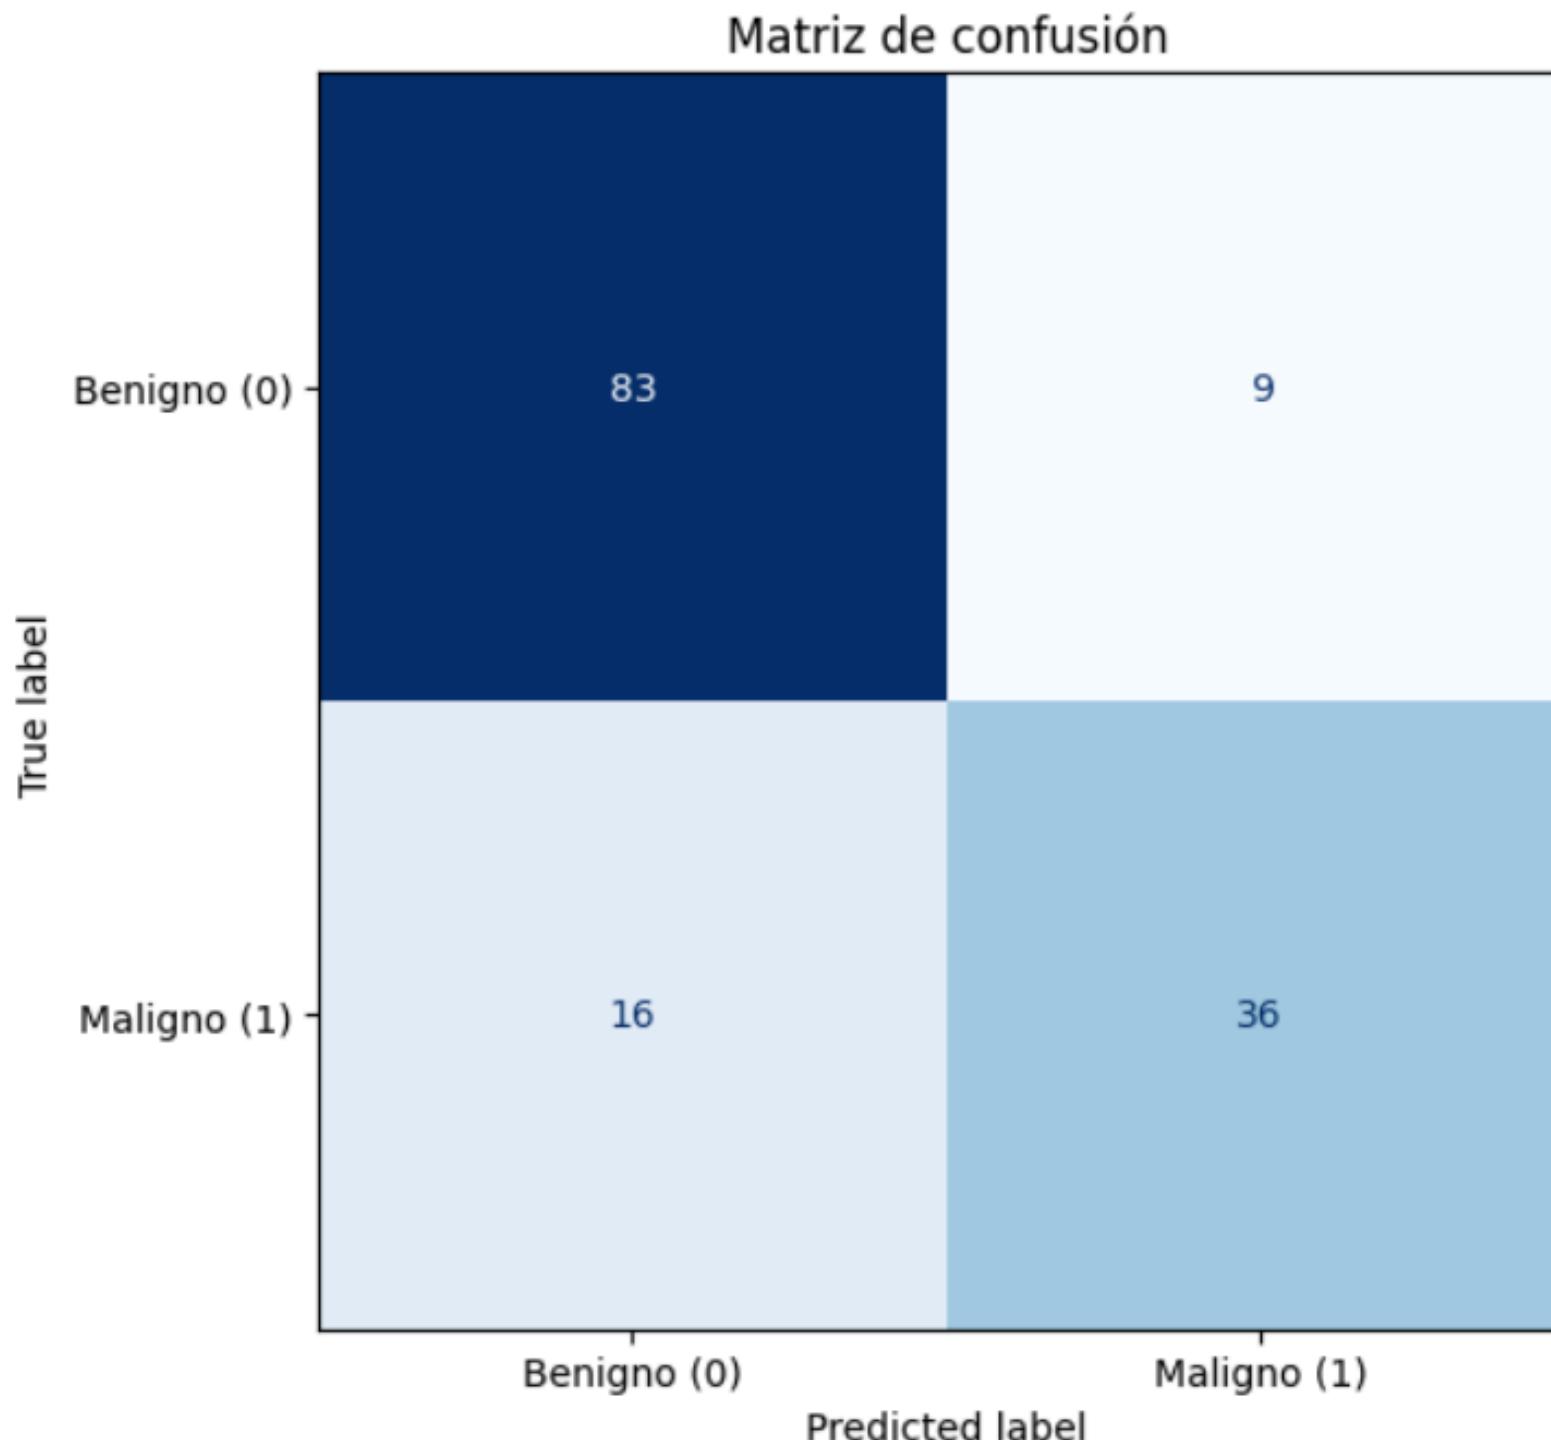
Precision: 0.80

Recall: 0.81

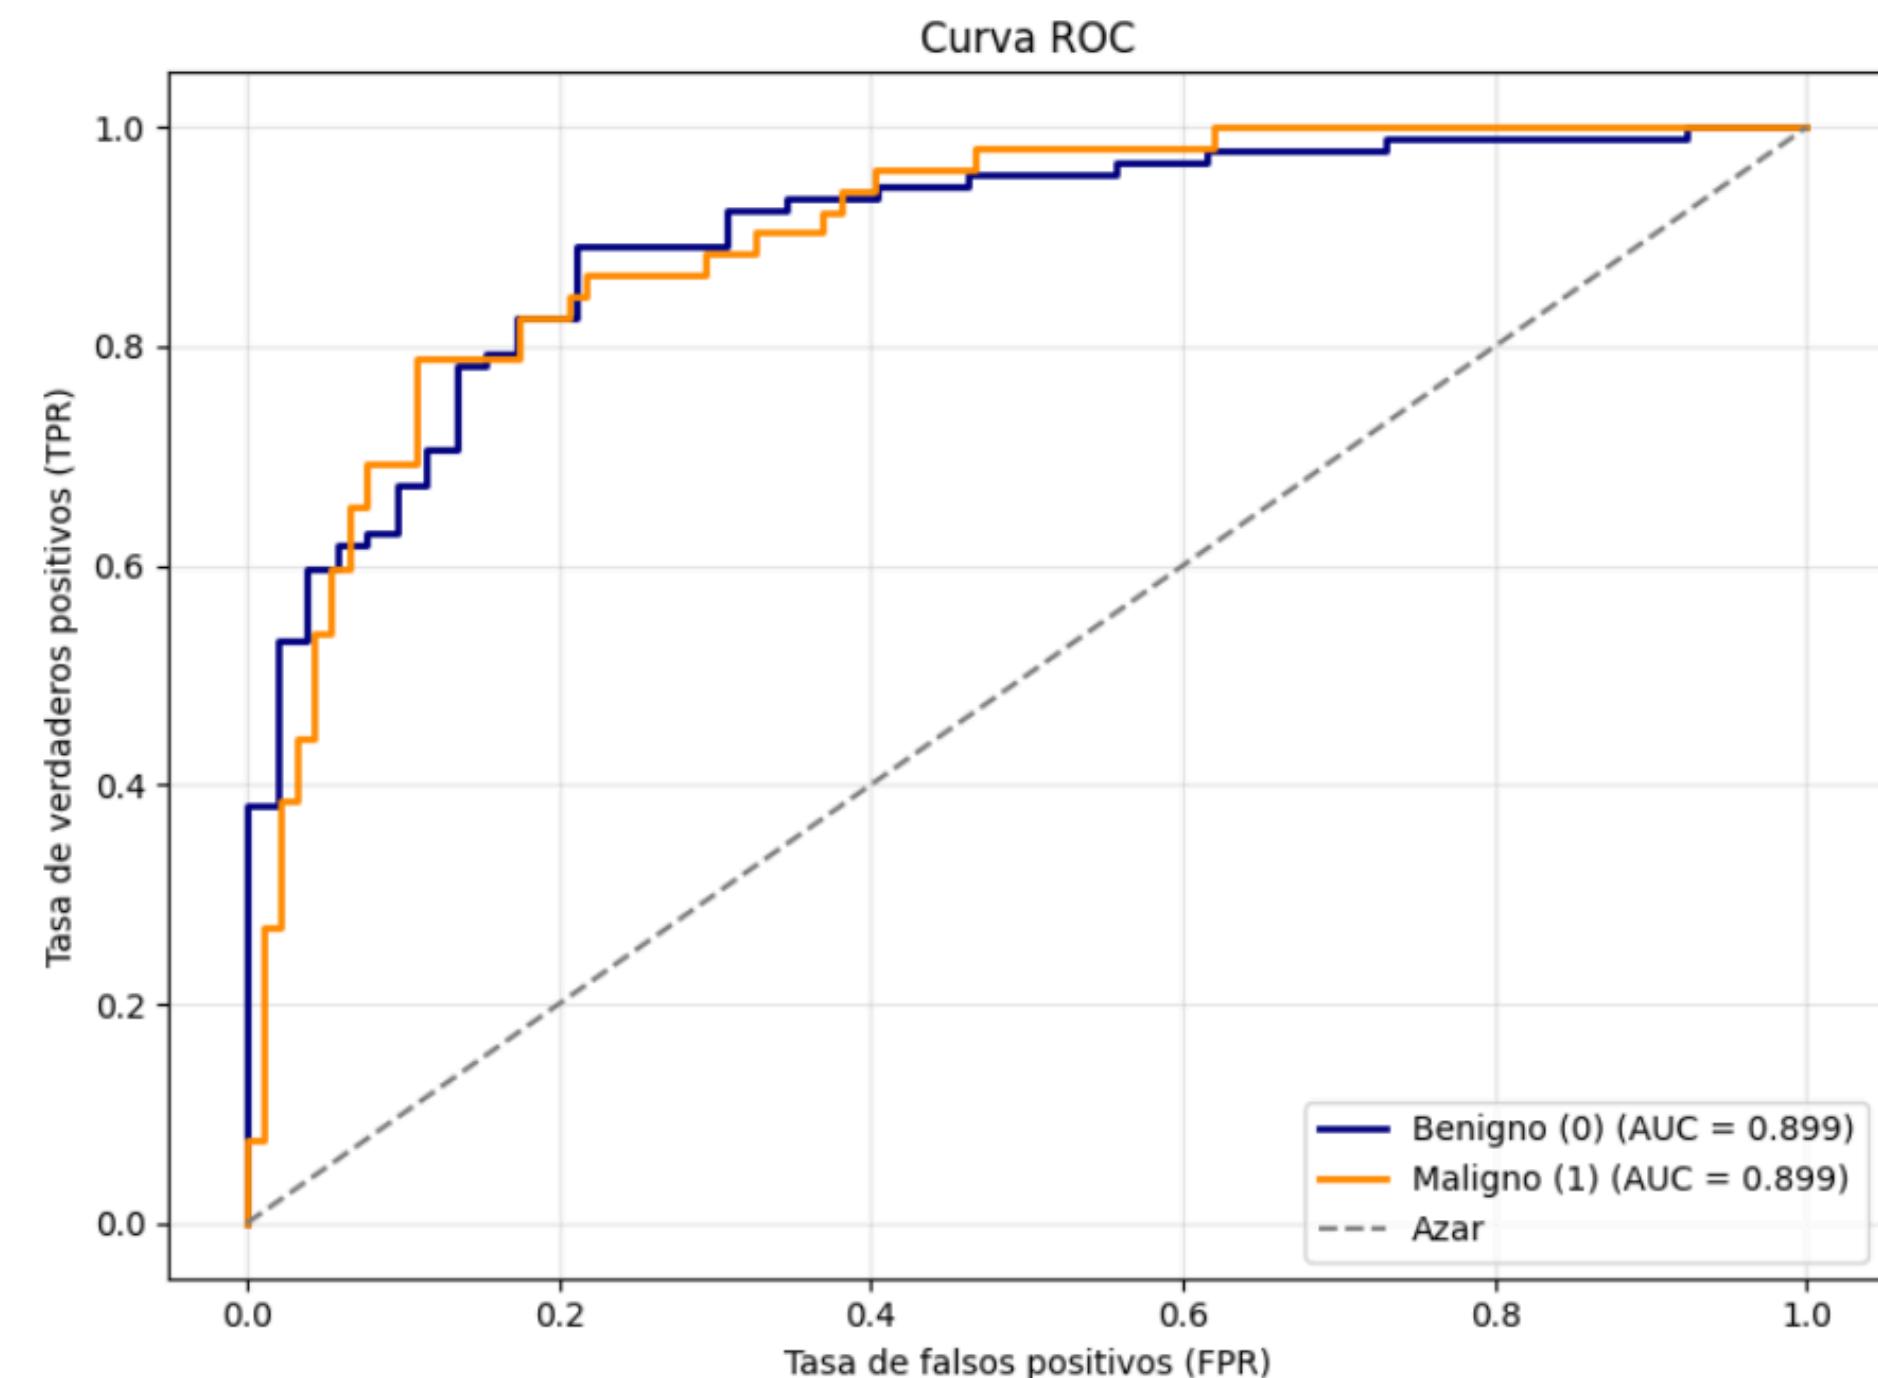
# Accuracy y Loss VS Epochs



# Matriz de Confusión



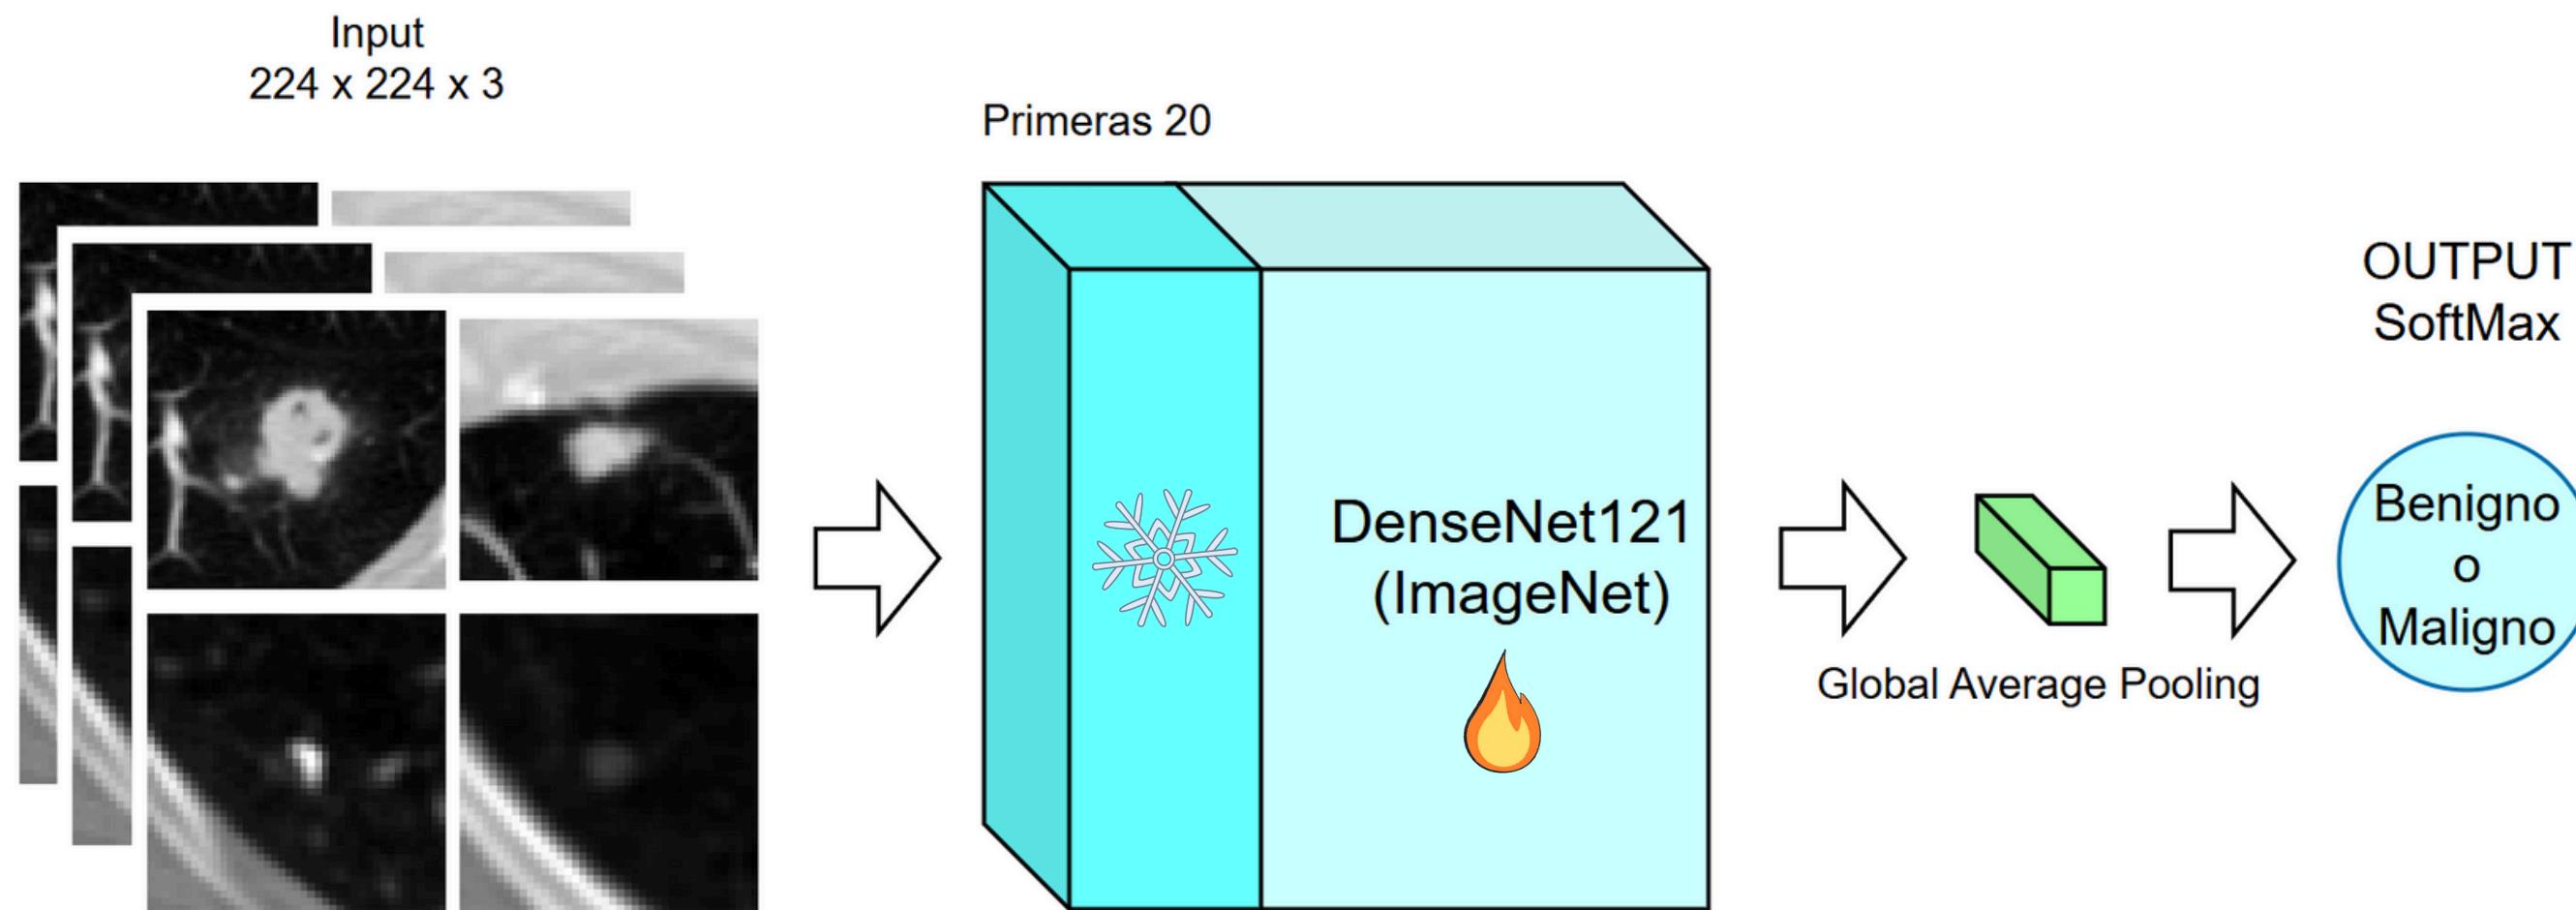
# Curva ROC





# Modelo CNN Transfer Learning

# Pipeline



## Métricas Validación:

Accuracy: 0.88

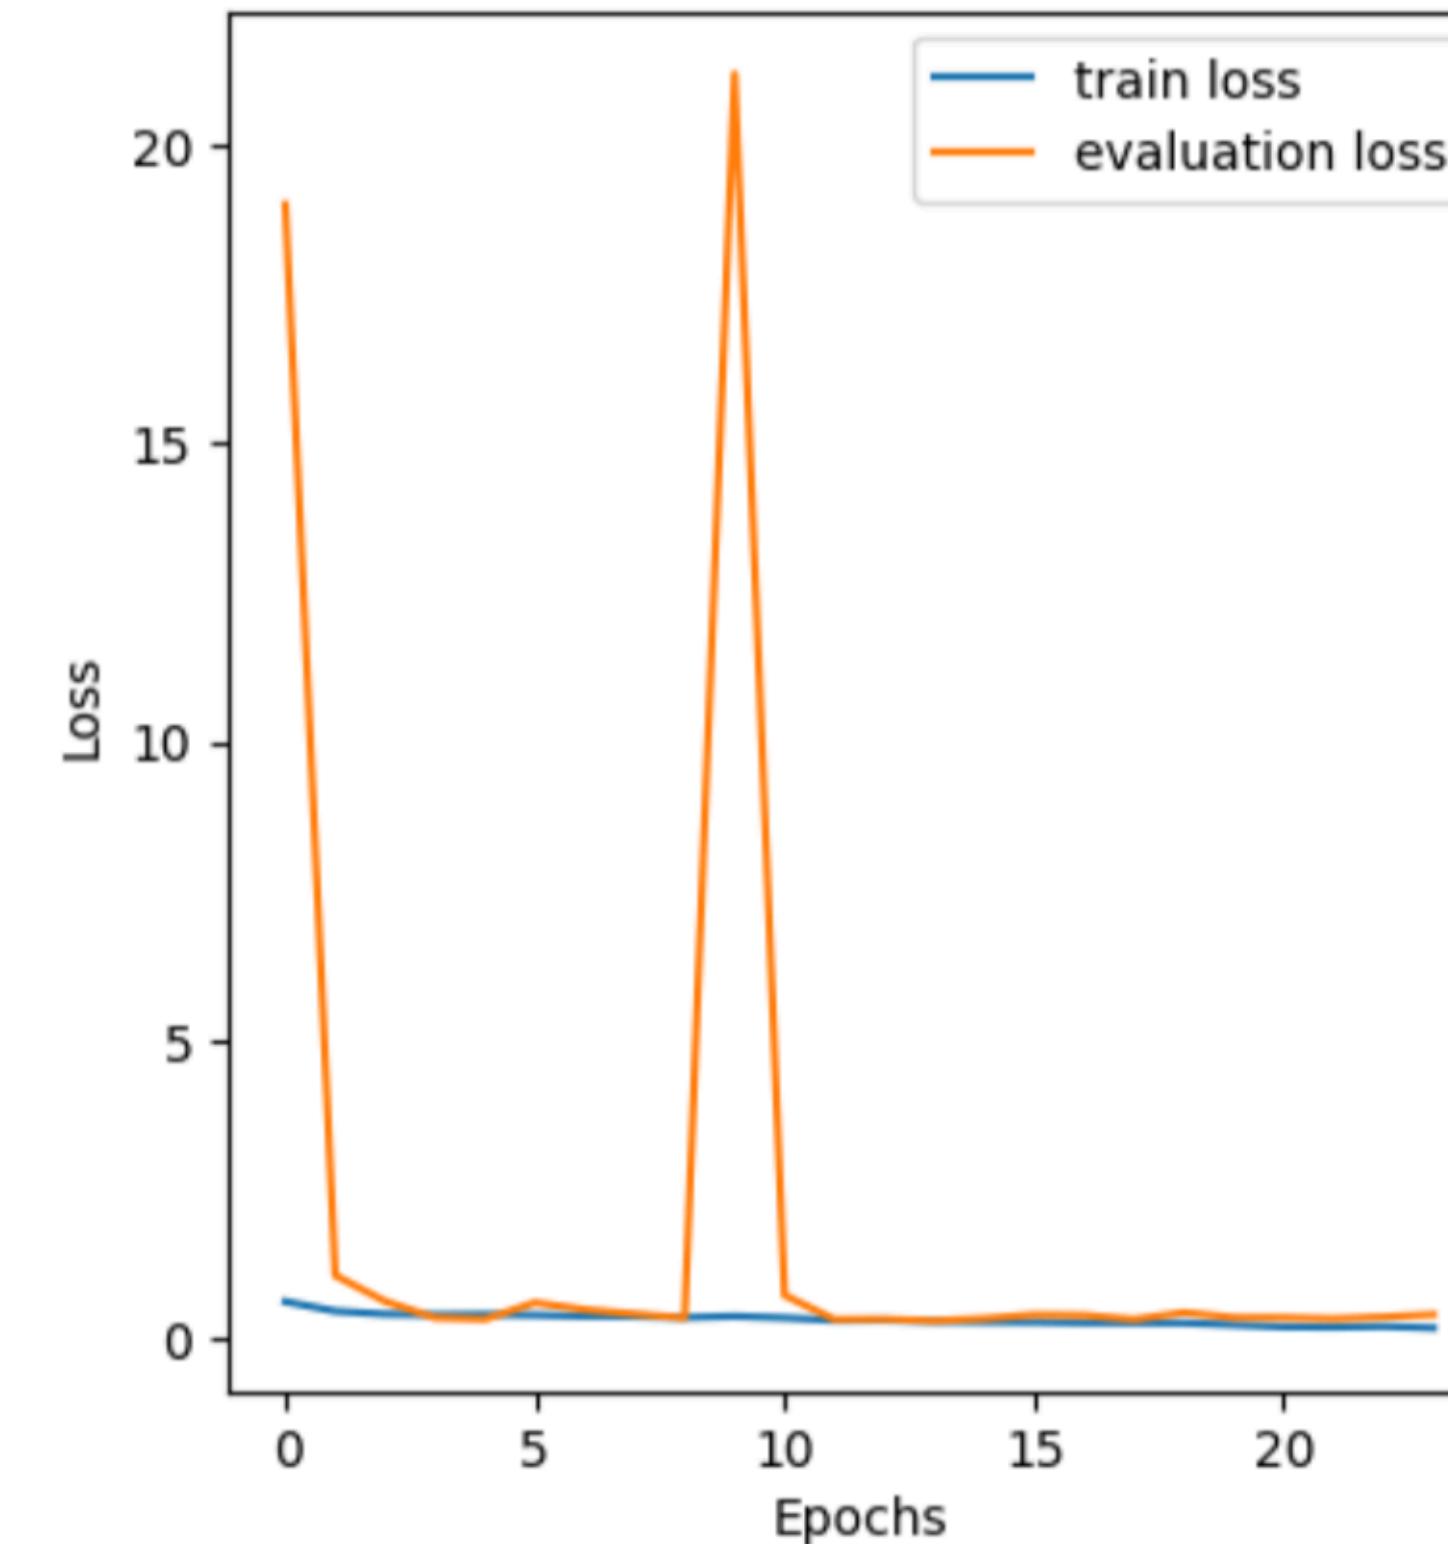
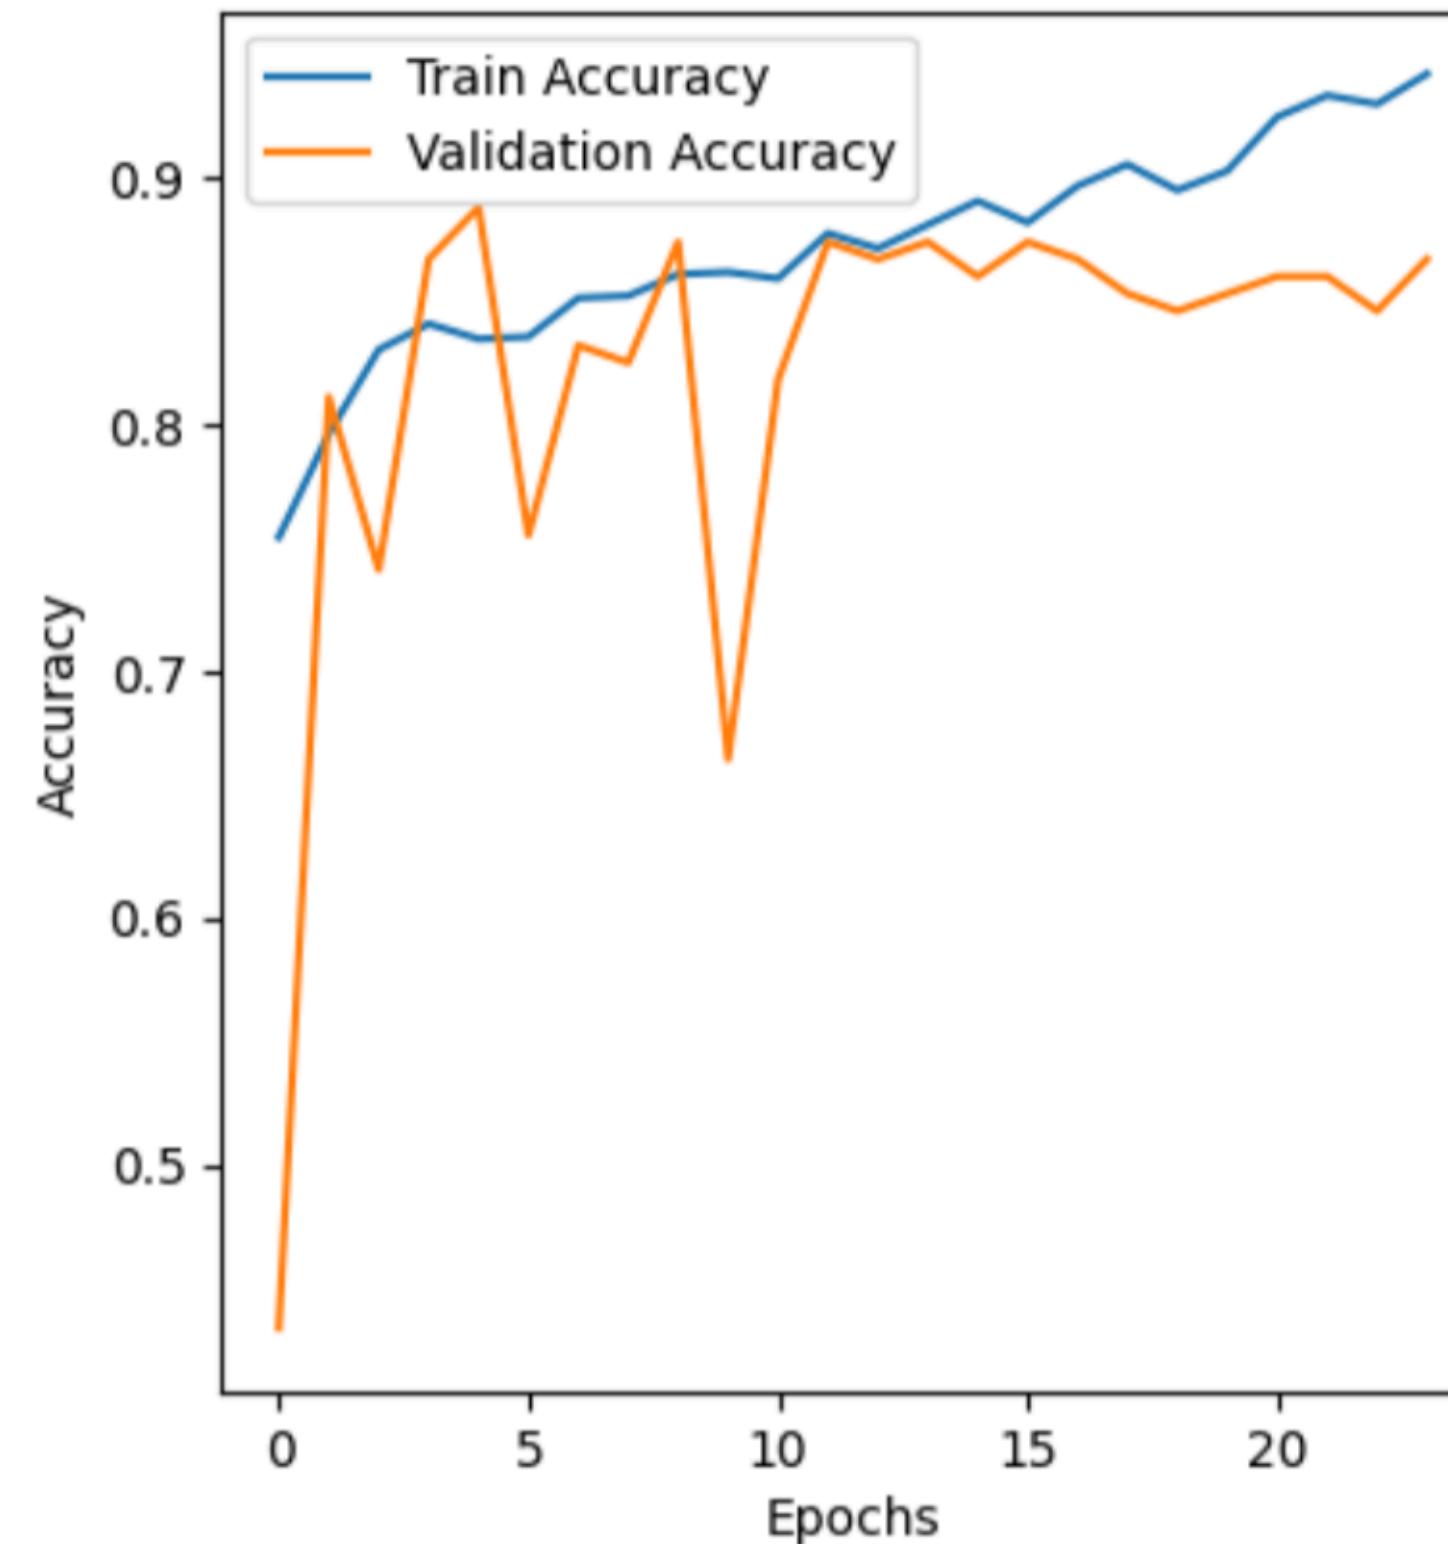
Precision: 0.88

AUC: 0.91

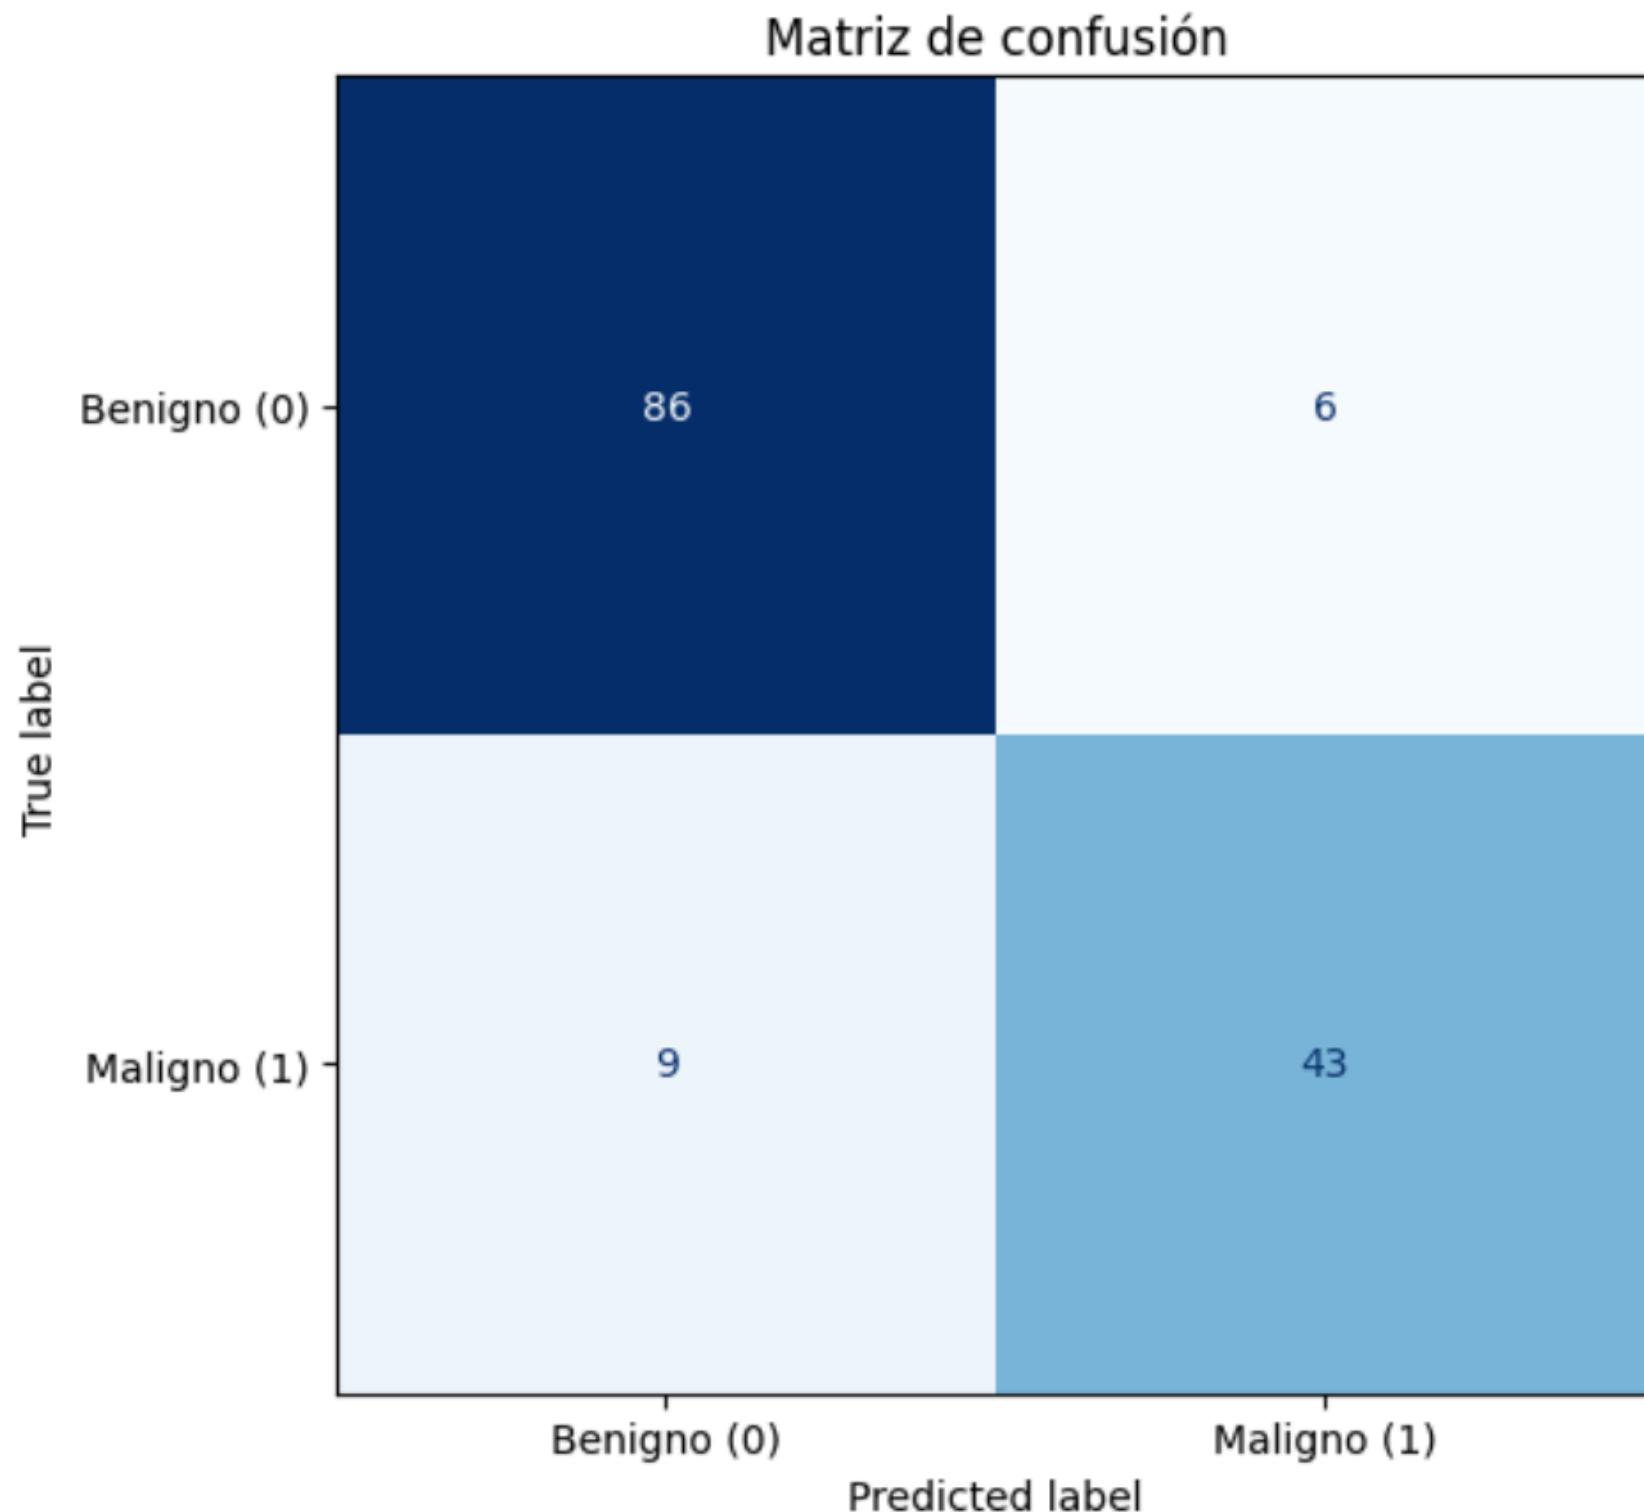
Recall: 0.85

Loss: 0.39

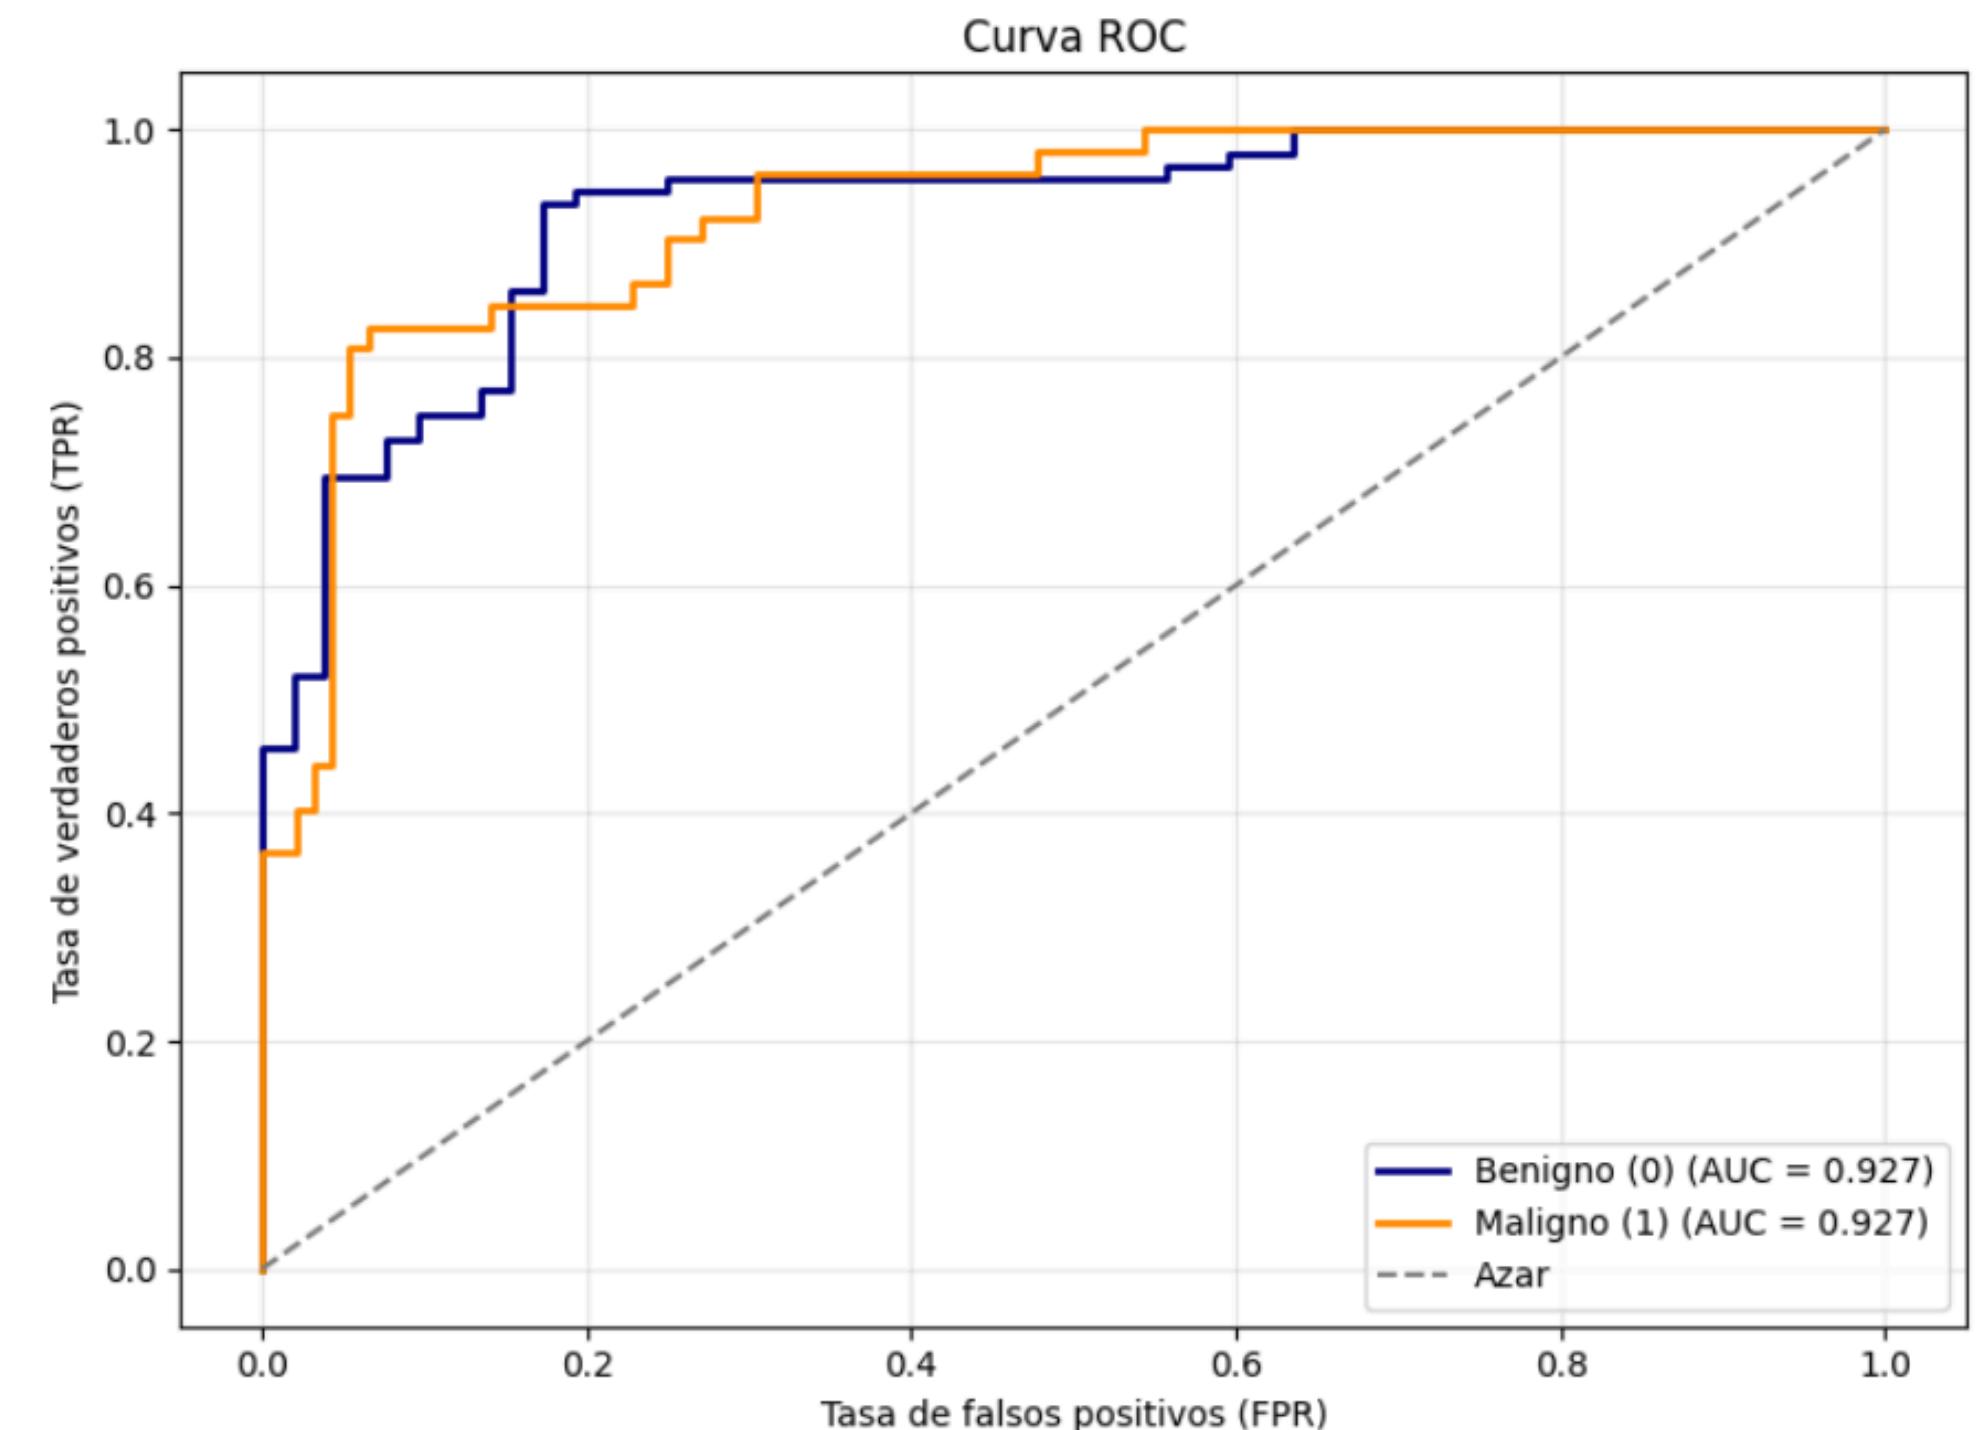
# Accuray y Loss VS Epochs



# Matriz de Confusión



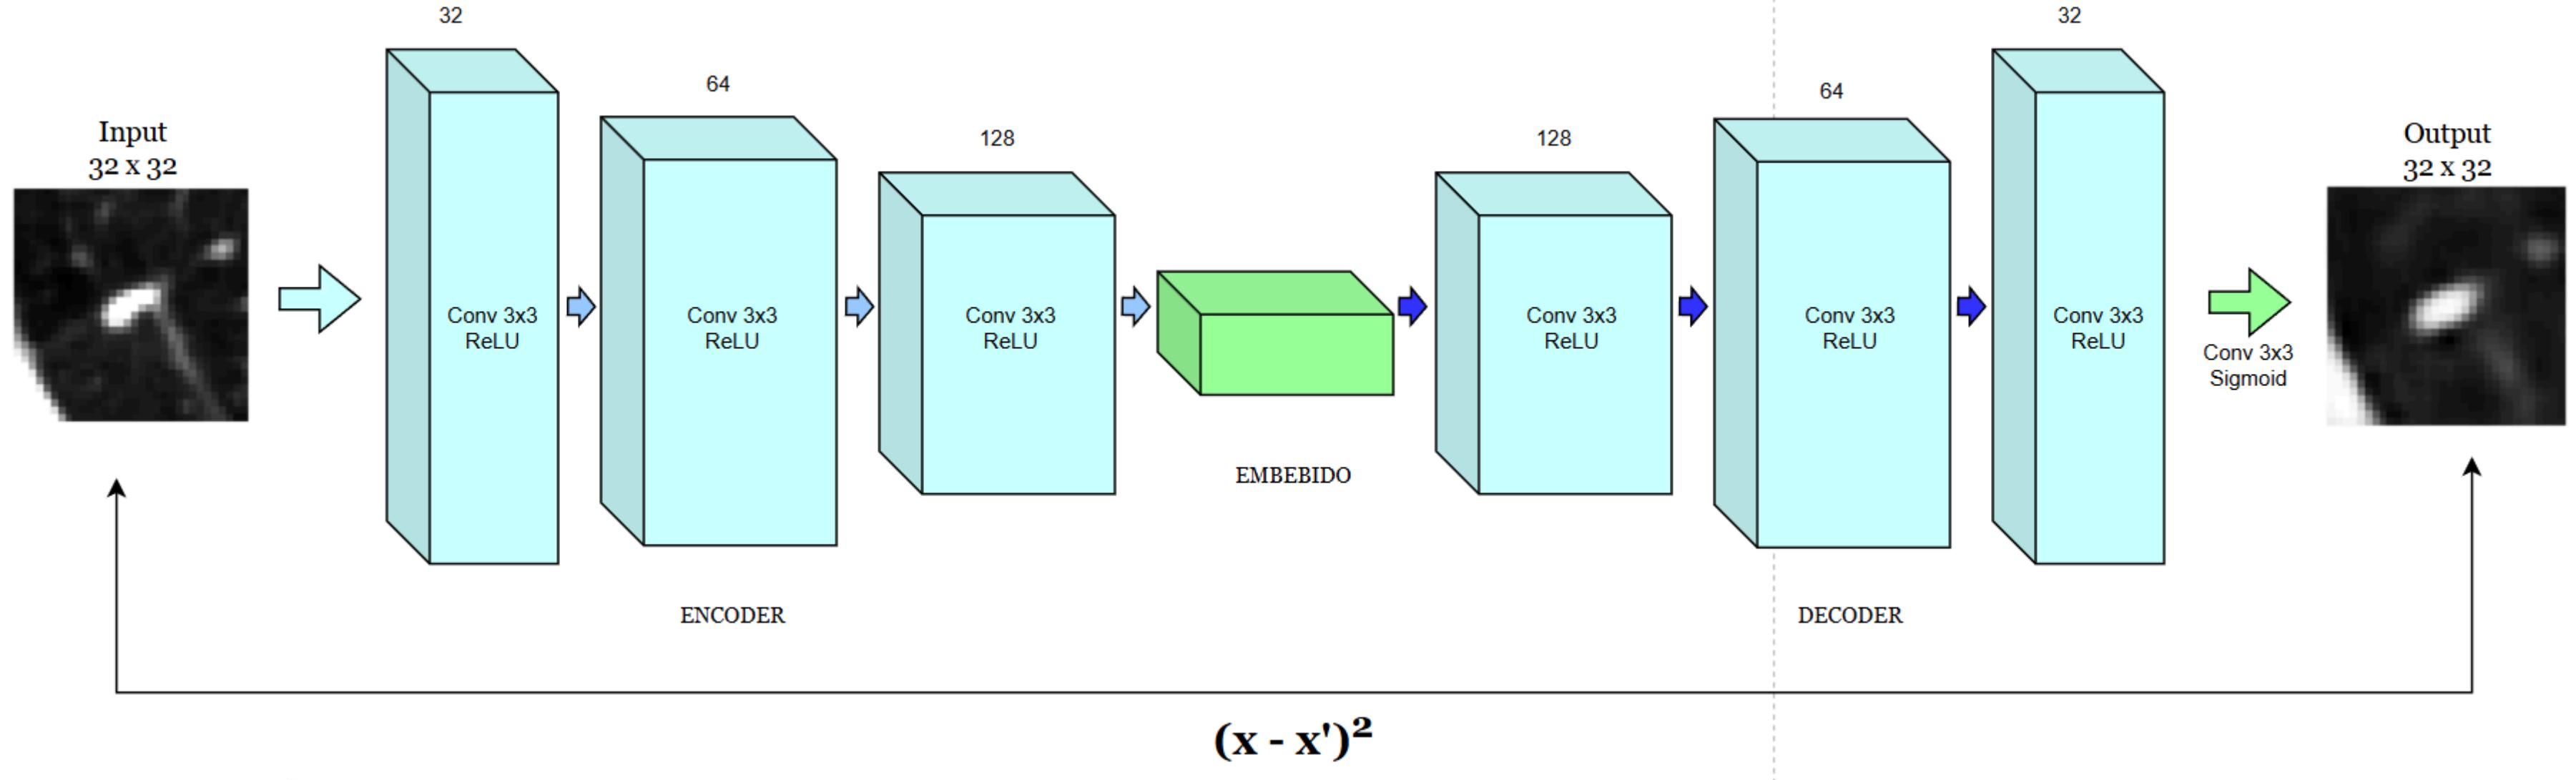
# Curva ROC





# Autoencoder Anómalo

# Pipeline



MaxPool  
 $2 \times 2$   
UpSamp  
 $2 \times 2$

**Métricas Validación:**  
MSE benignos: 0.0022  
MSE malignos: 0.0042

$$(x - x')^2$$

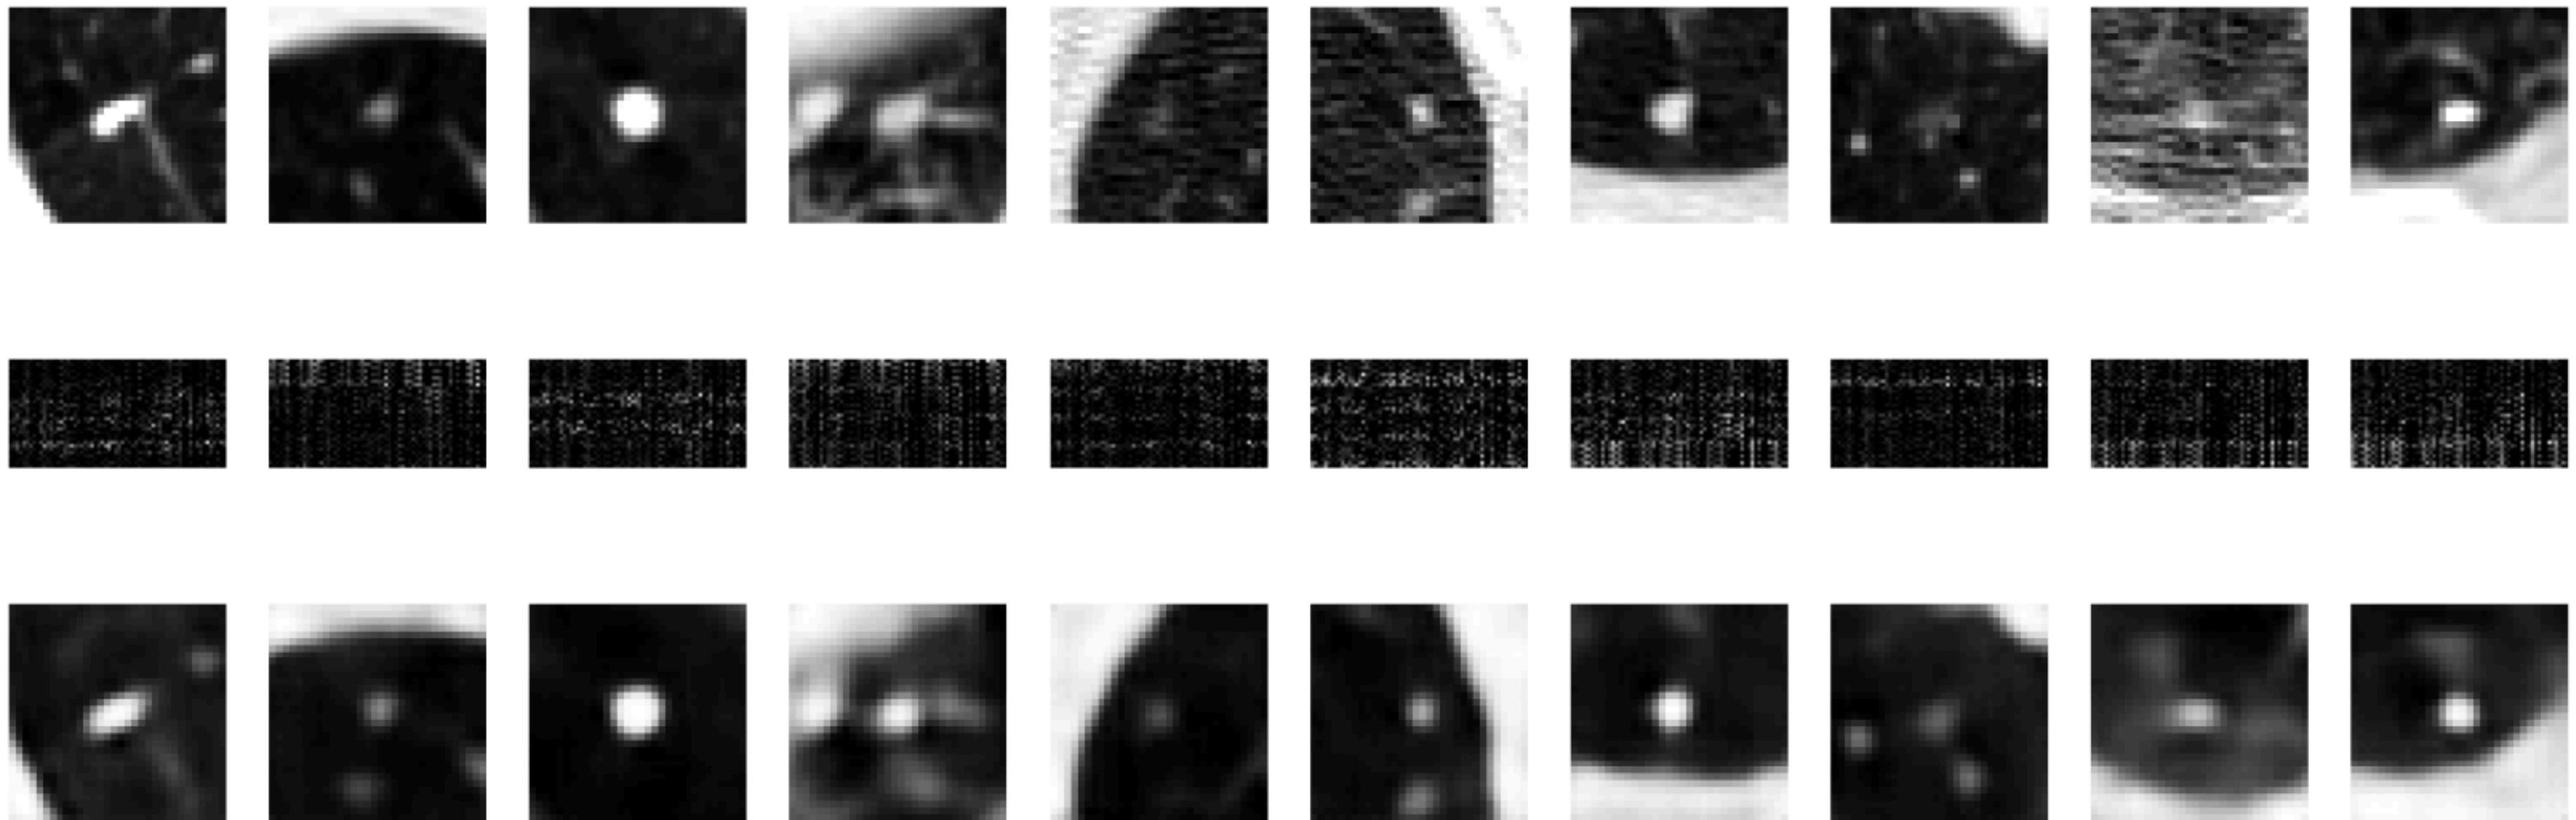
**Clase control:** Benigno  
**Clase Anomala:** Maligno  
**Threshold Seleccionado:** 0.00390

# Imagen vs Reconstrucción - Nódulos Benignos

Universidad  
Industrial de  
Santander



Resultados Autoencoder – Benignos

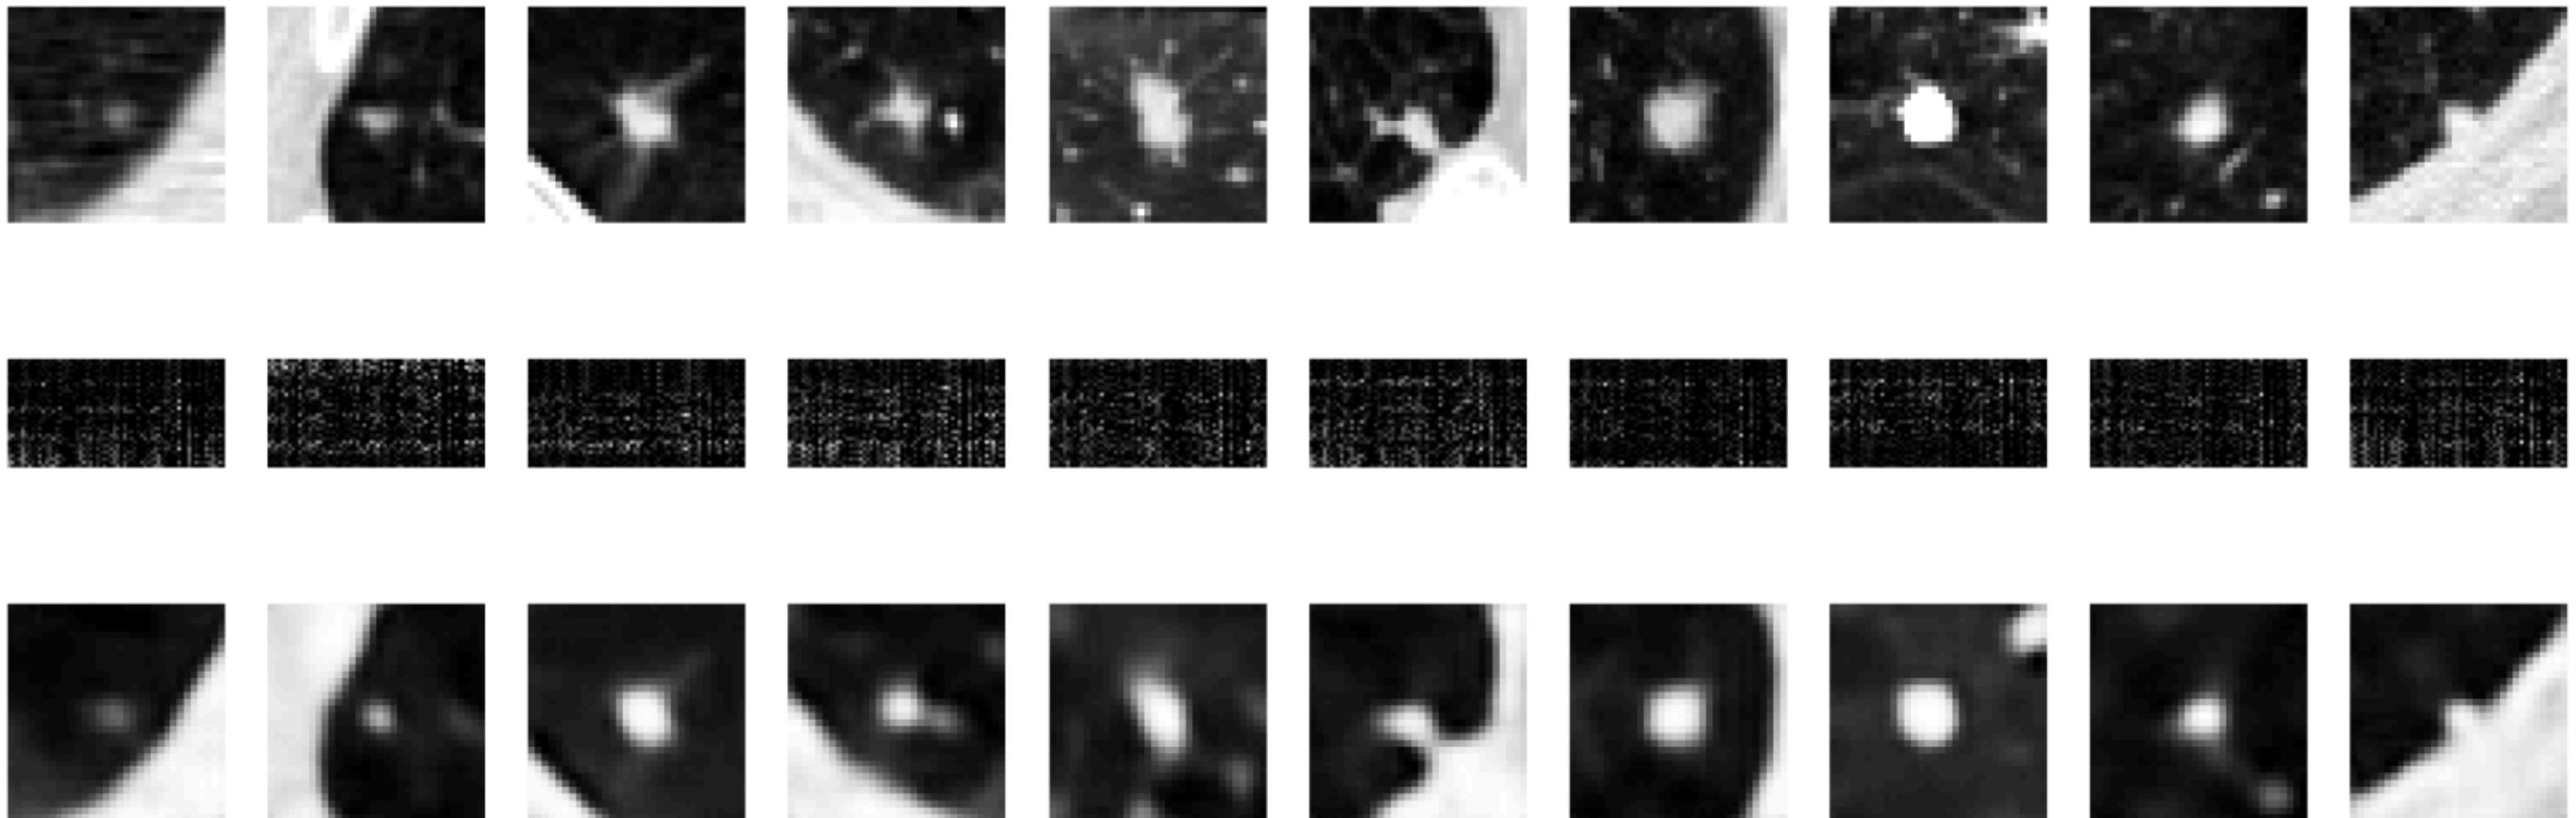


# Imagen vs Reconstrucción - Nódulos Malignos

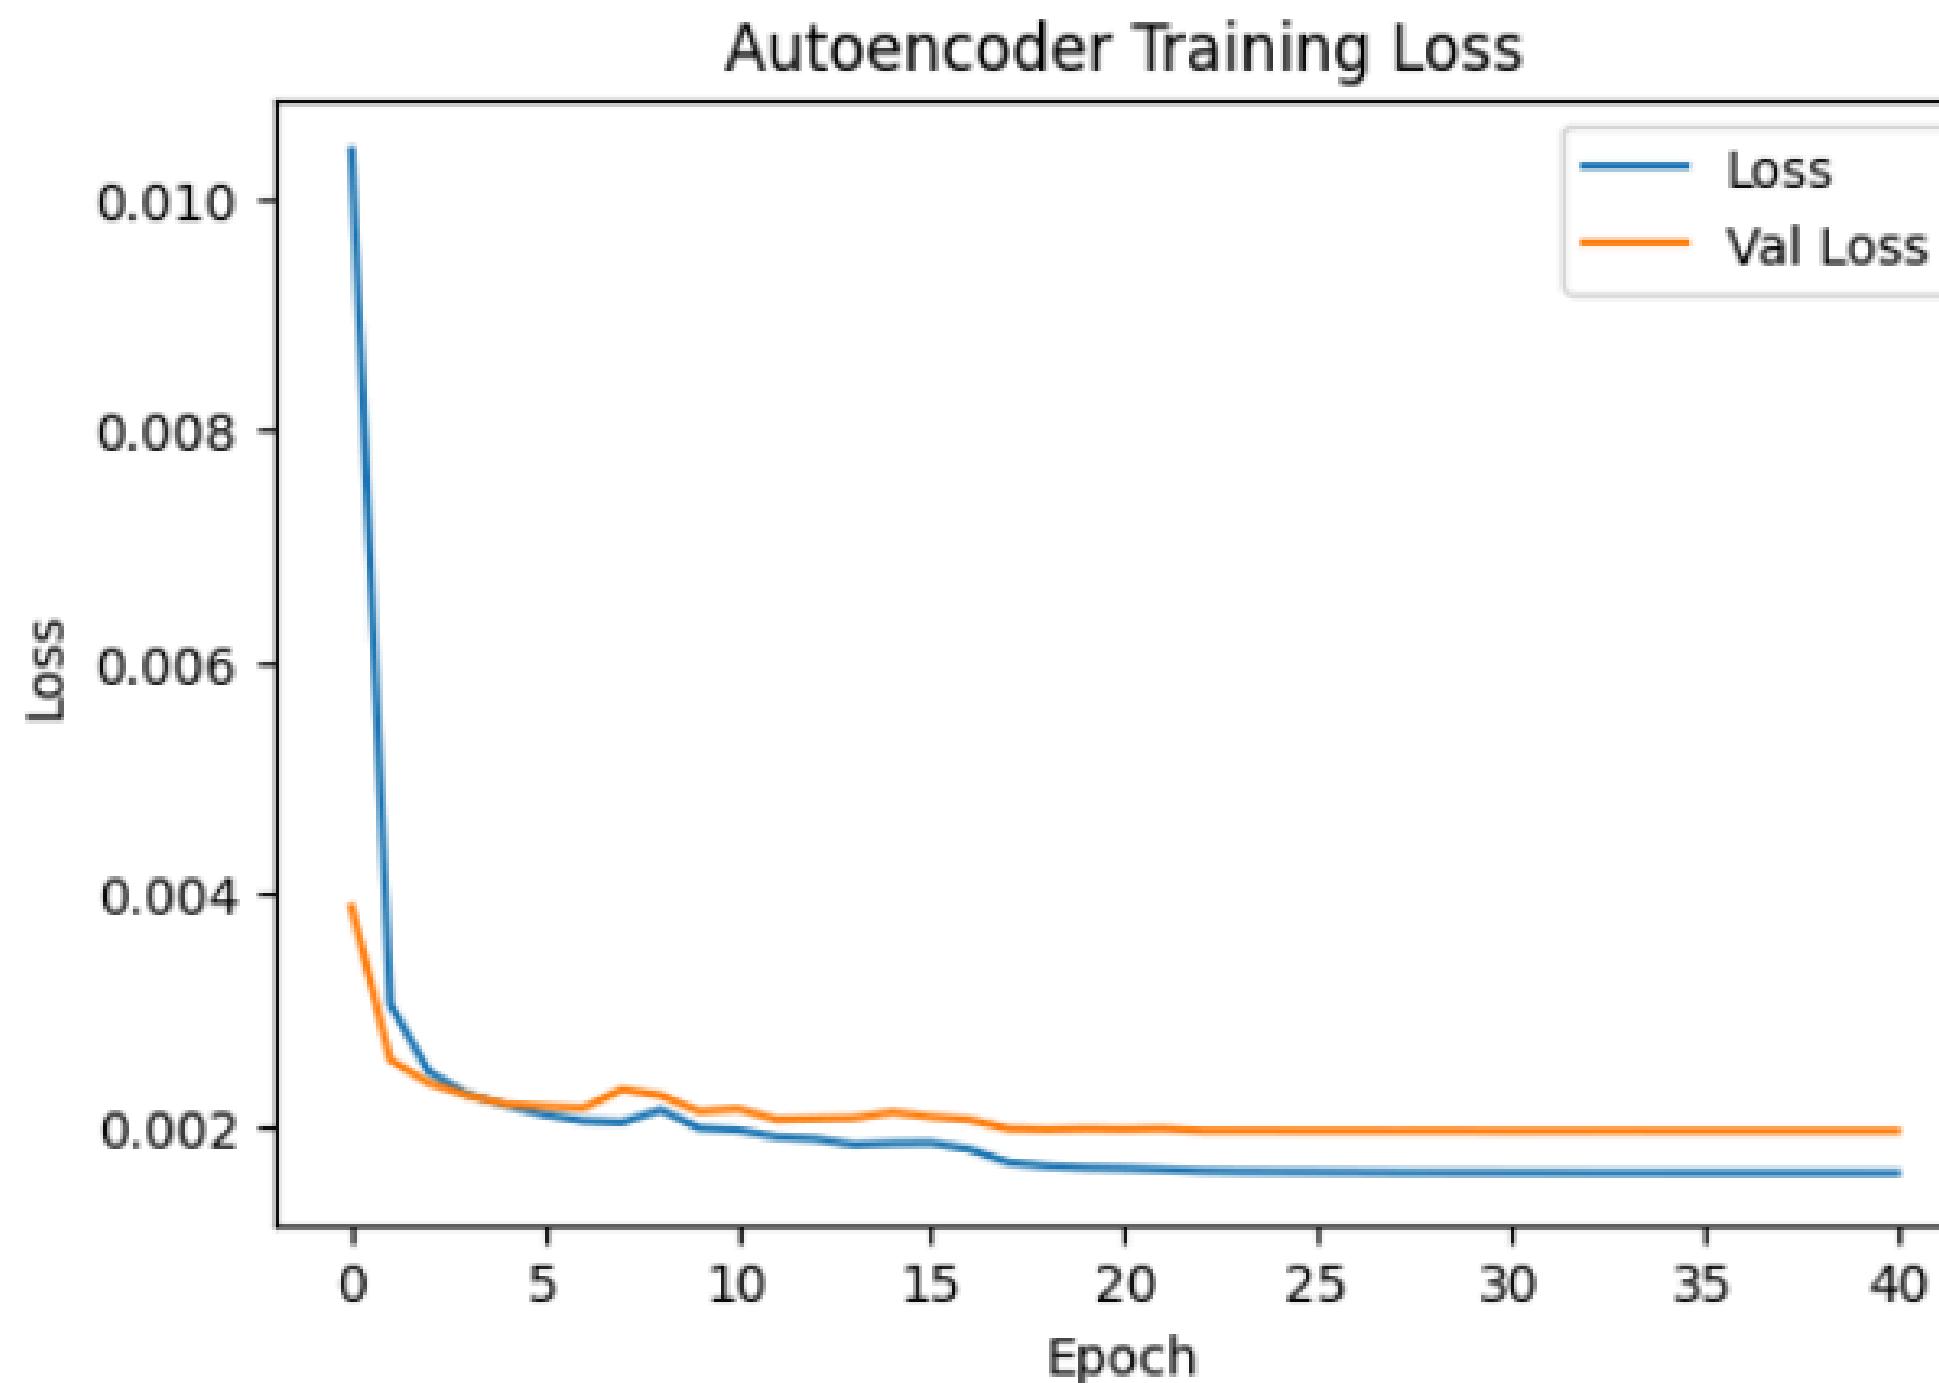
Universidad  
Industrial de  
Santander



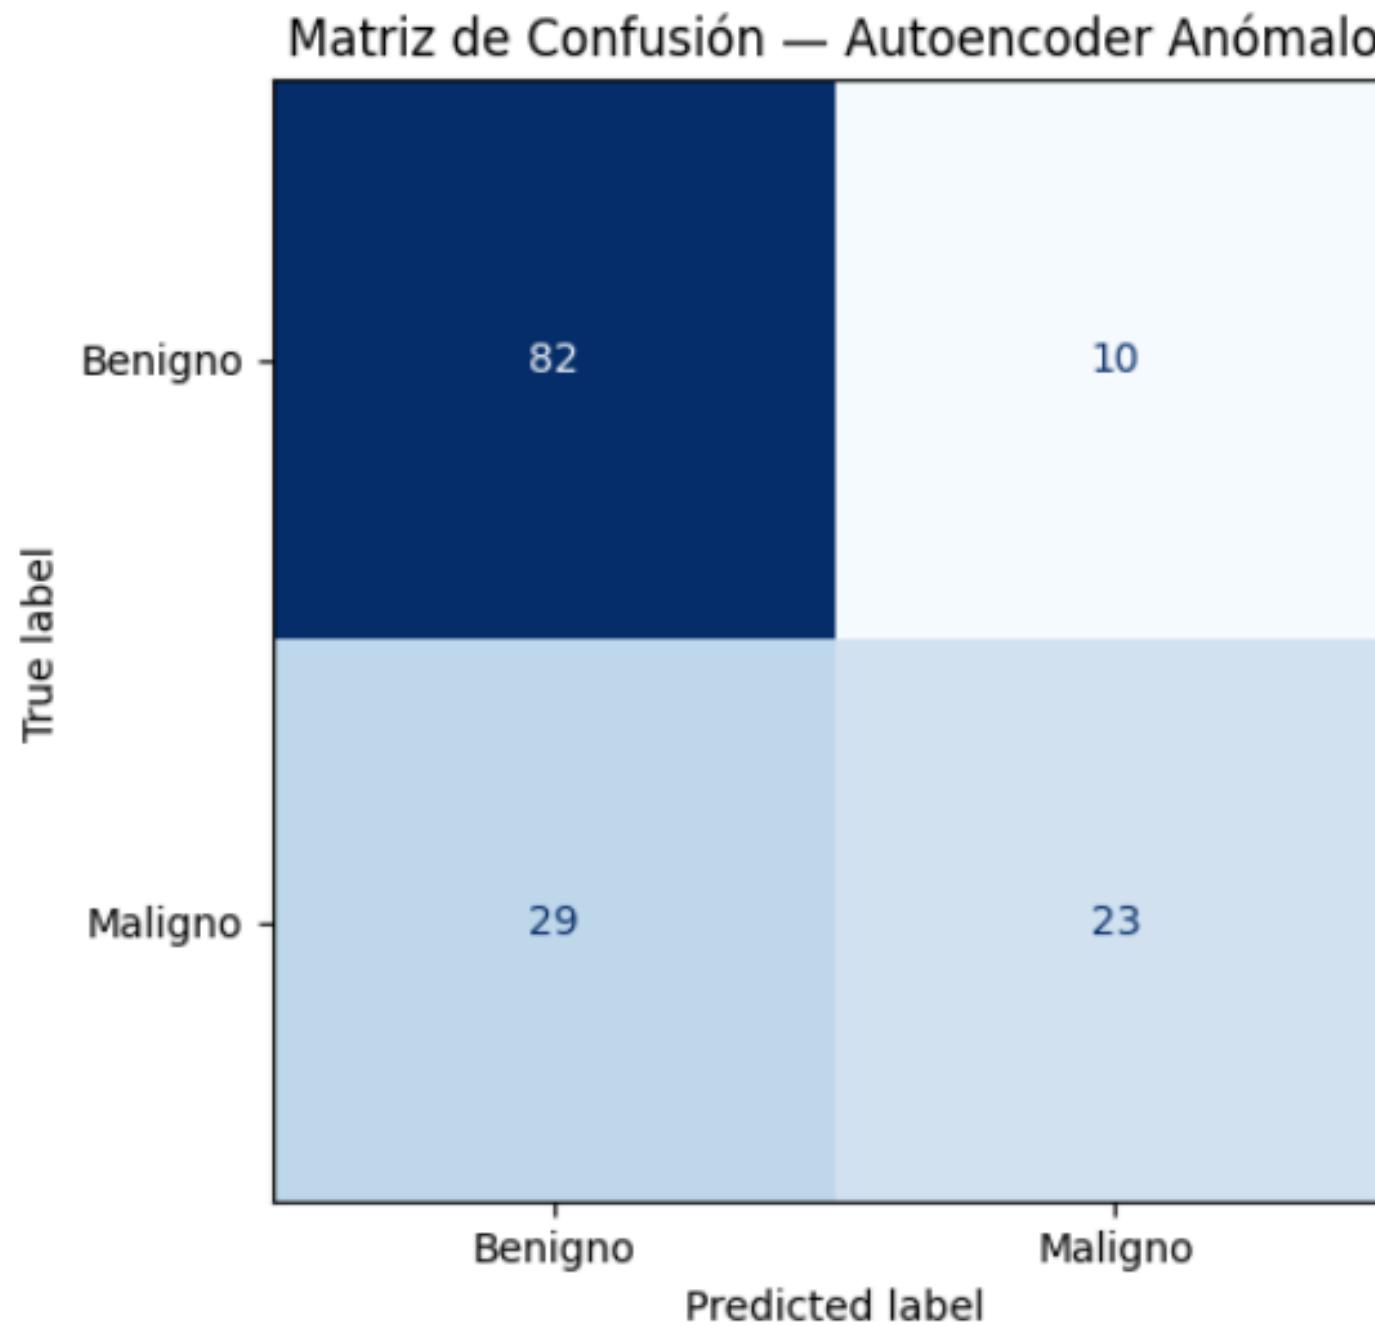
Resultados Autoencoder - Malignos



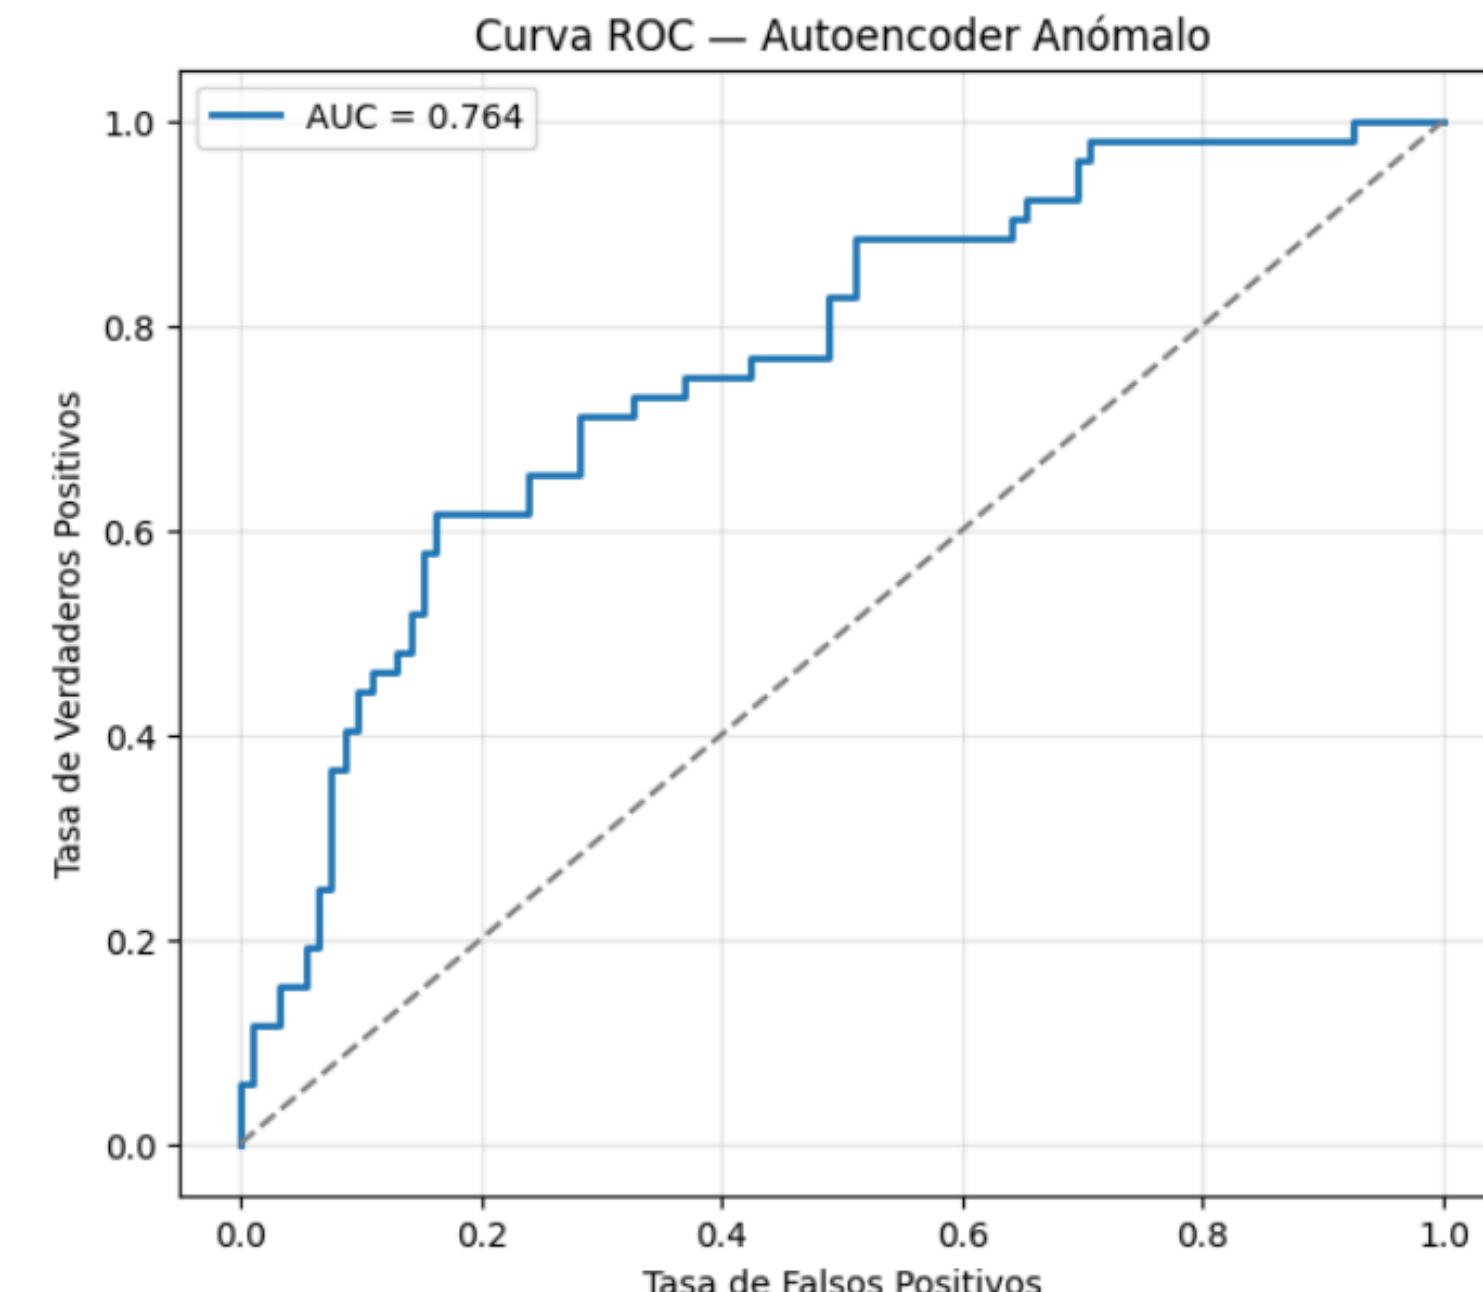
# Loss VS Epochs



# Matriz de Confusión



# Curva ROC



# Resultados

# Resultados

Metrics	DNN	CNN	CNN (Transfer Learning)	AutoEncoder
Loss (Categorical Cross-Entropy)	0,69	0,42	<b>0,39</b>	0,002
Precision	81	80	<b>88</b>	-
Accuracy	81	81	<b>88</b>	-
AUC	84	88	<b>91</b>	-
MAE	-	-	-	0,03
MSE	-	-	-	0,002

# Clasificación de Nódulos Indeterminados

Universidad  
Industrial de  
Santander



En el conjunto de datos, de los 1181 datos indeterminados, 38 tenían **gold standard**.

## Métricas Validación:

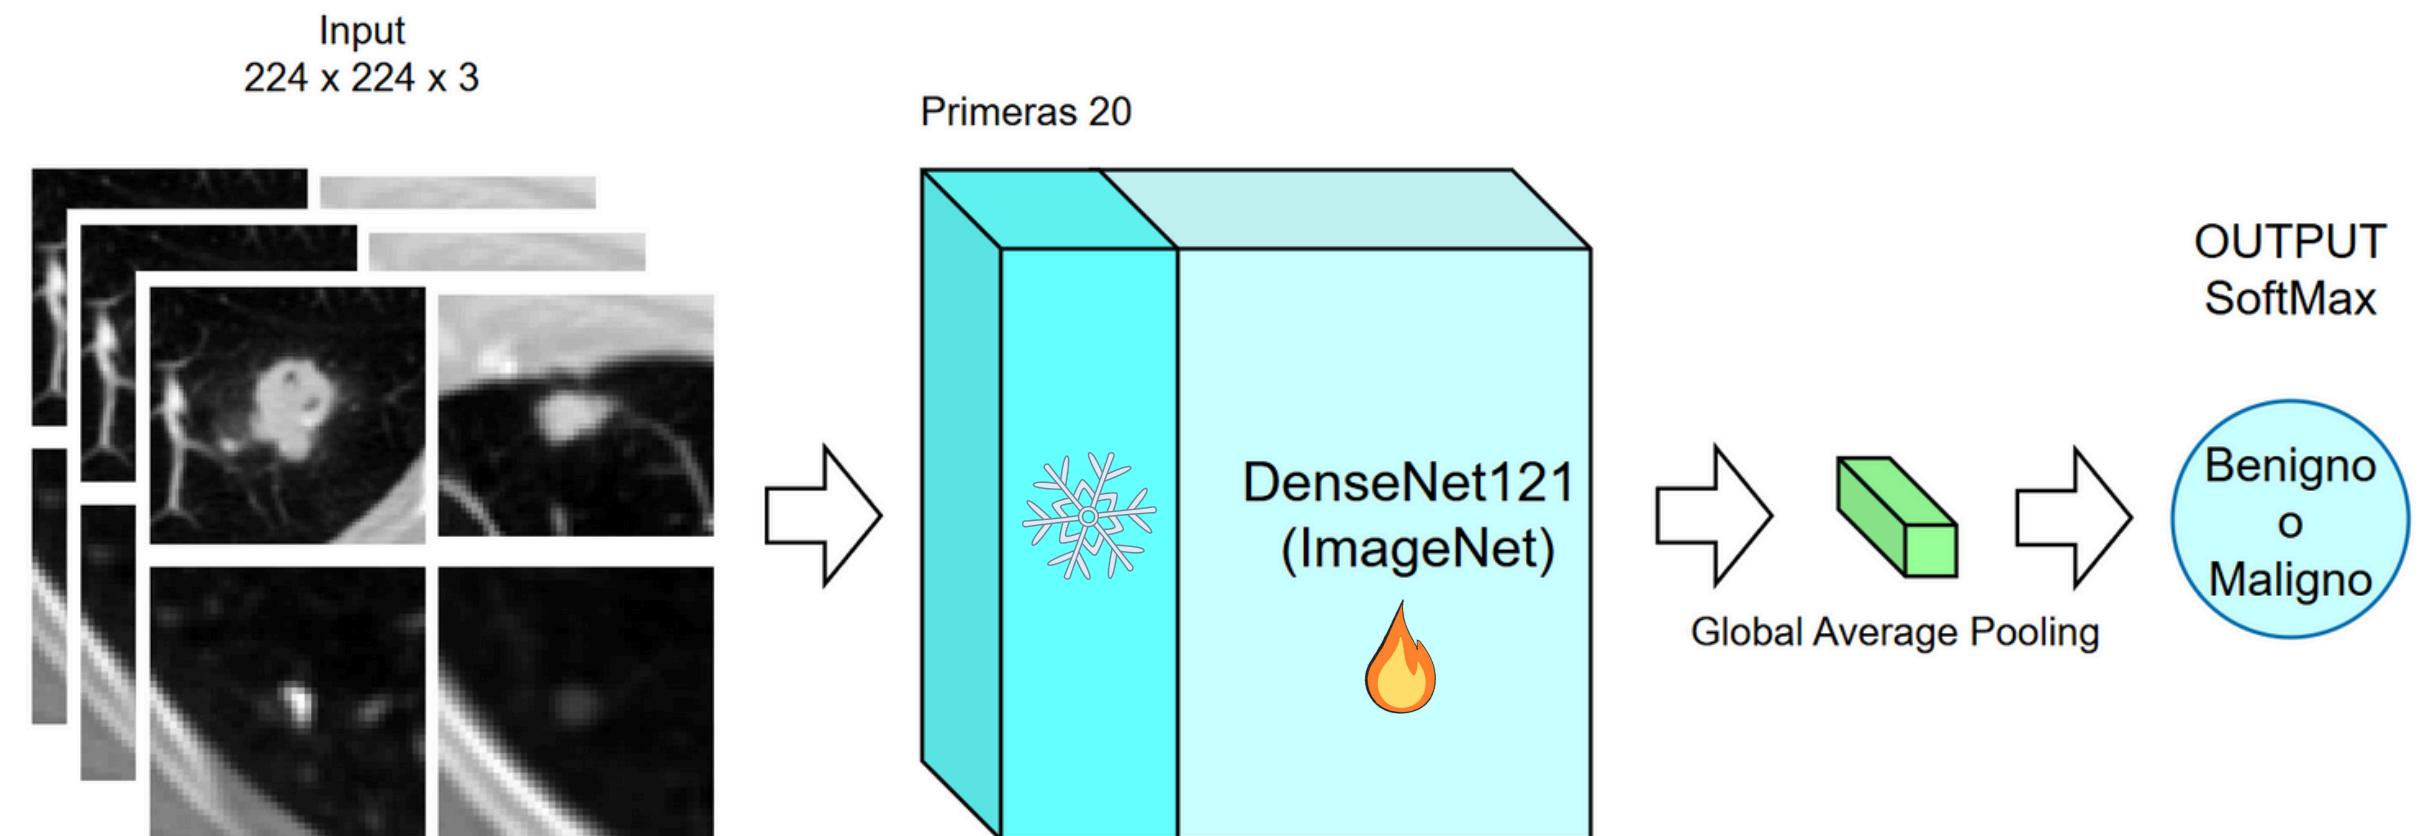
Accuracy: 0.56

Precision: 0.54

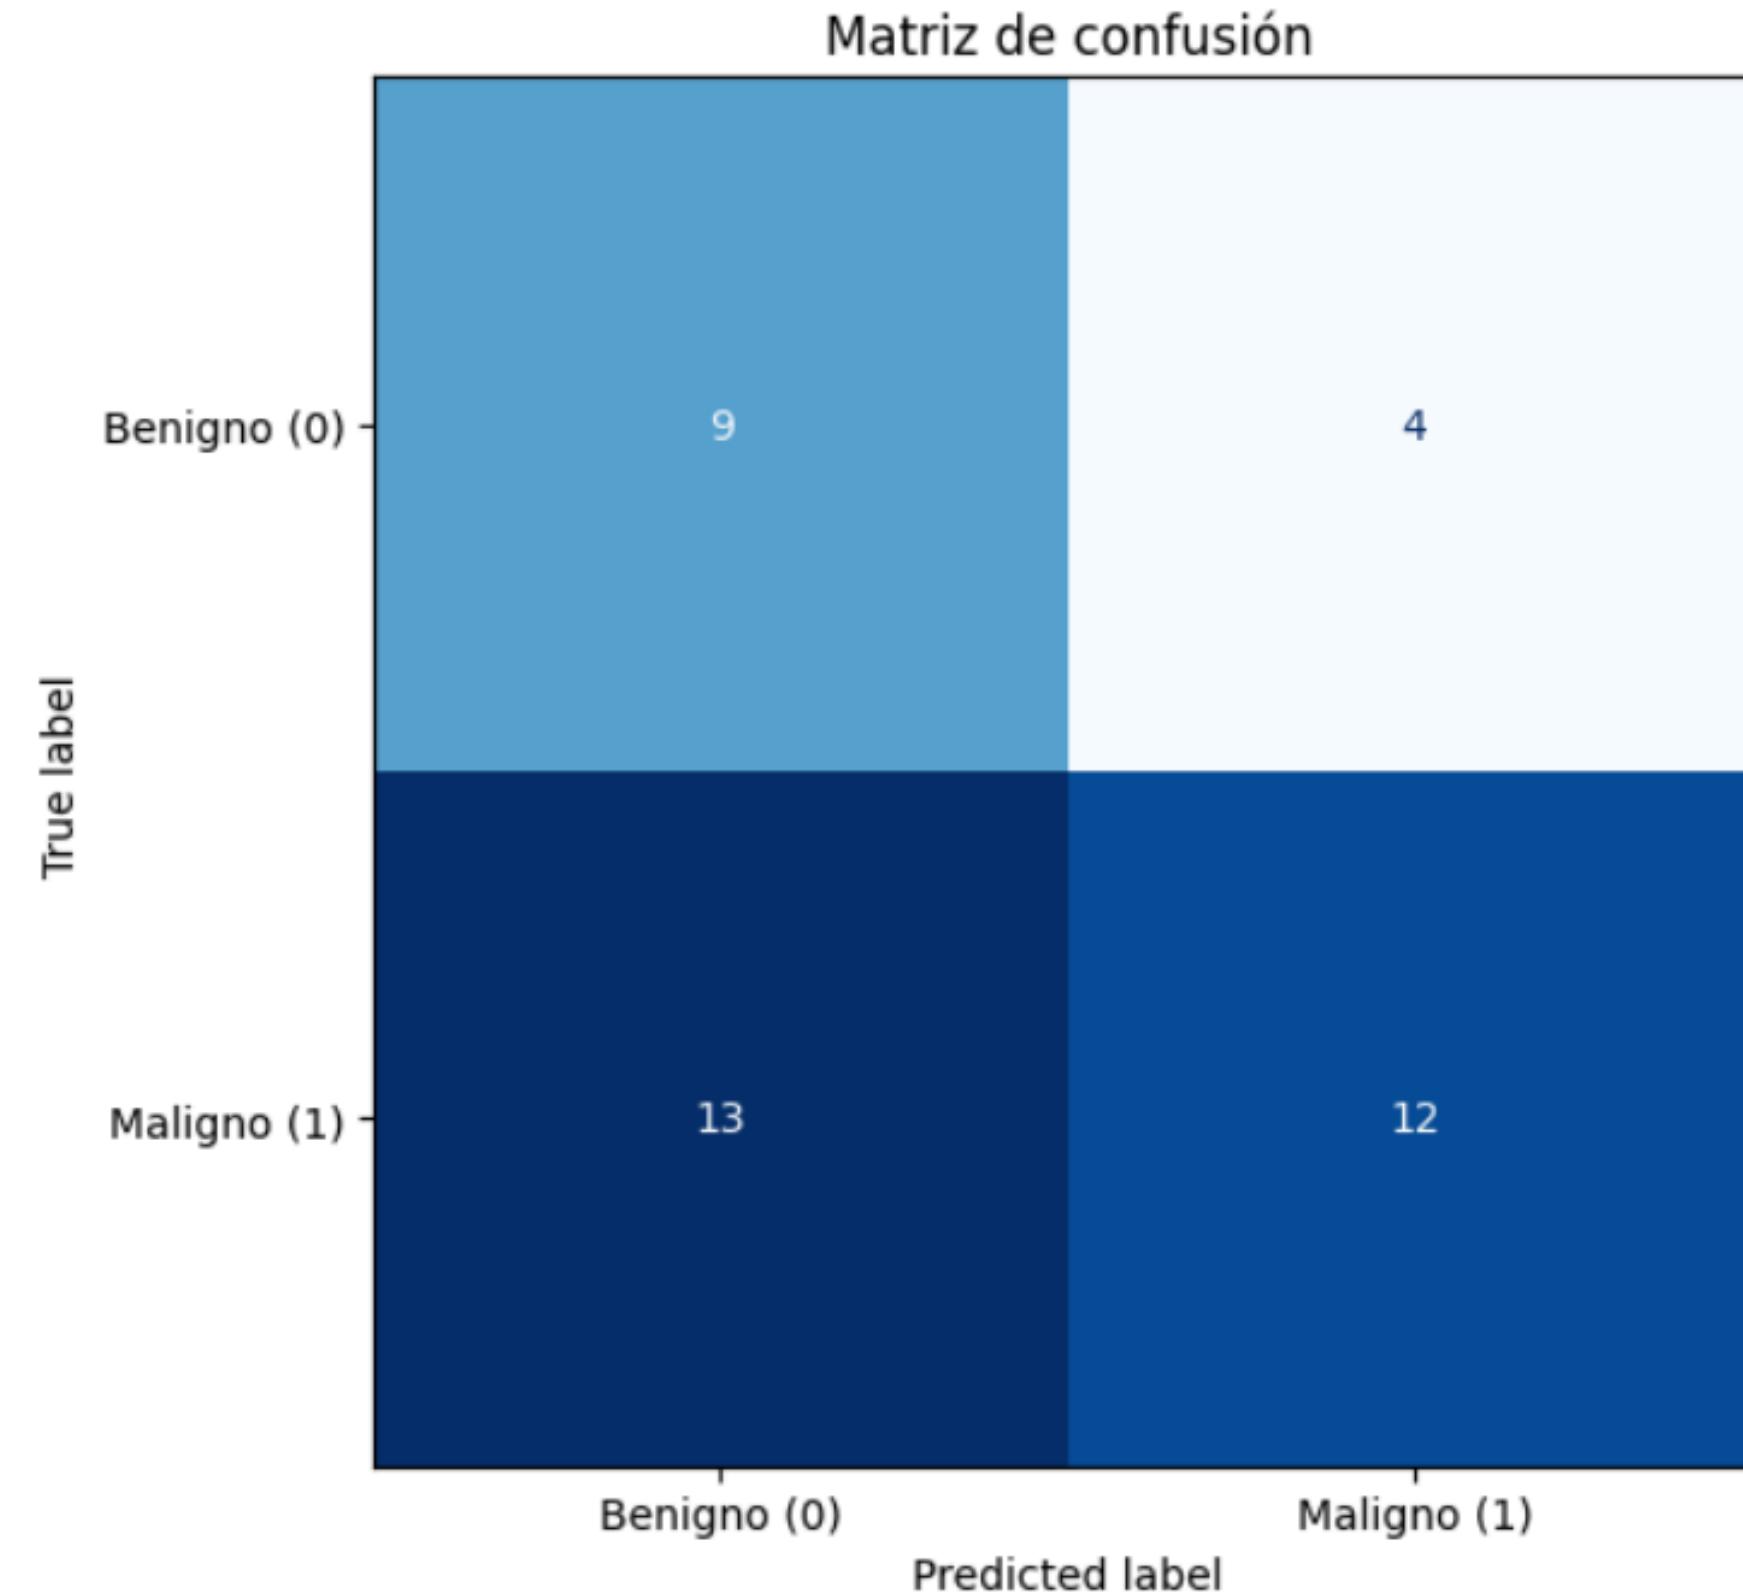
AUC: 0.53

Recall: 0.54

Loss: 0.99



# Matriz de Confusión





# Conclusiones

- Se logró el objetivo de clasificar tanto nódulos malignos y benignos, como los indeterminados, evaluando métricas que midan el desempeño de los modelos
- La CNN con **transfer learning** converge más rápido y es la que mejores resultados nos da con un 88% de accuracy.
- Las arquitectura con **transfer learning** es útil para apoyar procesos de detección temprana durante procedimientos reales sin llegar a reemplazar la tarea radiólogo, pero puede ser mejorada.

# Gracias!

## ¿PREGUNTAS?

